음성 AI 전문가 과정 · Day 1 / 40

Day 01

음성 AI 첫걸음
기술 지형도와 개발환경

Listen → Think → Speak
4 시간 · Colab T4 GPU · 실습 노트북 Part 1 ~ 6

```
# 실습 노트북 1-2 셀 출력
Python      : 3.13
CUDA 사용   : True
GPU         : Tesla T4
FFmpeg      : /usr/bin/ffmpeg

📄 안녕하세요 . 오늘 회의를
   시작하겠습니다 .
⏱️ RTF 0.05 → 실시간보다 빠름
```

사용법만으로는 답하기 어려운 질문

1	Whisper 는 소리를 그대로 듣지 않는다 . 무엇을 " 보고 " 받아쓸까 ?	D3 · D7
2	받아쓰기가 " 잘 됐다 " 는 것을 어떻게 숫자로 말할까 ?	D10
3	우리 회사 전문용어를 Whisper 가 알아듣게 하려면 ?	D12 · D13
4	몇 초짜리 목소리만으로 음성을 복제할 수 있을까 ? 해도 될까 ?	D19
5	음성 비서는 왜 사람보다 늦게 대답할까 ? 얼마나 줄일 수 있을까 ?	D21 · D28

넘어가기 전에 각 질문의 답을 한 줄씩 적어 두세요 . 과정이 끝난 뒤 다시 비교합니다 .

" 어떻게 쓰는가 " 에서 " 왜 이렇게 동작하는가 " 로

	사용법 중심 학습	이번 과정
질문	어떻게 사용하는가	왜 이렇게 동작하는가
확인 방법	실행 결과만 확인	파형 · 스펙트로그램 · RTF · CER · Latency 로 직접 측정
Whisper	model.transcribe() 호출	소리를 어떤 그림으로 바꿔 읽는가 , 얼마나 빠르고 정확한가
TTS	음성 파일 만들기	왜 16kHz mono WAV 로 바꿔야 하는가
음성 비서	STT, LLM, TTS 연결	어느 단계가 얼마나 오래 걸리는가 , 어떻게 줄이는가

가장 큰 차이는 확인 방법 : 설명을 듣고 끝내지 않고 , 설명한 내용이 사실인지 직접 확인한다 .

음성 비서 단면도로 보는 8주

입력 · 오디오 — 1주 디지털 오디오 · 샘플링 · 스펙트로그램 · VAD

ASR 듣기 — 2주 Whisper · faster-whisper · 화자 분리 3주 한국어 Fine-tuning

LLM 생각하기 — 5주 Claude API · Tool Calling · RAG · MCP

TTS 말하기 — 4주 Kokoro · Chatterbox · Voice Cloning 과 윤리

실시간 · 배포 — 6주 Pipecat · LiveKit · Streaming 7주 FastAPI · Docker · Edge

▶ **애니메이션** D1-1 오늘의 흐름 (Part 1 ~ 6)

평가 · 모든 층

CER · WER (정확도)
RTF (속도)
MOS (음질) · Latency (응답)

8주 · 최종 프로젝트

AI 콜센터 , 키오스크 음성 주문 , 회화 튜터 등 한 층도 빠짐없이 조립

공개 모델을 잘 쓰고, 고치고, 조립하는 과정

다루지 않는다

대규모 음성 모델 처음부터 사전학습 (Pretraining)
음악 · 효과음 생성
음성 기반 본인 인증 · 보안 시스템
음성학 · 언어학 이론

다룬다

Whisper · Kokoro 등 공개 모델 활용
한국어 데이터로 Fine-tuning (3 주차)
LLM · Tool · MCP 연결 (5 주차)
실시간 파이프라인과 배포 (6 ~ 7 주차)

```
# 오늘 쓰는 공개 모델과 도구
faster-whisper (large-v3-turbo)   edge-tts   jiwer   librosa   Claude API (선택)
```

Day 한 편의 흐름과 자료 구성

문제 상황 › 핵심 개념 › Animation › Colab 실습 › 빈칸 실습 › Worksheet › 정리

D1_실습.ipynb

실습 노트북

Colab 에서 따라 하기 · 빈칸 6 개 · 정답 보기

animation.html

애니메이션

9 개 탭 · 마이크 실시간 · 직접 조작

worksheet.html

개념 워크시트

4 교시 × 10 문항 · 교시마다 채점 · 오답 캡처 → 노션 제출

slides.pptx

강의 슬라이드

지금 보는 자료 · 발표자 노트 포함

권장 순서 : 슬라이드 설명 → 노트북 따라 하기 (출력 비교 , 다르면 오류 해결표) → animation.html 직접 조작 → 빈칸 실습 → 교시 끝 worksheet.html → 오답 캡처를 노션에 제출

무엇을 넣고, 무엇을 얻는가

ASR	음성	**ASR 모델 · Whisper**	글자	2 ~ 3주
TTS	글자	**TTS 모델 · edge-tts, Kokoro**	음성	4주
Speech-to-Speech	음성	**S2S 모델 · Realtime, Live**	음성	6주
Voice Agent	음성	**STT › LLM › TTS**	음성	5 ~ 6주

▶ **애니메이션** D1-2 4대 기술 입출력 흐름

이미 매일 쓰고 있는 네 가지 기술

ASR · 받아쓰기

회의록 자동 작성 · 동영상 자막
콜센터 녹취 분석 · 음성 검색

TTS · 읽어주기

지하철 안내 방송 · 오디오북
내비게이션 · 화면 읽어주기

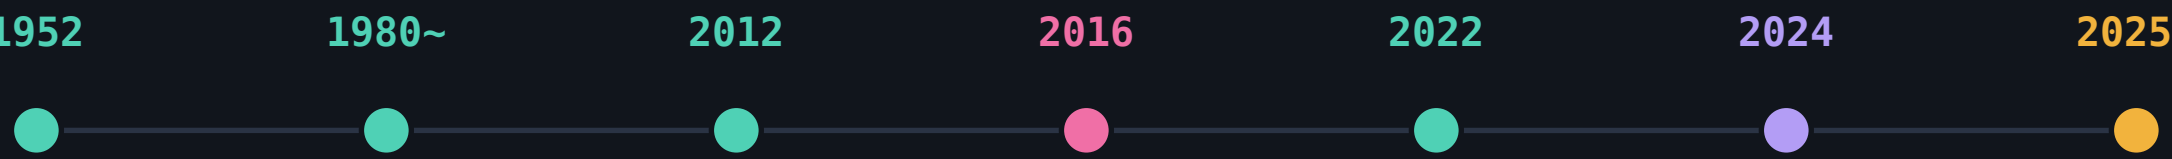
Speech-to-Speech

실시간 통역
감정이 살아 있는 자연스러운 대화

Voice Agent

AI 콜센터 상담원 · 예약 비서
키오스크 음성 주문

규칙에서 딥러닝 , 그리고 실시간 에이전트로



2022 년 Whisper 공개 이후 누구나 고품질 음성 인식을 쓸 수 있게 되었고 , 이제는 듣고 말하는 에이전트로 발전하고 있다 .

Google Colab · T4 GPU · Python 3.13

구성	기준	확인 방법
Runtime	Google Colab · T4 GPU	`!nvidia-smi`
Python	3.13 (Colab 기본)	`sys.version`
PyTorch	CUDA 사용 가능	`torch.cuda.is_available()`
FFmpeg	Colab 기본 설치	`!ffmpeg -version`
ASR	faster-whisper · large-v3-turbo	Part 5 모델 로드 셀
TTS	edge-tts · ko-KR 목소리	Part 2 목소리 목록
LLM (선택)	Claude API · Colab Secrets	ANTHROPIC_API_KEY

GPU 런타임을 선택한다

런타임 › 런타임 유형 변경 › T4 GPU › 저장

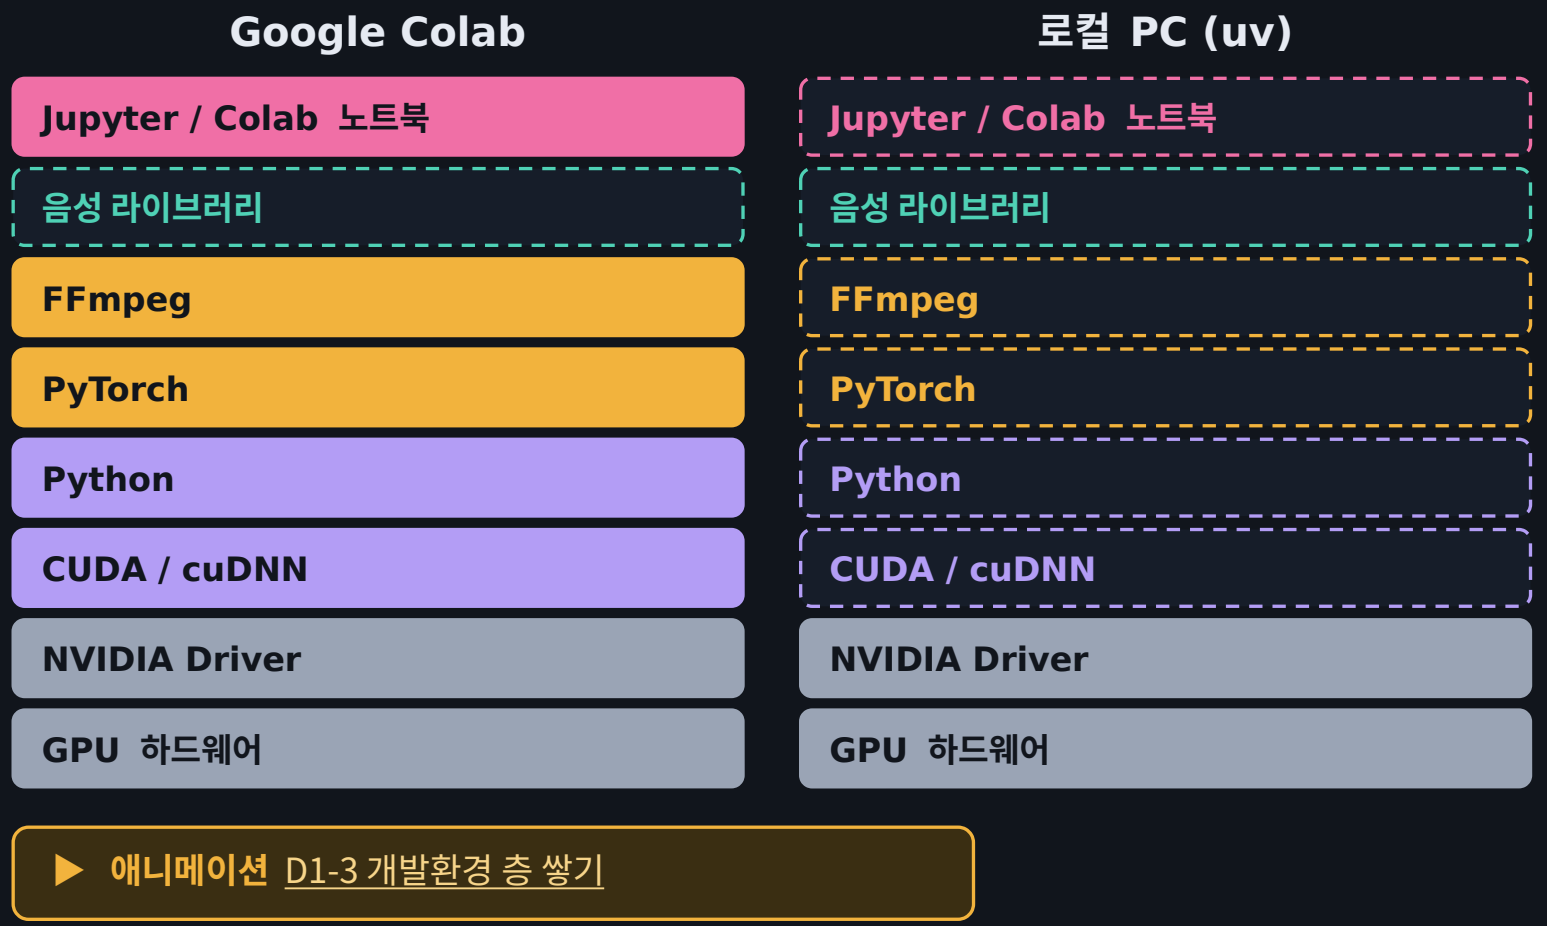
CPU 로 실행해도 동작하지만 ASR 이 small 모델로 바뀌고 훨씬 느리다.

```
$ !nvidia-smi
| Tesla T4   ...   15360MiB |

CUDA 사용    : True
```

API 키가 없어도 실습은 끝까지 진행된다. Part 6 의 LLM 이 규칙 기반 응답으로 자동 대체되기 때문이다.

아래층이 맞아야 위층이 동작한다



▶ **애니메이션** D1-3 개발환경 층 쌓기

읽는 법

색이 채워진 층 : 이미 준비됨
점선 층 : 직접 설치

Colab 에서는 맨 위 음성 라이브러리만 pip 로 설치한다 .

libcublas.so.12 오류는 CUDA 층 문제다 .

관찰하고 측정하려면 도구가 먼저

```
!pip install -q faster-whisper edge-tts \
    anthropic jiwer librosa soundfile
✅ 설치 완료

# Part 5: CUDA 12용 라이브러리 (GPU 사용 시)
!pip install -q nvidia-cublas-cu12 \
    "nvidia-cudnn-cu12==9.*"
```

도구	하는 일	Part
edge-tts	글자 → 목소리 합성	2
librosa	파형 · 스펙트로그램	3
ffmpeg	16kHz mono 변환	2 · 4
faster-whisper	받아쓰기 (ASR)	5
jiwer	CER 계산	5
anthropic	Claude API (LLM)	6

🧩 **빈칸 실습 1** `gpu_ok = torch.cuda.____()` 정답 : is_available

실습 파일은 위에서부터 차례로 실행한다 . 중간 셀을 건너뛰면 뒤에서 NameError 가 난다 .

집에서는 uv 로 같은 환경을 만든다

```
# 설치 (Windows PowerShell)
> irm https://astral.sh/uv/install.ps1 | iex
# 프로젝트 만들기
$ uv init voice-ai && cd voice-ai
$ uv python pin 3.11
$ uv add torch faster-whisper edge-tts jiwer jupyterlab
# 실행
$ uv run jupyter lab
```

uv 란 ?

Rust 로 만든 매우 빠른 Python 패키지 관리 도구 . pip · venv · Python 버전 관리를 한 번에 한다 .

과제 3

로컬 PC 에 uv 로 환경을 만들고 torch.cuda.is_available() 결과 화면을 캡처해 제출한다 .

글자가 소리 파일이 되기까지

문장
" 안녕하세요 "
›
edge-tts
목소리 합성
›
mp3
24kHz
›
ffmpeg
-ar 16000 -ac 1
›
WAV
16kHz mono
›
음성 모델
Whisper

16kHz

1 초에 16,000 번 소리를 측정했다는 뜻

mono

채널이 하나 . 음성 모델의 공통 입력 형식

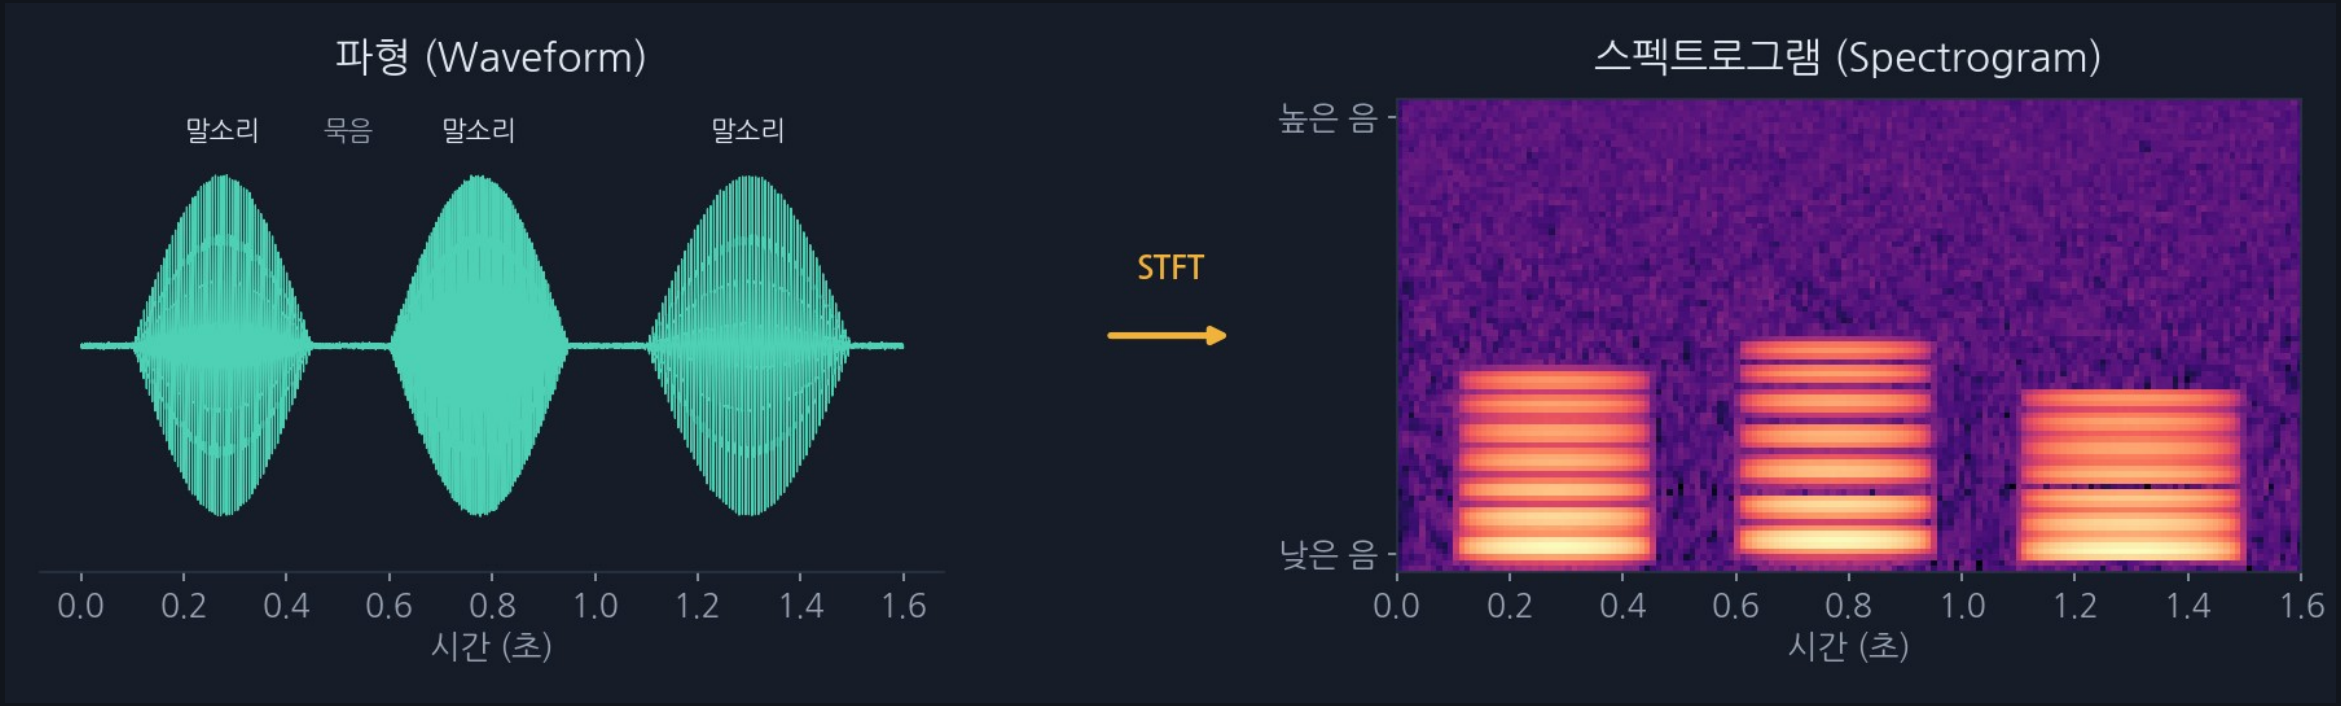
한국어 목소리

ko-KR-SunHiNeural (여성)
ko-KR-InJoonNeural (남성)

🧩 **빈칸 실습 2** `my_voice = "____"  # 남성 목소리` 정답 : ko-KR-InJoonNeural

▶ **애니메이션** D1-4 소리 파일의 여행

소리를 보는 두 가지 방법



파형

시간에 따른 소리의 크기 . 평평하면 묵음

스펙트로그램

언제 , 어떤 높낮이의 소리가 났는가 . Whisper 가 읽는 그림

▶ **애니메이션** D1-5 내 목소리 보기 (마이크 실시간)

샘플 수로 오디오 길이를 알 수 있다

80,000 ÷ **16,000** = **5 초**

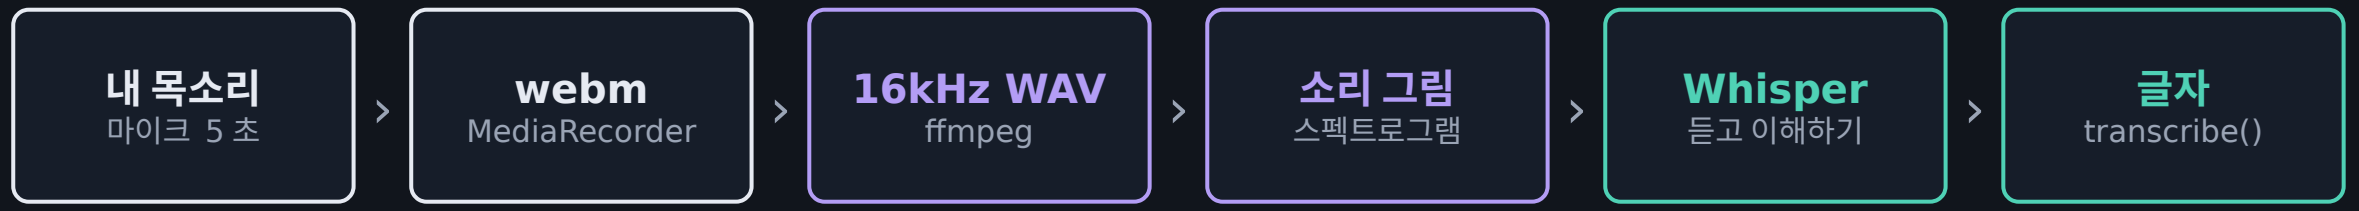
샘플 수 | 1 초당 측정 횟수 | 오디오 길이

```
샘플 수 : 80,000 | 샘플링 레이트 : 16000 Hz
길이 : 5.00 초 | 범위 : [-0.612, 0.587]
```

🧩 **빈칸 실습 3** `len(y) / ____` 정답 : sr

▶ **애니메이션** D1-6 샘플링 체험 · 길이 계산기

Whisper 는 그림을 보고 글자를 쓴다



환경	모델	특징
GPU (T4)	`large-v3-turbo`	정확하고 빠름 · 오늘 기본값
CPU	`small`	가벼움 · 정확도 낮음

```
📄 sample.wav
[  0.00s →  4.20s] 안녕하세요 .  음성 AI
⏱️ 처리 0.4s | 오디오 7.8s | RTF 0.05
```

출력 수치는 예시

🧩 **빈칸 실습 4** `text, segs, info, elapsed = ____(my_wav)` 정답 : transcribe

▶ **애니메이션** D1-7 받아쓰기와 RTF

말하는 속도보다 빨리 받아쓸까 ?

10 초 음성을 1 초 만에 받아쓰면

0.1

RTF = 처리 시간 ÷ 음성 길이 = 1 ÷ 10

RTF < 1 · 실시간보다 빠름

말하는 속도보다 빨리 받아쓴다 . 음성 비서에 쓸 수 있다 .

RTF > 1 · 실시간보다 느림

녹음 파일을 모아서 나중에 처리하는 용도에 맞는다 .

몇 글자나 틀렸을까 ?

정답	오	늘	날	씨	좋	다	·
인식	오	·	날	시	좋	다	요
	일치	삭제	일치	대체	일치	일치	삽입

50%

3 번 틀림 ÷ 정답 6 글자

🧩 **빈칸 실습 5** `cer = jiwer.____(ref, hyp)` 정답 : cer

▶ **애니메이션** D1-8 CER 계산기 (직접 입력)

같은 음성 , 단계마다 보이는 모습이 다르다

librosa.load

숫자 배열

```
y.shape = (80000,)
float32, -1 ~ 1
1 초에 16,000 개
```

show_audio

소리 그림

```
80 mel × 약 500 frame
밝을수록 강한 소리
묵음은 어둡게
```

transcribe

시간 + 글자

```
[0.00s → 4.20s]
안녕하세요 . 음성 AI
RTF 0.05
```

jiwer.cer

정확도

```
REF 와 HYP 비교
대체 · 삭제 · 삽입
CER 0.00%
```

sample.wav 하나를 네 단계에서 관찰 : **숫자 → 그림 → 글자 → 점수**

출력 수치는 예시이며 실행 환경에 따라 다르다 .

만날 수 있는 오류와 해결

오류 메시지	원인	해결 (노트북에 반영됨)
`open() got an unexpected keyword argument 'metadata_errors'`	최신 PyAV 와 faster-whisper 충돌	파일 경로 대신 load_16k() 로 읽은 numpy 배열 전달
`libcublas.so.12 is not found`	CUDA 12 라이브러리 없음 (CUDA 층)	nvidia-cublas-cu12, cudnn 설치 후 미리 로드
`CUDA 사용 : False`	런타임 유형이 CPU	런타임 유형 변경 › T4 GPU
`NameError: name '____' is not defined`	빈칸을 채우지 않고 실행	빈칸을 채운 뒤 다시 실행
`녹음 실패 · 마이크 권한`	브라우저 마이크 권한 거부	주소창 권한 허용 , 안 되면 sample.wav 사용

오류가 나면 개발환경 층 그림을 떠올린다 . 메시지가 어느 층 이야기인지부터 찾는다 .

지금까지 만든 부품을 이어 붙인다




```
# 🧩 빈칸 실습 6: 함수 이름 3개로 조립
user_text = transcribe(input_wav)[0]
reply, _  = llm_reply(user_text)
out = await tts(reply, "my_agent.wav")
```

API 키가 없다면

llm_reply() 가 규칙 기반 응답으로 자동 대체된다 .
" 지금 몇 시야 ?" → 현재 시각

▶ **애니메이션** D1-9 음성 비서 시뮬레이터

음성 비서의 답변은 짧은 말투로

텍스트 챗봇	음성 비서
표 · 목록 · 이모지 사용	기호가 그대로 읽히므로 쓰지 않음
길고 자세한 답변	1 ~ 2 문장 , 길면 기다림이 늘어남
문어체	구어체
괄호로 보충 설명	괄호 없이 문장으로 풀기

```
SYSTEM_PROMPT = (
  "당신은 친절한 한국어 음성
  비서입니다 . 답변은 TTS 로
  읽히므로 마크다운 , 목록 ,
  이모지 , 괄호를 쓰지 말고
  1~2 문장의 짧은 구어체로
  답하세요 ."
)
```

과제 2: SYSTEM_PROMPT 를 바꿔 나만의 음성 비서 캐릭터 (예 : 영어 회화 선생님) 만들기

사용자가 기다리는 시간 = 세 단계의 합



예시 값 . 실제 값은 노트북 Part 6 의 막대 그래프로 확인한다 .

사람은 약 0.2 초

상대가 말을 끝낸 뒤 대답이 시작되기까지의 평균 간격

Streaming · 6 주차

앞 단계가 끝나기 전에 조금씩 먼저 넘겨 첫 소리를 앞당긴다

Speech-to-Speech

글자로 바꾸는 단계를 없애 더 빨리 대답한다

▶ **애니메이션** D1-9 음성 비서 • Streaming 비교 켜기

정리 · 다음 시간 Day 2

디지털 오디오와 음성 신호 처리 기초

- [ ] torch.cuda.is_available() 가 True 다
- [ ] edge-tts 로 내 문장을 남자 목소리로 만들었다
- [ ] 파형과 스펙트로그램을 보고 묵음 구간을 찾았다
- [ ] 내 목소리를 받아쓰고 RTF 를 확인했다
- [ ] CER 을 계산하고 대체 · 삭제 · 삽입을 구분했다
- [ ] 함수 3 개로 음성 비서를 조립했다

다음 : Day 2

오늘 본 한 줄
샘플 수 : 80,000 | 16000 Hz

이 숫자 80,000 개는 어떻게 만들어지고 , 무엇을 잃고 무엇을 남길까 ?

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D1_ 실습 .ipynb	빈칸 6
실습 노트북	

레포 위치 04-voice-ai/day01