음성 AI 전문가 과정 · Day 3 / 40

Day 03

주파수 분석

FFT · STFT · Mel · MFCC

Sum of Sines → DFT → STFT → Mel → MFCC
4 시간 · Colab CPU · 실습 노트북 Part 1 ~ 6

```
>>> extract_features("speech.wav")

Log-Mel (80, 593)   ← Whisper 입력
MFCC    (13, 593)   ← 봉우리 모양
1 초에 약 100 frame

>>> logmel_30s.shape
(80, 3000)
```

출력 예시

Whisper 가 읽는 " 소리 그림 " 은 어떻게 만들어질까

1	목소리 같은 복잡한 소리는 무엇으로 이루어져 있을까 ?	Part 1
2	FFT 는 신호 속 주파수를 어떻게 찾아낼까 ?	Part 2
3	25 ms 로 잘라 보면 몇 Hz 차이까지 구분할 수 있을까 ?	Part 3
4	Whisper 의 80 × 3000 입력은 정확히 어떻게 만들까 ?	Part 4 · 5
5	목소리 높이가 달라도 " 아 " 를 " 아 " 로 알아보는 특징은 ?	Part 6

수업이 끝나면 다섯 질문 모두에 수식 하나와 한 문장으로 답할 수 있어야 한다 .

사인파에서 MFCC 까지

Part 1 사인파의 합 › **Part 2** DFT 원리 › **Part 3** FFT 실습 › **Part 4** STFT › **Part 5** Mel › **Part 6** MFCC · 추출기

교시	내용	실습
1 교시	사인파의 합 , 배음 · 포먼트 , DFT 원리 , 오일러	Part 1 ~ 2 · 빈칸 1, 2 · 워크시트 1 교시
2 교시	FFT 실습 : 해상도 , 창 함수 , dB	Part 3 · 빈칸 3 · 워크시트 2 교시
3 교시	STFT, 스펙트로그램 , 트레이드오프	Part 4 · 빈칸 4 · 워크시트 3 교시
4 교시	Mel, Log-Mel, MFCC, 특징 추출기	Part 5 ~ 7 · 빈칸 5 ~ 7 · 워크시트 4 교시 · 노션 제출

▶ **애니메이션** D3-1 오늘의 흐름 (Part 1 ~ 6)

복잡한 소리 = 배음 (f_0 의 정수배) 의 합



음 높이 = f_0

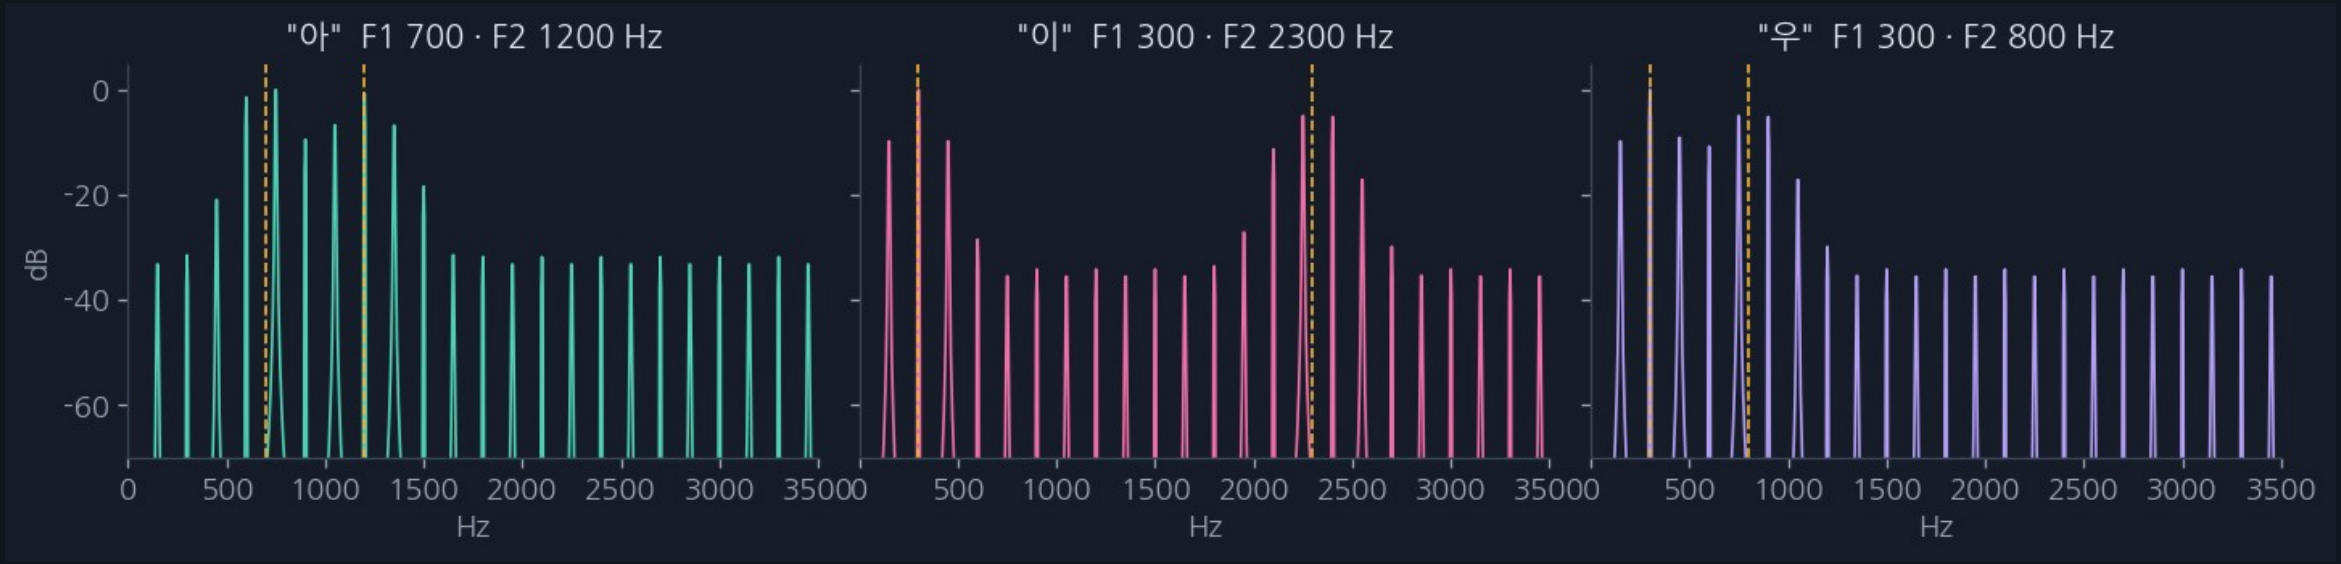
반복 주기 $T = 1/f_0$. 배음을 바꿔도 그대로

음색 = A_k

각 배음의 크기 비율 . 피아노 vs 바이올린 , " 아 " vs " 이 "

▶ **애니메이션** D3-2 사인파의 합 (배음 슬라이더)

같은 높이, 다른 모음: 봉우리 위치가 다르다

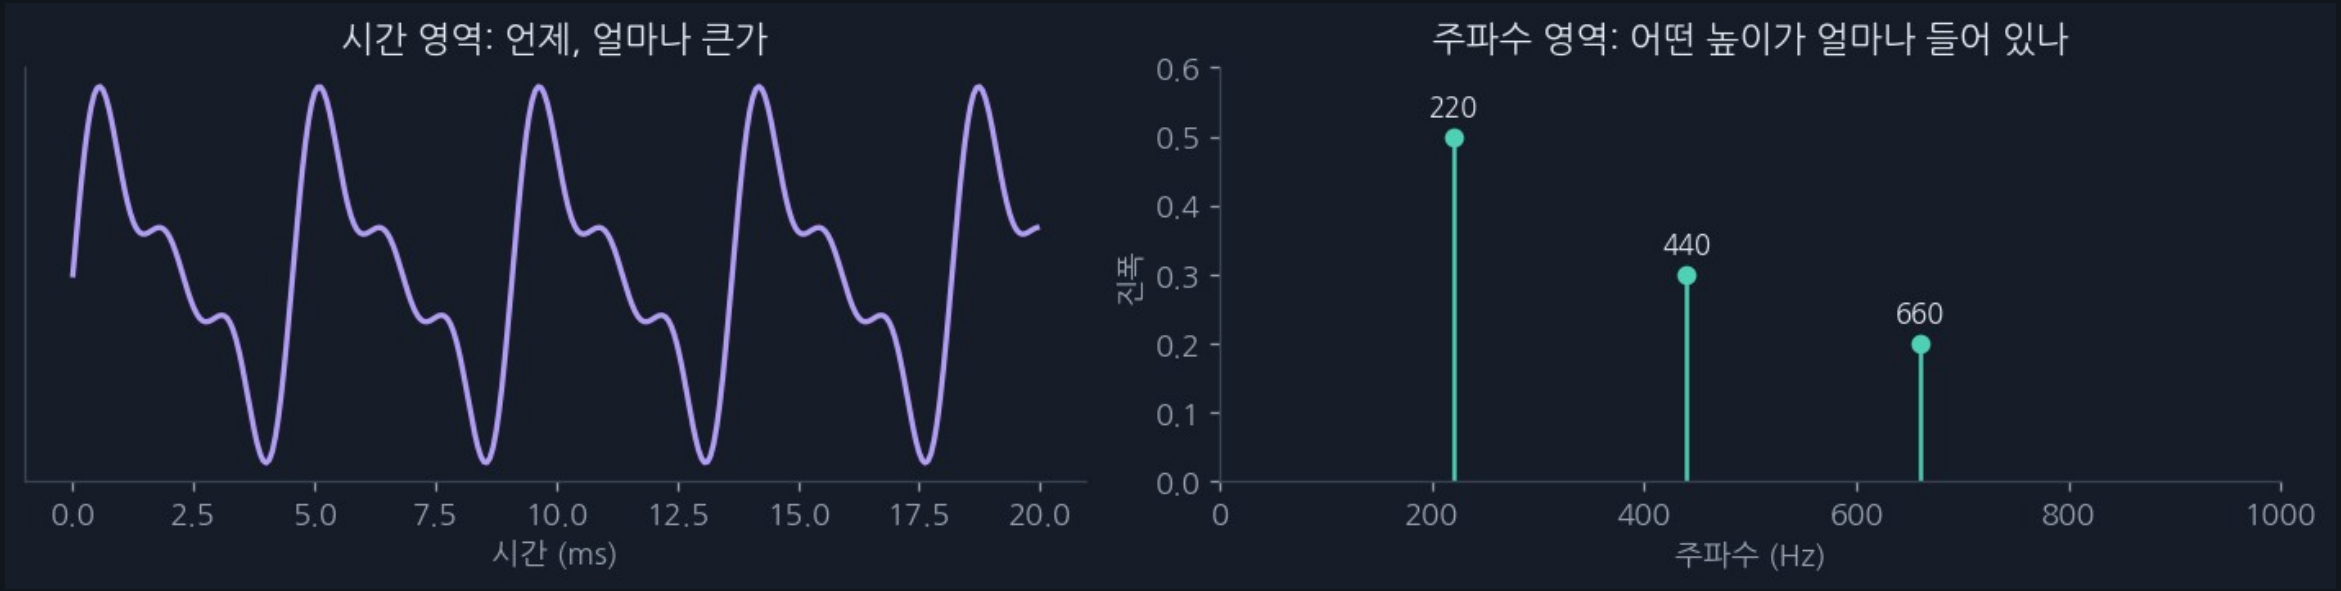


$$x(t) = \Sigma\ A_k \sin(2\pi \cdot k \cdot f_0 \cdot t + \varphi_k)$$

$A_k \approx G(k \cdot f_0)$ $\quad G =$ 성도의 봉우리 모양

모음	F1	F2
아	약 700 Hz	약 1200 Hz
이	약 300 Hz	약 2300 Hz
우	약 300 Hz	약 800 Hz

시간 영역과 주파수 영역



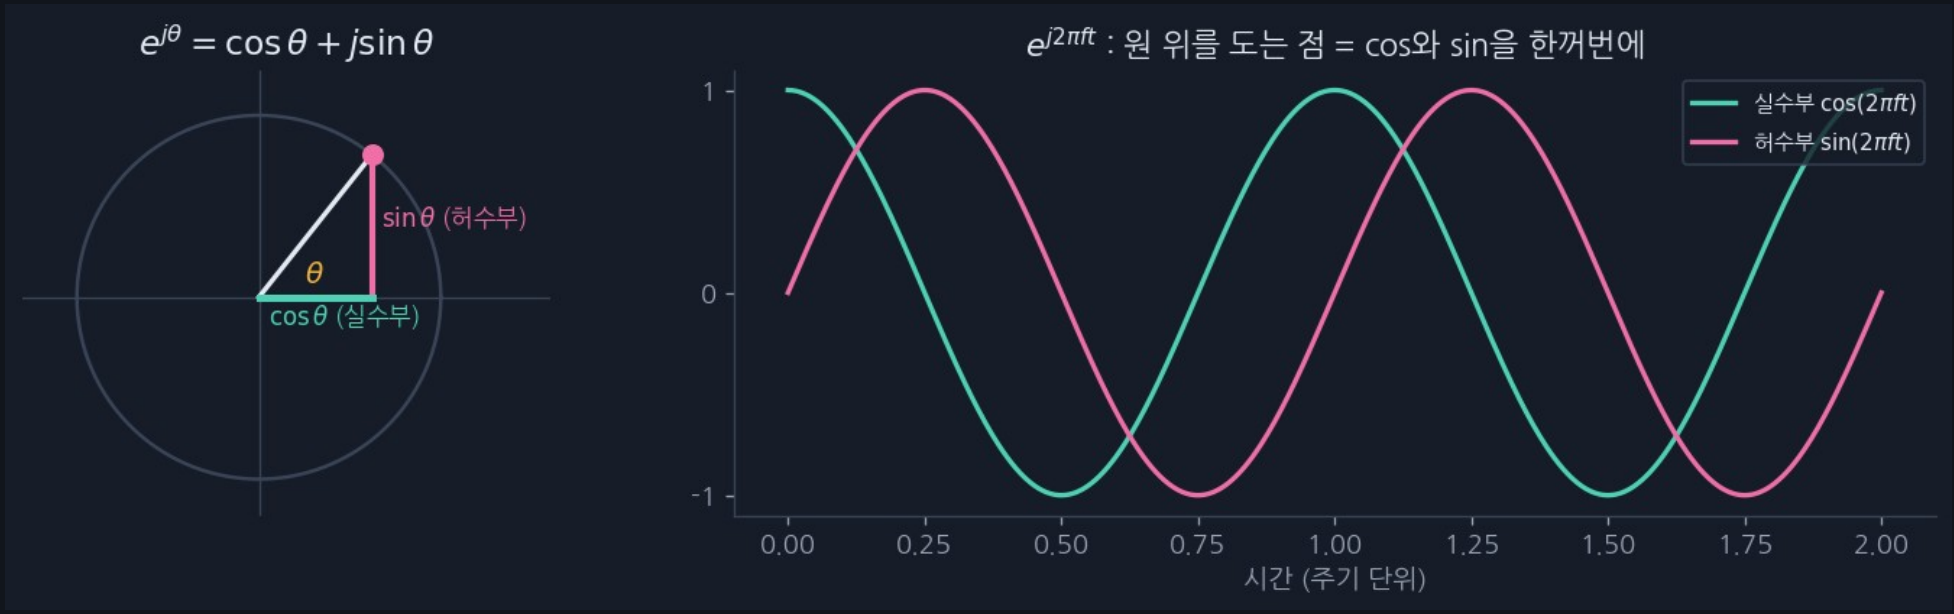
FFT: 시간 영역 → 주파수 영역 . STFT: 둘을 합쳐 " 언제 , 어떤 높이가 " (스펙트로그램)

시험 사인파와 곱해서 더하기



▶ **애니메이션** D3-3 DFT 원리 (스캔 • 감아 보기)

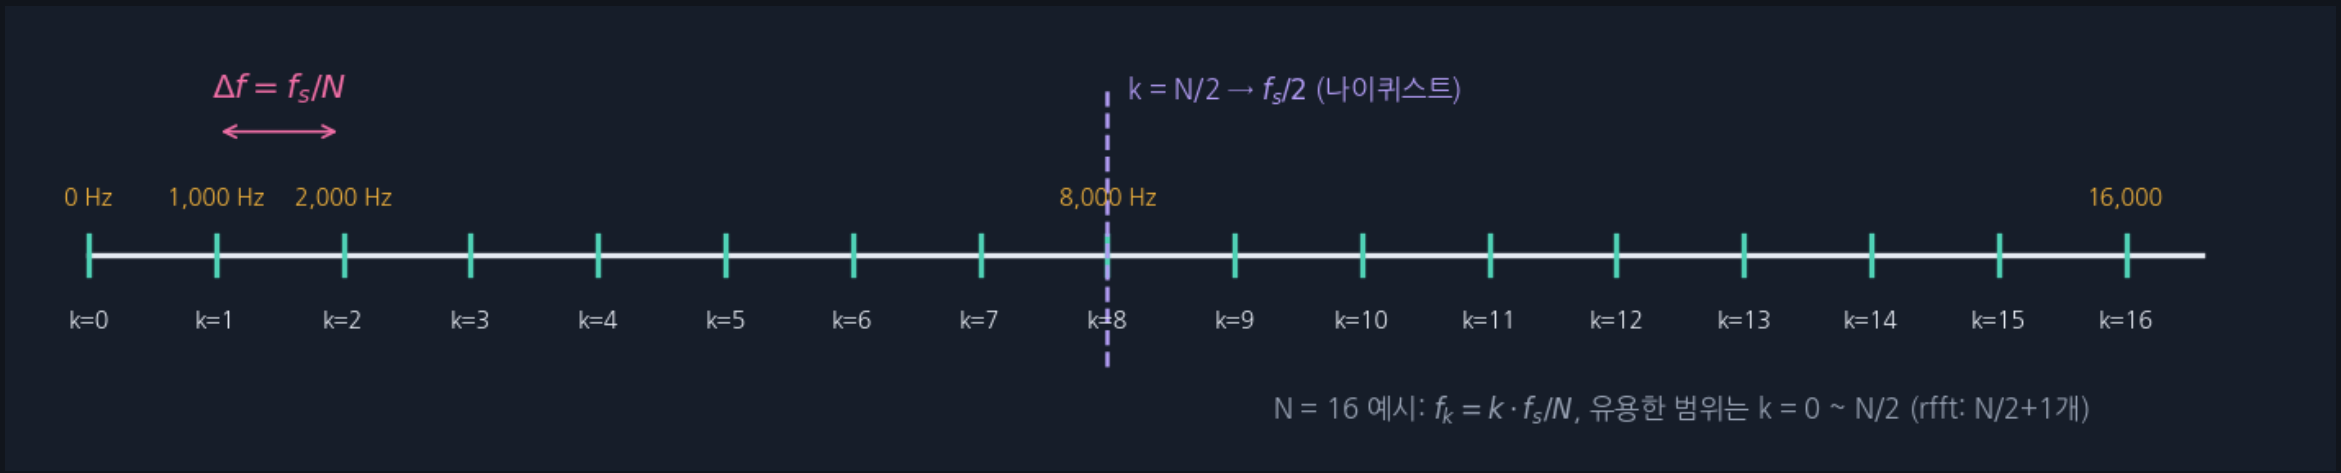
cos 와 sin 을 한 번에 : e^{jθ} = cos θ + j sin θ



단계	식
급수	e^x = 1 + x + x²/2! + x³/3! + …
x = jθ, j² = −1	e^{jθ} = (1 − θ²/2! + …) + j(θ − θ³/3! + …) = cos θ + j sin θ
DFT 시험 사인파	e^{−j2πfn/fs} = cos(2πfn/fs) − j sin(2πfn/fs)

X[k] = Σ x[n] · e^{−j2πkn/N}

```
X[k] = Σn=0..N−1  x[n] · e^(−j2πkn/N)   =   ck − j·sk
fk = k · fs / N          |X[k]| = √(c² + s²)          A = 2|X[k]| / N
```



🧩 **빈칸 실습 2** `freqs = np.arange(N) * ____ / N;   mag = np.____(X)` 정답 : SR, abs

결과는 같고 , 계산은 약 100 배 빠르다

1,048,576 → 10,240 = ≈ 100 배

DFT: N^2 (N = 1024) | FFT: $N \cdot \log_2 N$ | 곱셈 횟수 차이

```
결과가 같은가 : True
직접 DFT 45.7 ms | FFT 0.092 ms | 약 499 배
```

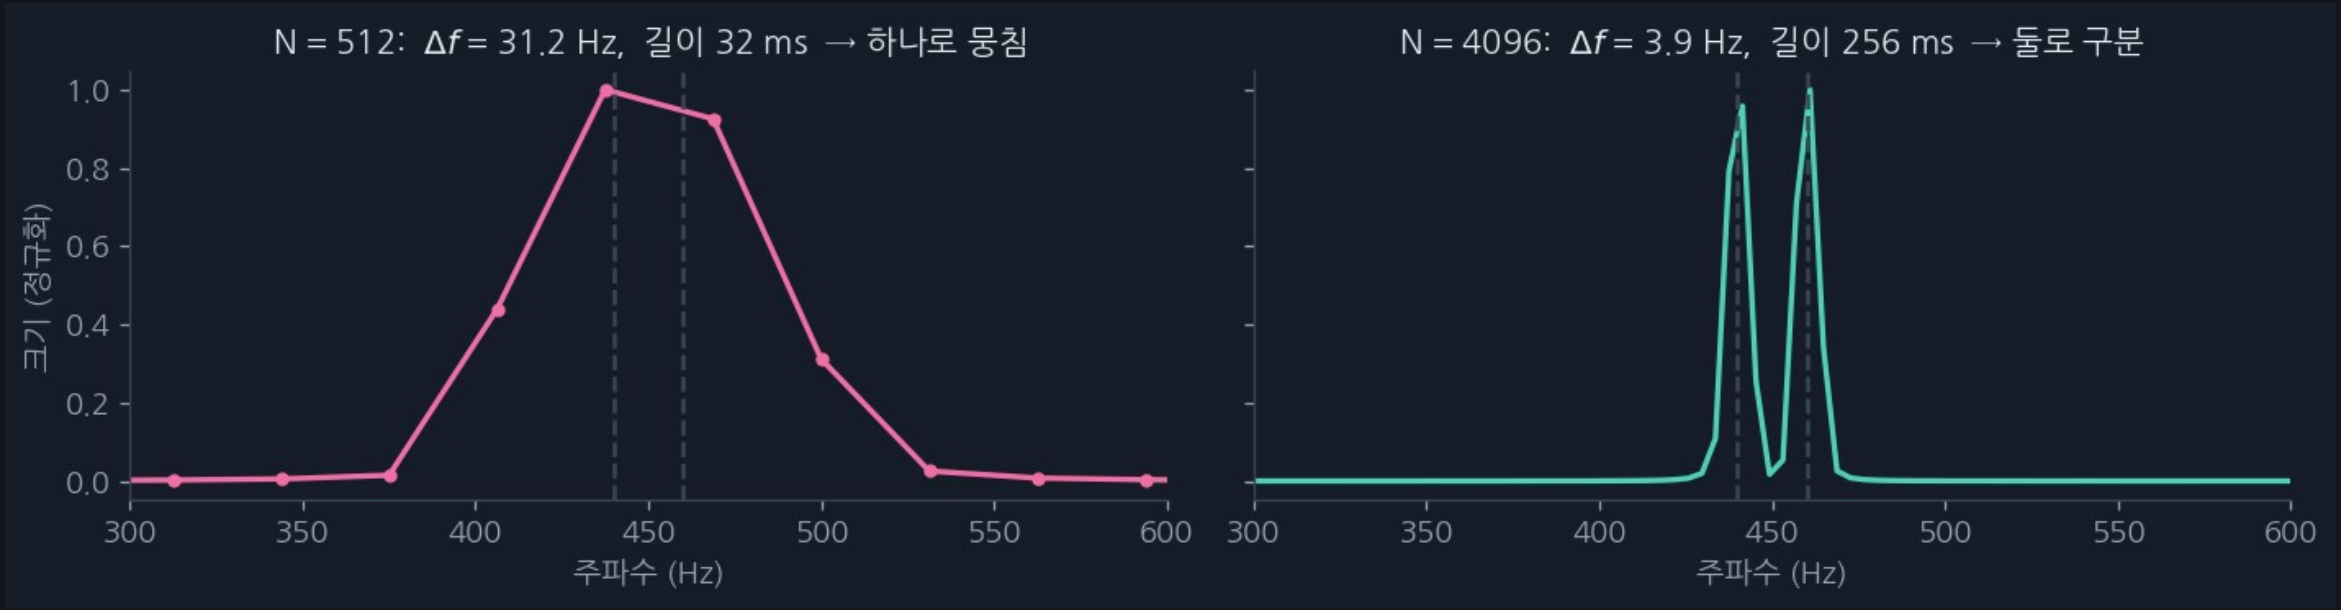
실전에서는 항상 np.fft

N = 16,000(1 초) 이면 직접 DFT 행렬만 약 4 GB

실행 예시 . 시간은 환경에 따라 다르다 .

🧩 **빈칸 실습 1** `chord = tone(262) + tone(330) + tone(____)  # 솔` 정답 : 392

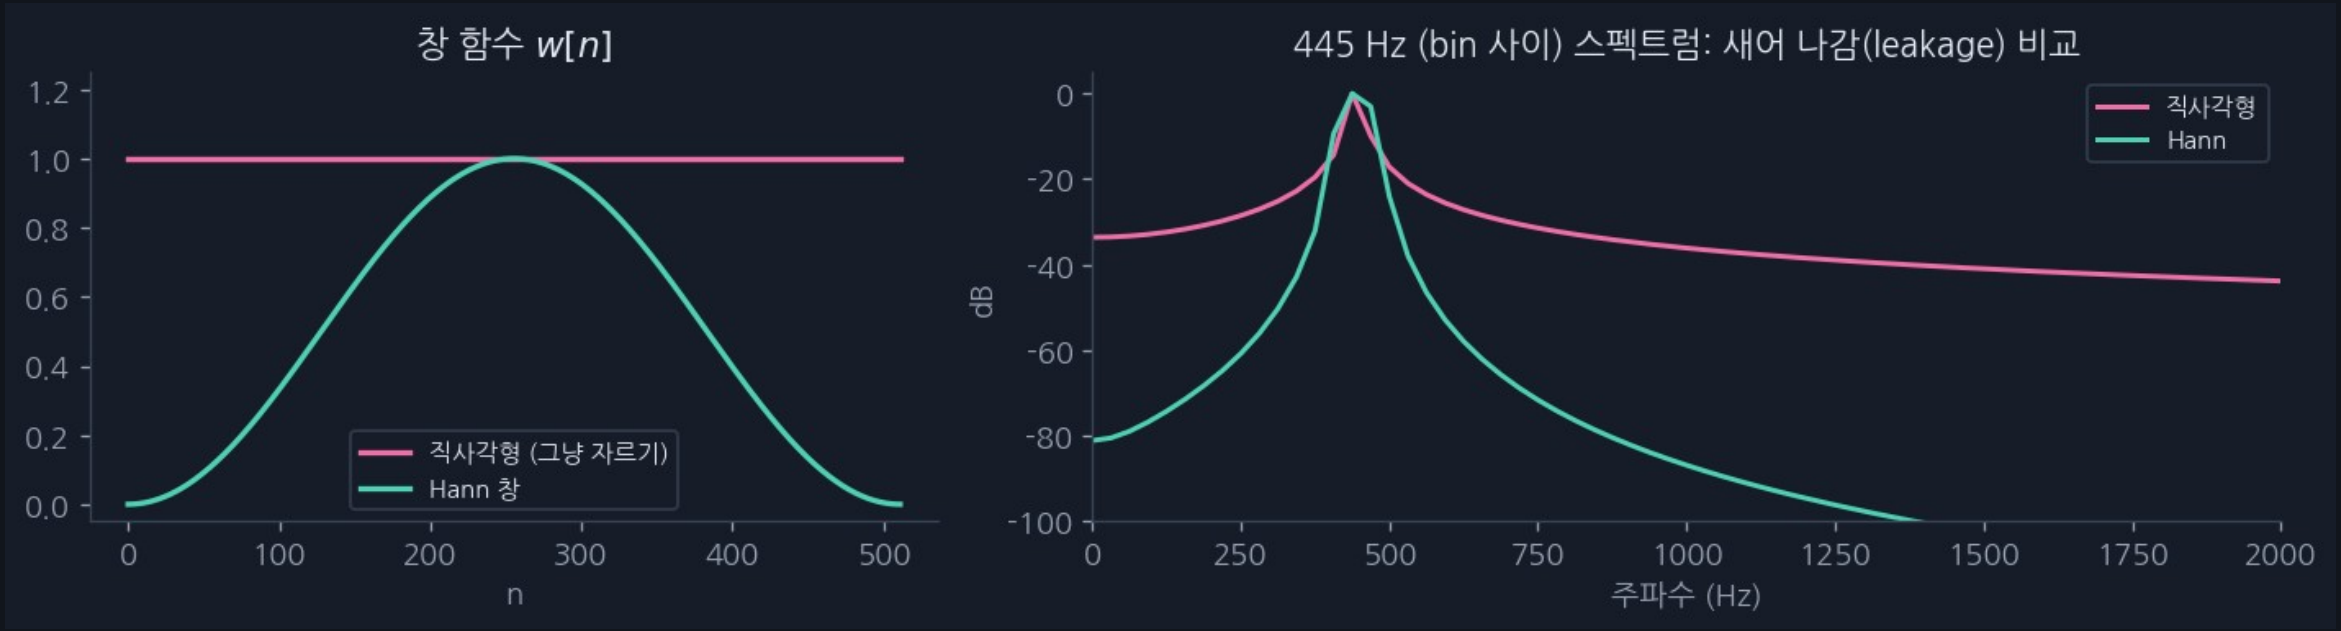
Δf = f_s / N : 길게 볼수록 촘촘하다



N	길이	Δf
400	25 ms	40 Hz
4096	256 ms	3.9 Hz
16000	1 s	1 Hz

▶ **애니메이션** D3-4 주파수 해상도

그냥 자르면 새어 나간다 : Hann 창

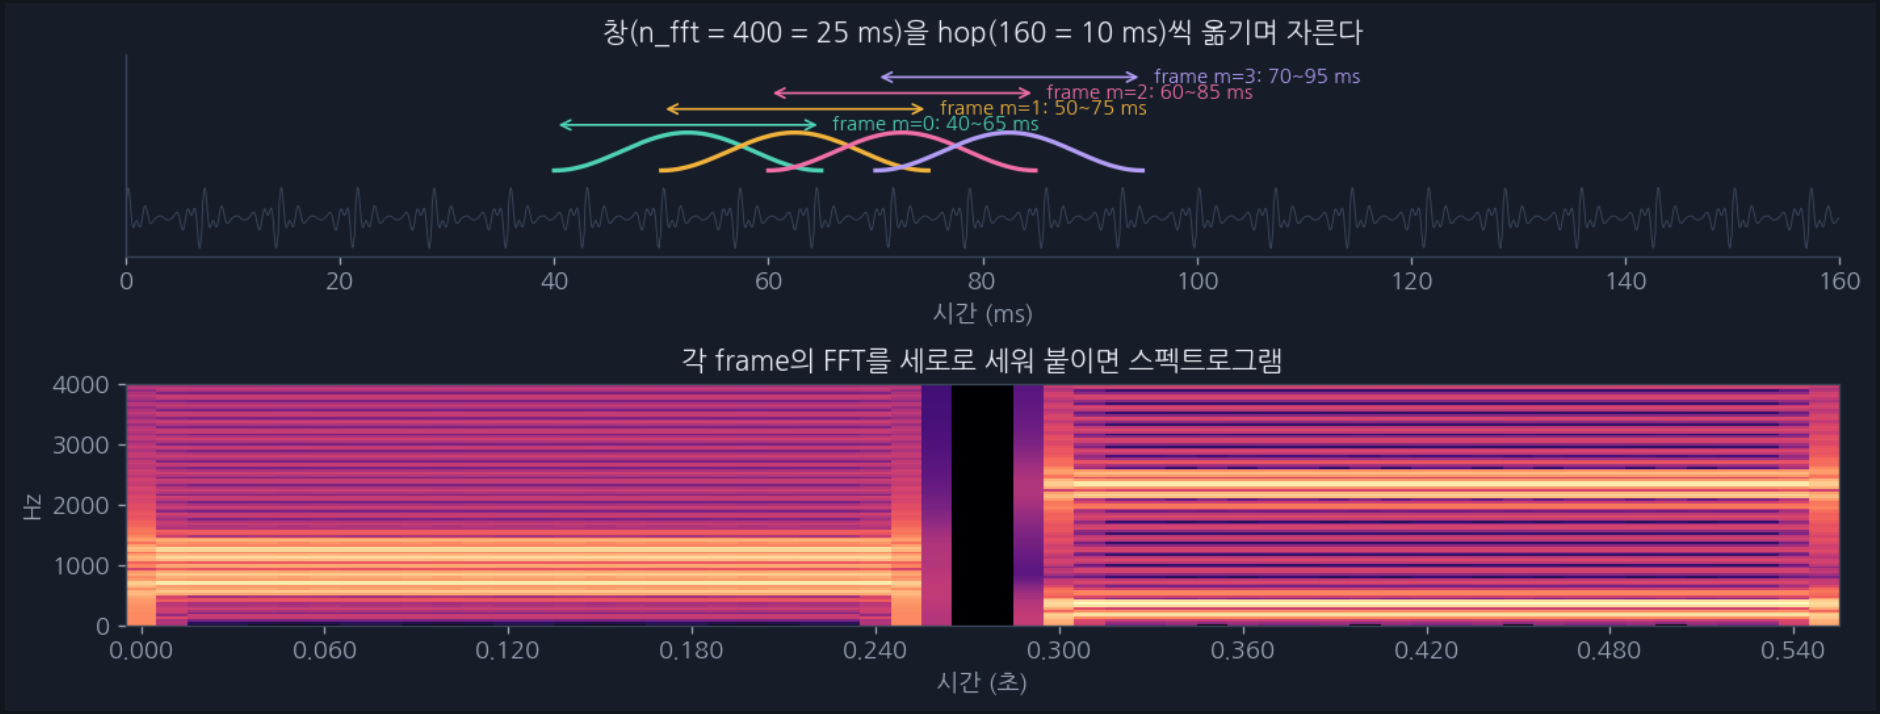



```
w[n] = 0.5 − 0.5·cos(2πn / (N−1))
```

🧩 **빈칸 실습 3** `w = np.____(N)` 정답 : hanning

▶ **애니메이션** D3-5 창 함수와 leakage

잘라서 FFT 하고, 세워 붙이면 스펙트로그램



$$X[m,k] = \Sigma\ x[n + mH] \cdot w[n] \cdot e^{(-j2\pi kn/N)}$$

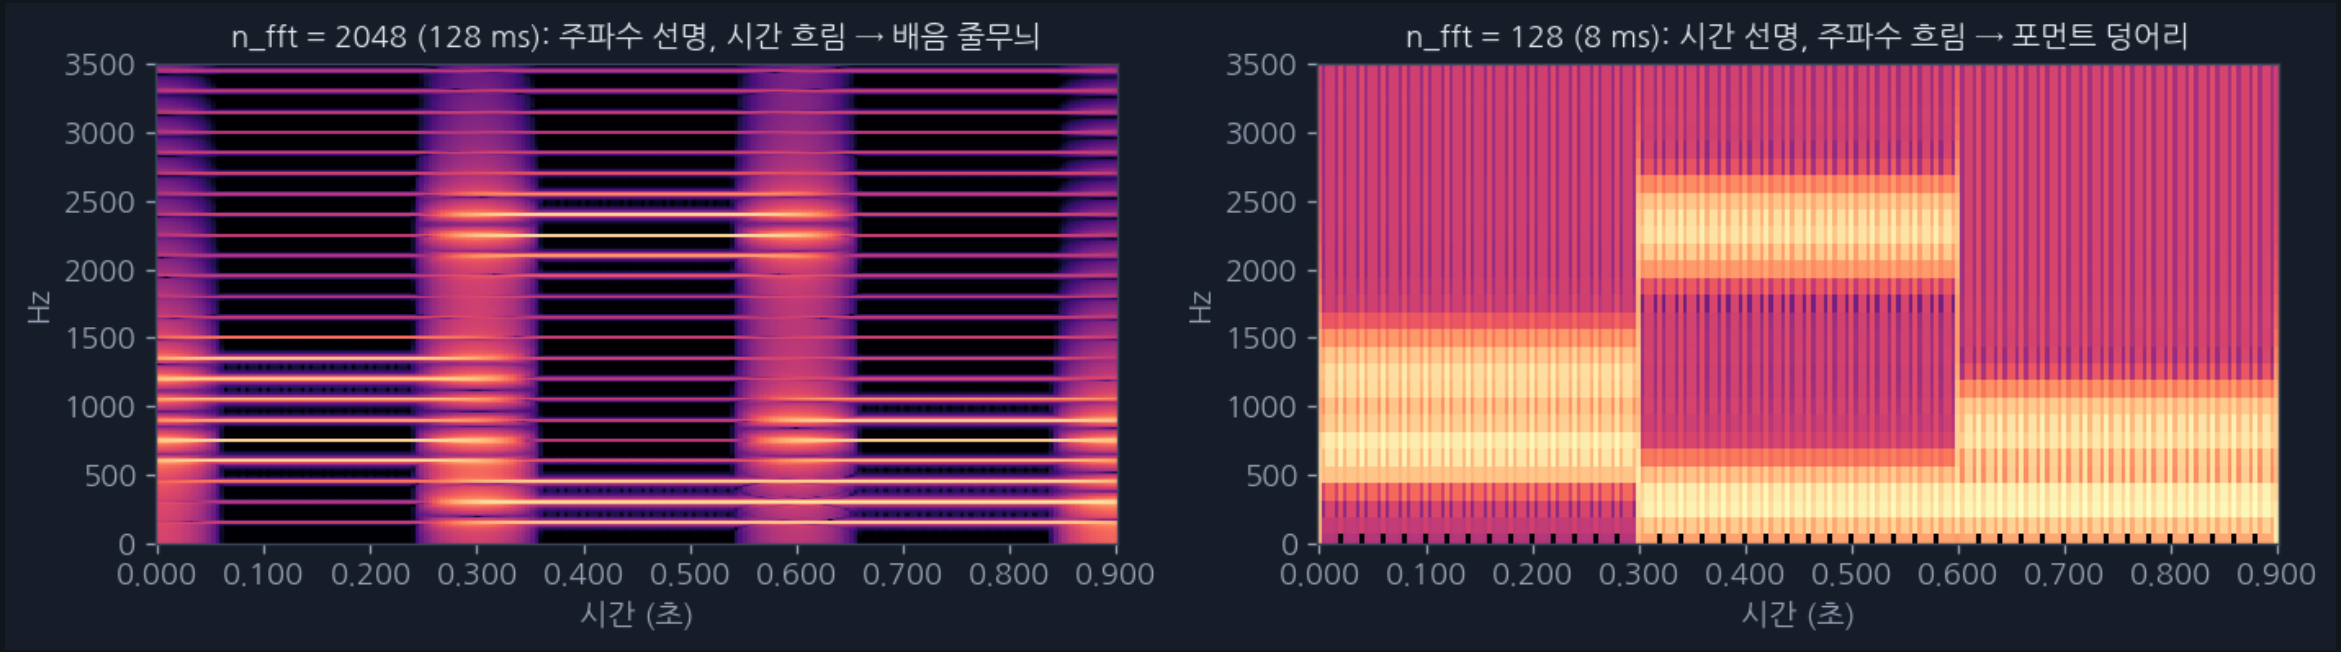
▶ **애니메이션** D3-6 STFT 프레이밍

(1 + N/2, 1 + ⌊L/H⌋)

상황	공식	예 (N=400, H=160)
center=False	$M = 1 + \lfloor (L - N)/H \rfloor$	L = 16,000 → 98
center=True (기본)	$M = 1 + \lfloor L/H \rfloor$	L = 16,000 → 101
30 초 (Whisper)	`1 + 480000 // 160`	3001 → 3000 사용
세로 (bin 수)	$1 + N/2$	201 (간격 40 Hz)
겹침	$(N - H)/N$	60%

🧩 **빈칸 실습 4** `hop = int(____ * SR)  # 10 ms` 정답 : 0.010 → 160

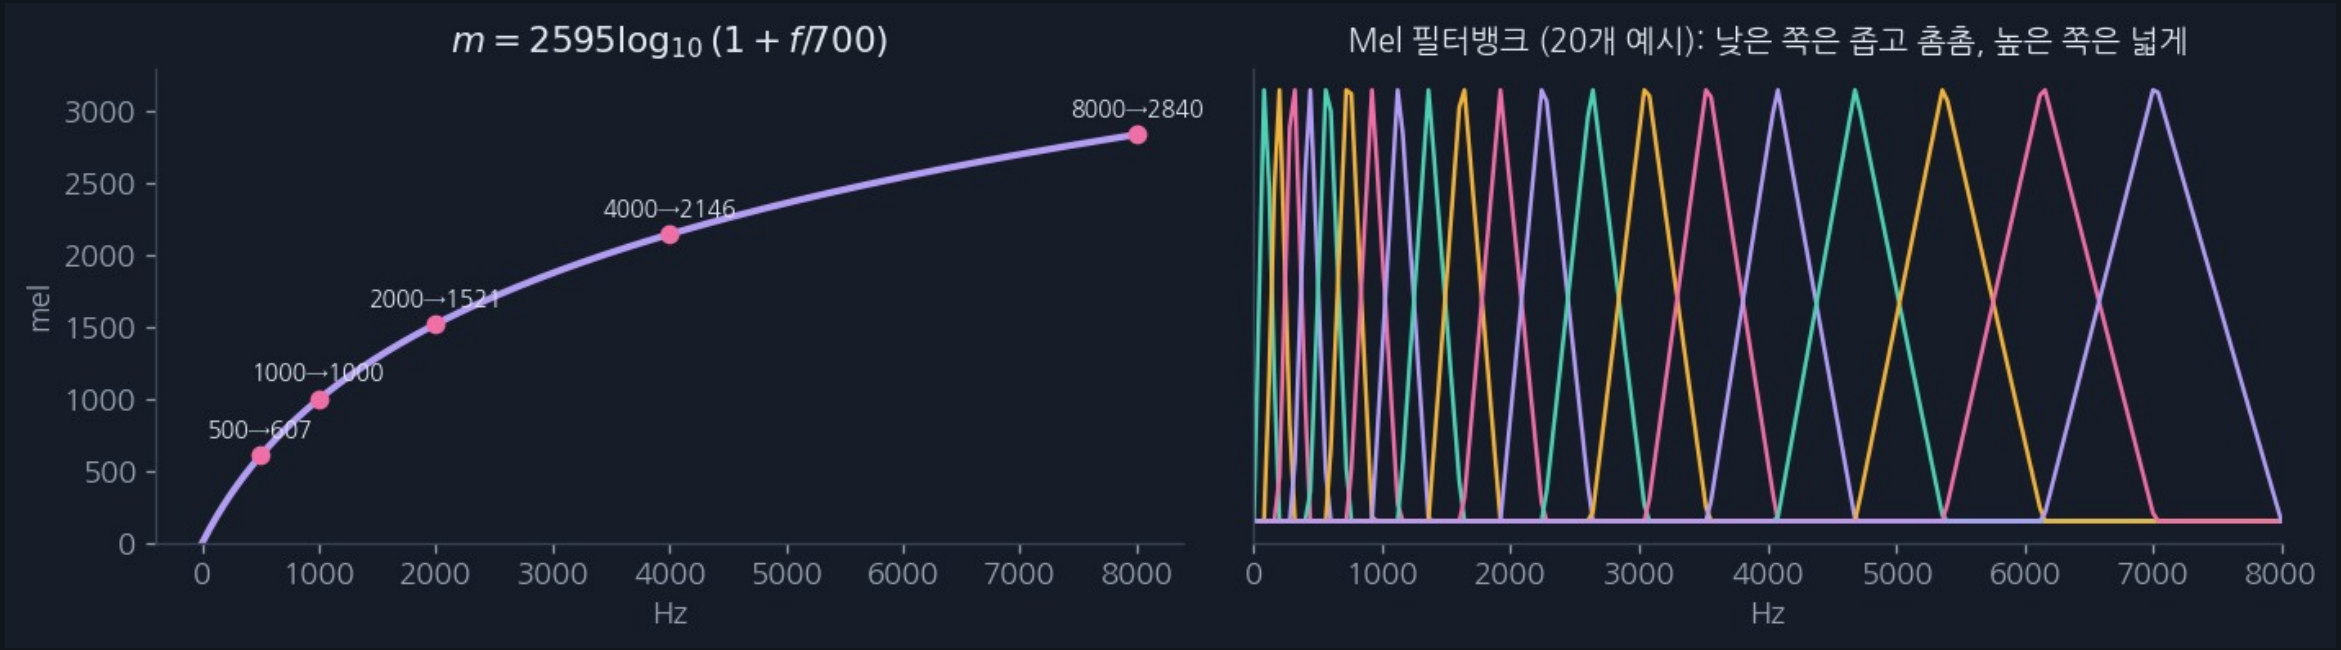
시간과 주파수를 동시에 선명하게 볼 수 없다



$$(N / f_s) \times (f_s / N) = 1$$

▶ **애니메이션** D3-7 시간-주파수 트레이드오프 (실시간)

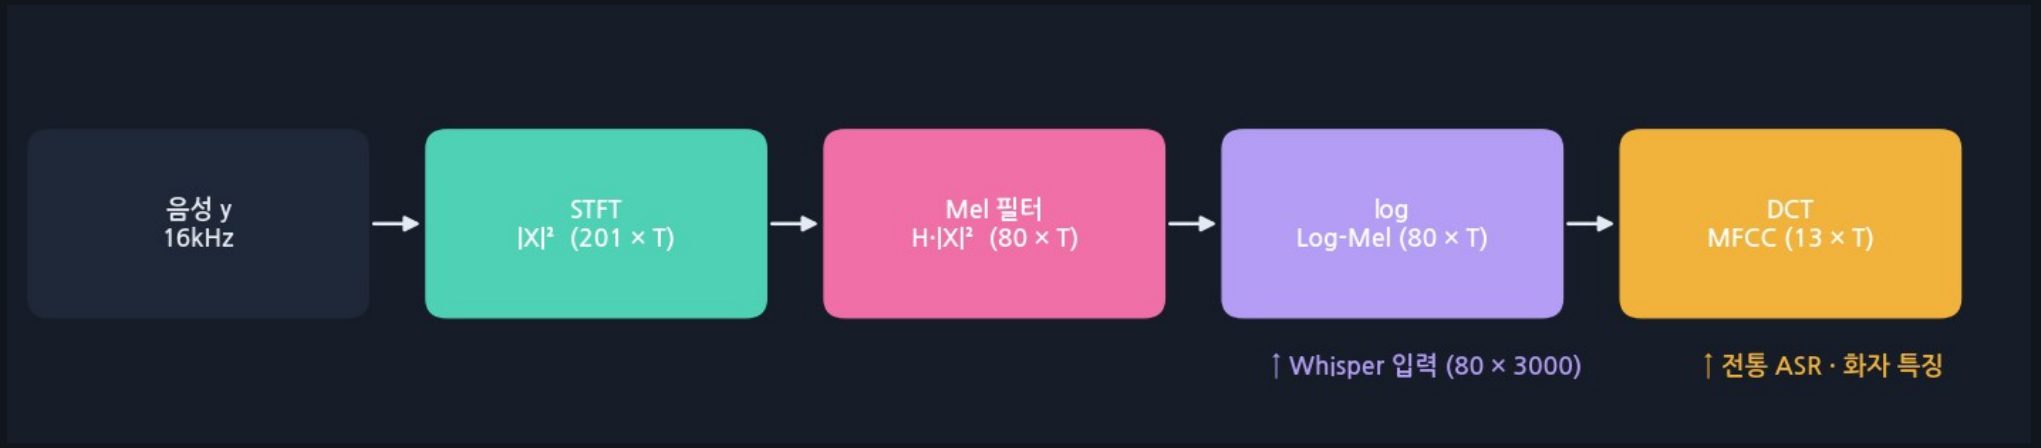
귀에 맞춘 주파수 축과 삼각형 필터




```
m = 2595·log₁₀(1 + f/700)   ⇔   f = 700(10^(m/2595) − 1)
```

▶ **애니메이션** D3-8 Mel 필터뱅크

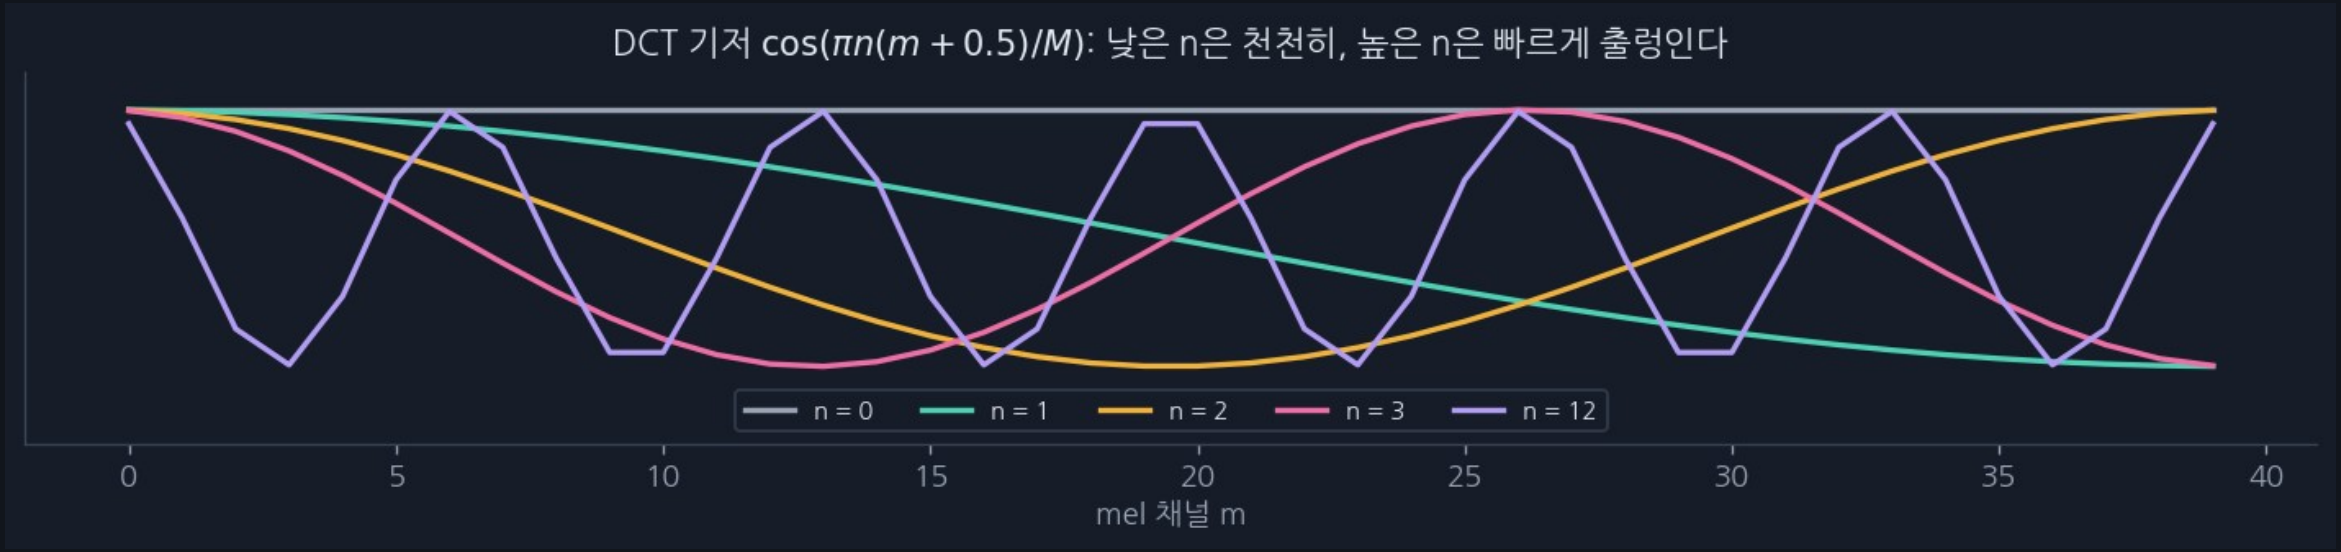
Whisper 입력 80 × 3000 의 정체



단계	모양	수식
STFT 파워	(201, T)	$\|X[k, t]\|^2$
필터뱅크	(80, 201)	$H_m(k)$ 삼각형
Mel	(80, T)	$H \cdot \|X\|^2$
Log-Mel	(80, T) 30초 → (80, 3000)	$10 \cdot \log_{10}(\text{Mel})$

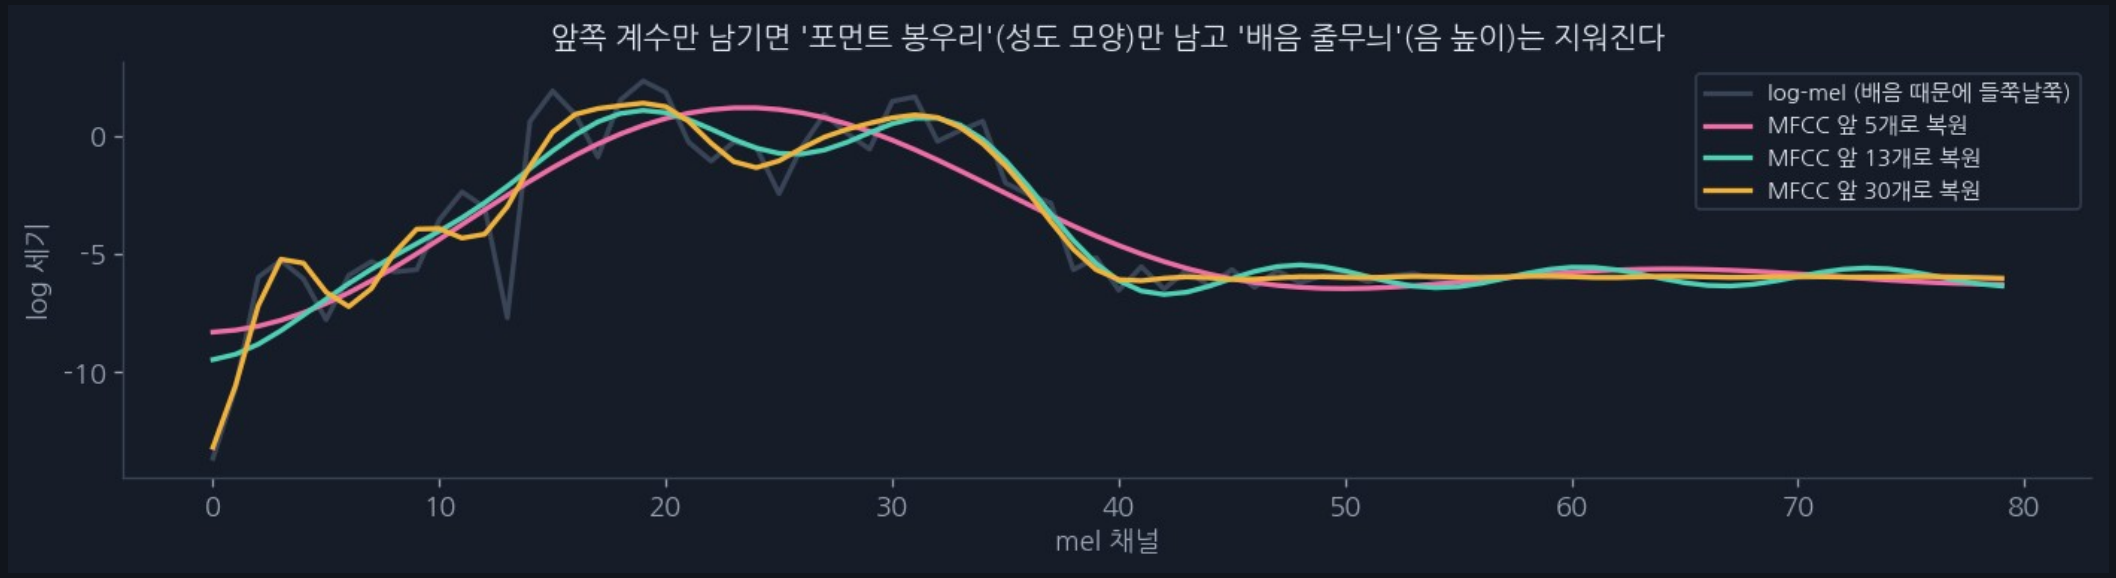
🧩 **빈칸 실습 5** `librosa.feature.melspectrogram(..., n_mels=____)` 정답 : 80

Log-Mel 을 DCT 하면 앞쪽에 봉우리 모양이 모인다



$$c_n = \sum_m \log(\text{Mel}_m) \cdot \cos[\pi \cdot n \cdot (m + 0.5) / M], \quad n = 0 \ldots 12 \quad (c_0 = \text{전체 크기})$$

음 높이가 달라도 같은 모음이면 MFCC 가 비슷하다



" 아 "120 vs " 아 "240

MFCC 거리 약 91 (같은 모음)

" 아 "120 vs " 이 "120

MFCC 거리 약 169 (다른 모음)

▶ **애니메이션** D3-9 MFCC

🧩 **빈칸 실습 6** `librosa.feature.mfcc(S=lm, n_mfcc=____)` 정답 : 13

extract_features(): 어떤 파일이든 Log-Mel 과 MFCC 로

```
def extract_features(src):
    path = make_model_ready(src, "feat_in.wav")
    y, sr = librosa.load(path, sr=16000)
    mel = librosa.feature.melspectrogram(y=y, sr=sr,
          n_fft=____, hop_length=____, n_mels=80)
    logmel = librosa.power_to_db(mel, ref=np.max)
    mfcc = librosa.feature.mfcc(S=logmel, n_mfcc=13)
    return {"logmel": logmel, "mfcc": mfcc}
```

🧩 빈칸 실습 7

n_fft = 400 (25 ms)
hop_length = 160 (10 ms)

결과 : Log-Mel (80, T), MFCC (13, T), 1 초에 약 100 frame

D6 부터 Whisper 가 이 Log-Mel 을 입력으로 받는다 .

오늘의 원리를 여덟 줄로

원리	수식	확인
푸리에 급수	$x(t) = \Sigma\ A_k \sin(2\pi k\ f_0\ t + \varphi_k)$	배음 간격 = f_0
DFT	$X[k] = \Sigma\ x[n]\ e^{(-j2\pi kn/N)}$	np.allclose(dft, fft)
bin · 진폭	$f_k = k\ f_s\ /\ N,\ \ A = 2\lvert X[k]\rvert/N$	500 Hz → 0.5000
해상도	$\Delta f = f_s\ /\ N$	400 → 40 Hz
Hann 창	$w[n] = 0.5 - 0.5\ \cos(2\pi n/(N-1))$	np.hanning 과 일치
STFT	$M = 1 + \lfloor L/H \rfloor,\ \ 모양\ (1 + N/2,\ M)$	(201, 593)
Mel	$m = 2595\ \log_{10}(1 + f/700),\ \ H\cdot\lvert X\rvert^2$	1000 Hz → 1000 mel
MFCC	$c_n = \Sigma\ \log\ Mel_m\ \cos[\pi n(m+0.5)/M]$	dct 직접 = librosa

오늘 헷갈리기 쉬운 것

헷갈리는 점	설명
직접 DFT 가 메모리 오류	N × N 복소수 행렬 . N = 16,000 이면 약 4 GB → 실습은 N = 1024
frame 수가 3001	librosa center=True 는 1 + L//H. Whisper 는 마지막을 버려 3000
power_to_db vs amplitude_to_db	파워는 $10 \cdot \log_{10}$, 진폭은 $20 \cdot \log_{10}$. 결과 dB 는 같다
librosa mel 값이 HTK 공식과 다름	librosa 기본은 Slaney 방식 . HTK 와 비교할 때는 htk=True
Whisper mel 수	기본 80. large-v3 계열은 128 mel

frame 수와 bin 수는 항상 공식으로 먼저 예측하고 shape 로 확인한다 .

오디오 전처리 : 리샘플링 · 정규화 · 노이즈 제거 · VAD

- [ ] 도 - 미 - 솔 화음을 FFT 로 분해했다
- [ ] 직접 만든 dft() 가 np.fft 와 같음을 확인했다
- [ ] Δf = f_s/N 과 Hann 창의 효과를 실험했다
- [ ] my_stft() 로 스펙트로그램을 만들고 frame 수를 예측했다
- [ ] Whisper 입력 80 × 3000 Log-Mel 을 만들었다
- [ ] MFCC 가 음 높이보다 모음을 담는 것을 확인했다

다음 : Day 4

오늘 만든 스펙트로그램으로
잡음은 어디에 있고 , 말소리는 언제 시작할까 ?

리샘플링 · 정규화 · 노이즈 제거 · Silero VAD

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D3_ 실습 .ipynb	빈칸 7
실습 노트북	

레포 위치 04-voice-ai/day03