음성 AI 전문가 과정 · Day 6 / 40

Day 06

ASR 원리
CTC · Attention · Transducer
자기지도 학습 (wav2vec 2.0 · HuBERT)

정렬 문제 → CTC blank · 접기 · forward α → Wav2Vec2 + CTC 디코딩 · 타임스탬프 → Attention Enc-Dec(Whisper) → Transducer 격자 → wav2vec 2.0 · HuBERT
2 주차 M2 · 4 시간 · Colab (CPU 도 가능) · 실습 노트북 Part 1 ~ 6

```
프레임별 경로 (- = blank):
--S-PP-EE--CH-----|--R-E-CC-O-G-N-II-T--
I-O-N---|-T-U-RR-N-S--|--S-OU-N-D-|...

>>> ctc_collapse(path)
'SPEECH RECOGNITION TURNS SOUND INTO TEXT'

0.12 ~ 0.58 s  SPEECH
0.62 ~ 1.30 s  RECOGNITION
```

출력 예시 (값은 실행마다 다름)

0.0 · 오늘 답할 질문

소리 200 프레임을 글자 11 개로 , 정렬도 모른 채 어떻게 배울까

1 음성 인식이 이미지 분류 (D5) 보다 어려운 이유는 ? 정렬 문제란 ? Part 1

2 CTC 는 blank 와 접기 규칙으로 어떻게 " 모든 정렬 " 을 더할까 ? Part 2

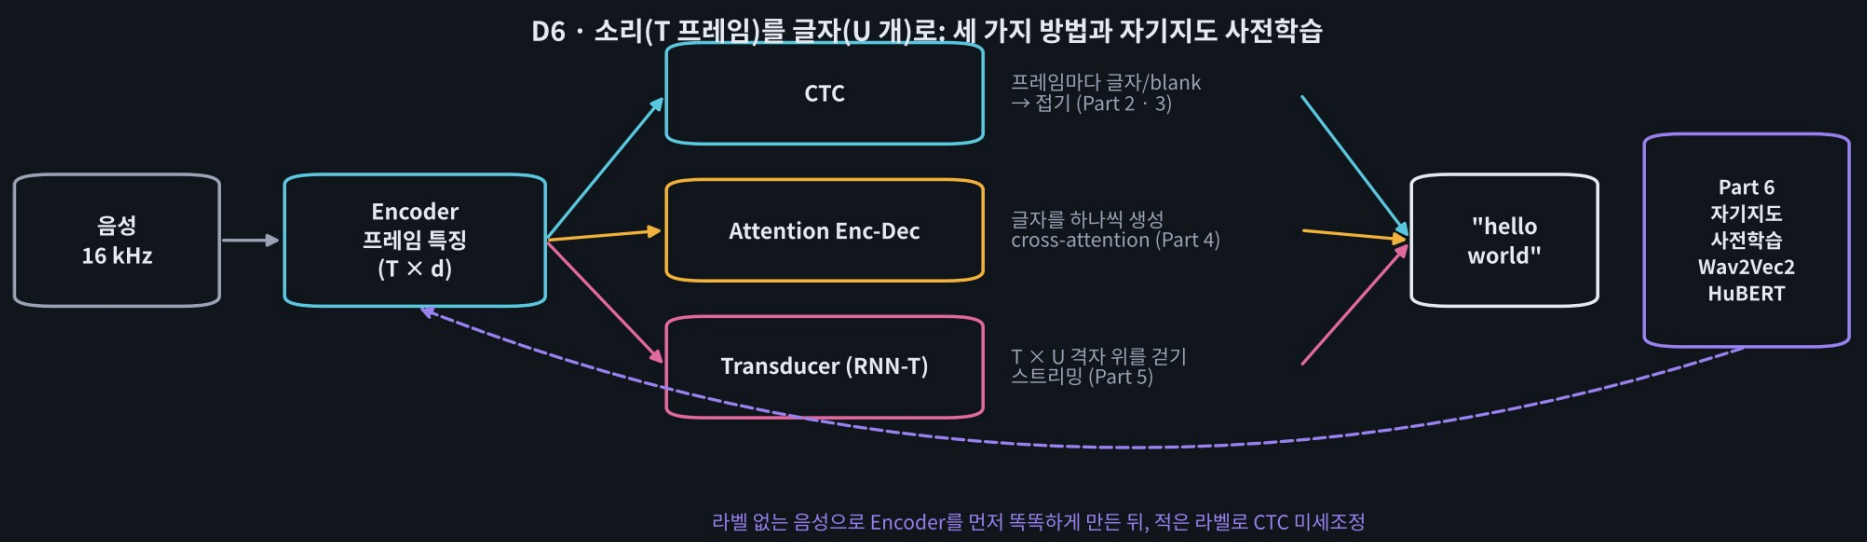
3 Wav2Vec2 는 1 초를 몇 프레임으로 만들고 , 출력을 어떻게 글자로 바꿀까 ? Part 3

4 Whisper 같은 AED 는 왜 한 토큰씩 생성하고 , attention 이 정렬이 될까 ? Part 4

5 스트리밍 자막에는 왜 Transducer 를 쓸까 ? 세 방식의 차이는 ? Part 5

6 라벨 없는 음성으로 무엇을 어떻게 미리 배울까 ? (wav2vec 2.0 · HuBERT) Part 6

세 가지 방법 + 자기지도 사전학습



교시	내용	실습
1 교시	정렬 문제 , CTC blank · 접기 · 경로 수 · forward α	Part 0 ~ 2 · 빈칸 1 ~ 2 · 워크시트 1 교시
2 교시	Wav2Vec2 + CTC: 프레임 수 공식 , greedy 디코딩 , 스파이크 , 타임스탬프	Part 3 · 빈칸 3 ~ 5 · 워크시트 2 교시
3 교시	Attention Enc-Dec(Whisper-tiny), Transducer 격자 , 세 방식 비교	Part 4 ~ 5 · 빈칸 6 ~ 8 · 워크시트 3 교시
4 교시	wav2vec 2.0 마스킹 · 양자화 · InfoNCE, HuBERT 가짜 라벨	Part 6 ~ 7 · 빈칸 9 · 워크시트 4 교시 · 노션

▶ 애니메이션 D6-1 오늘의 흐름 (Part 1~6)

T ≫ U, 그리고 어느 프레임이 어느 글자인지 모른다



글자 U = 11개. T(200) ≫ U(11), 그리고 어느 프레임이 어느 글자인지(정렬) 라벨에는 없다

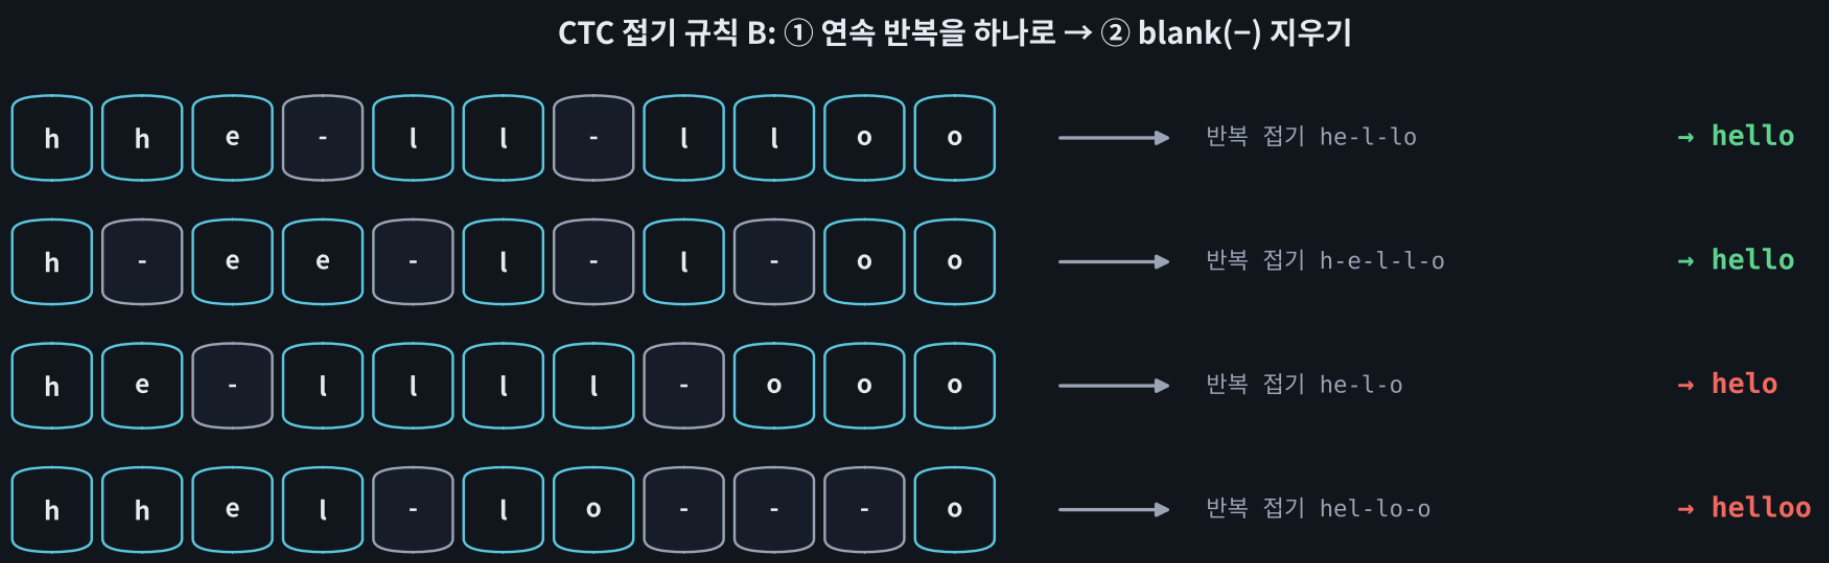
방법	정렬을 다루는 방식
CTC	경로를 모두 더함
AED	attention 으로 찾아봄
Transducer	T×U 격자 경로 합

X = (x₁, …, x_T) 10 ms(또는 20 ms)마다 한 프레임 Y = (y₁, …, y_U) 글자
Ŷ = argmax_Y P(Y | X) 2초: T = 200 (10 ms) vs U ≈ 11

학습 데이터 = "이 녹음 = hello world" 뿐. 프레임 ↔ 글자 대응(정렬)은 없다

▶ 애니메이션 D6-2 정렬 문제 (속도 · 경로 수)

𝓑: ① 연속 반복을 하나로 → ② blank 지우기



blank는 같은 글자를 '나누는' 칸: 3번째 줄은 l 사이에 blank가 없어 l 하나로 접히고, 4번째 줄은 o 사이 blank 때문에 o가 두 개가 된다

🧩 빈칸 실습 1

return [k for k in merged if k != ____] 정답 : blank

▶ 애니메이션 D6-3 CTC 접기 (경로 직접 바꾸기)

blank = 같은 글자를 " 나누는 " 칸

정답으로 접히는 경로를 " 모두 " 더한다

$$P(\pi \mid X) = \prod_t p_t(\pi_t) \quad \leftarrow \text{조건부 독립 가정}$$

$$\mathbf{P(Y \mid X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} \prod_t p_t(\pi_t)}$$

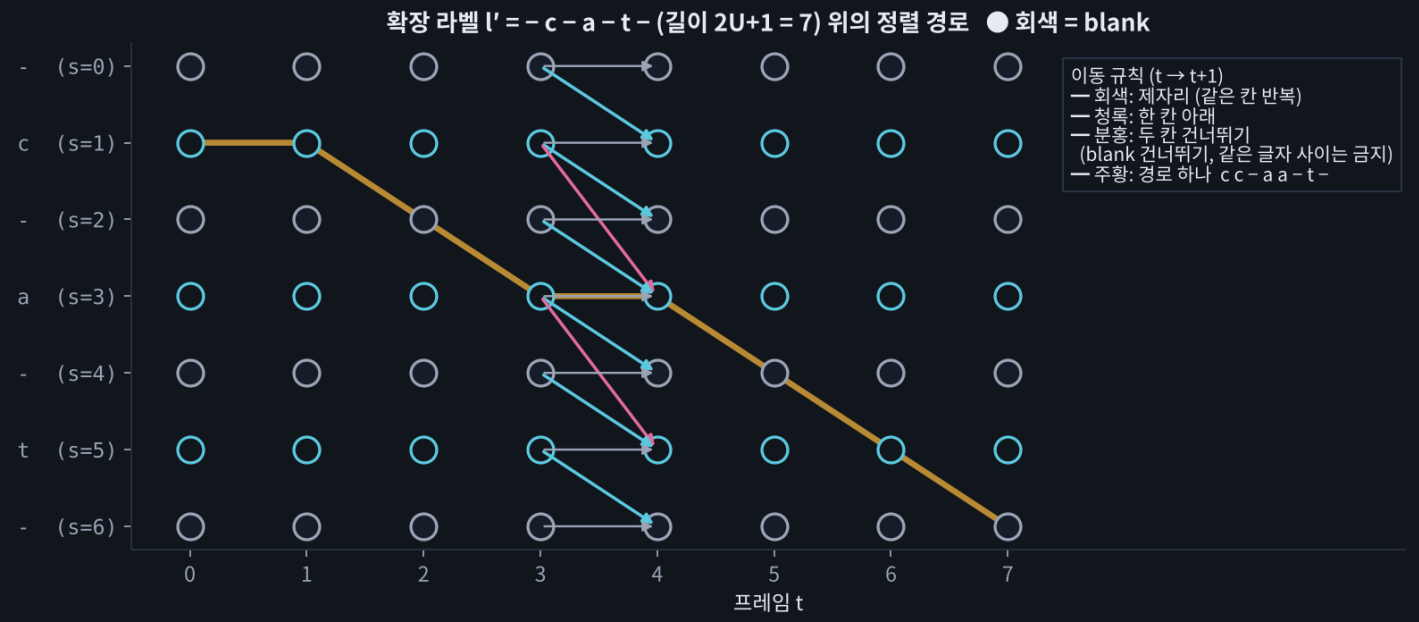
$$L_{CTC} = -\log P(Y \mid X)$$

T, U	경로 수 C(T+U, 2U)
5, 3 (cat)	28
6, 3	84
50, 10	$\approx 10^{16}$
150, 40	$\approx 10^{55}$

```
paths = all_alignments("cat", 5, ["-", "c", "a", "t"])     # 4⁵ = 1024 개를 전부 만들어 보고 접기
len(paths) → 28 = C(8, 6)     예 : '--cat', '-c-at', 'cc-at', 'caatt', …
실제 3 초 · 40 글자 → 약 10⁵⁵ 개 → 하나씩 더하기는 불가능 → 동적 계획법 (α)
```

조건부 독립 = 앞에서 무엇을 썼는지 모른 채 고른다 → 빠르지만 문맥 (동음이의어) 에 약하다

확장 라벨 위에서 겹치는 계산을 재사용 : O(T·S)



$$l' = - y_1 - y_2 \ \dots - (S = 2U+1)$$

$$\alpha_t(s) = (\alpha_{t-1}(s) + \alpha_{t-1}(s-1) + \alpha_{t-1}(s-2)^*) \cdot p_t(l'_s)$$

$$^* \ l'_s \neq \text{blank} \ \text{그리고} \ l'_s \neq l'_{s-2}$$

$$\mathbf{P = \alpha_T(S-1) + \alpha_T(S-2)}$$

🧩 빈칸 실습 2

if s >= 2 and lp[s] != blank and lp[s] != ____: 정답 : lp[s - 2]

▶ 애니메이션 D6-4 CTC 격자 · α (경로 수 세기)

수식 검증 1: 전부 더하기 = α = F.ctc_loss

파형을 CNN 7 층에 바로 : 보폭 320 (20 ms), 수용 영역 400 (25 ms)



Conv 7층: 보폭 5·2·2·2·2·2·2 = 320 → 20 ms
수용 영역 400 샘플 = 25 ms

$$T = \lfloor (L - 400) / 320 \rfloor + 1 \quad (1초 \rightarrow 49\ 프레임)$$

$$L_i = \lfloor (L_{i-1} - K_i) / S_i \rfloor + 1$$

K = (10,3,3,3,3,2,2) S = (5,2,2,2,2,2,2)

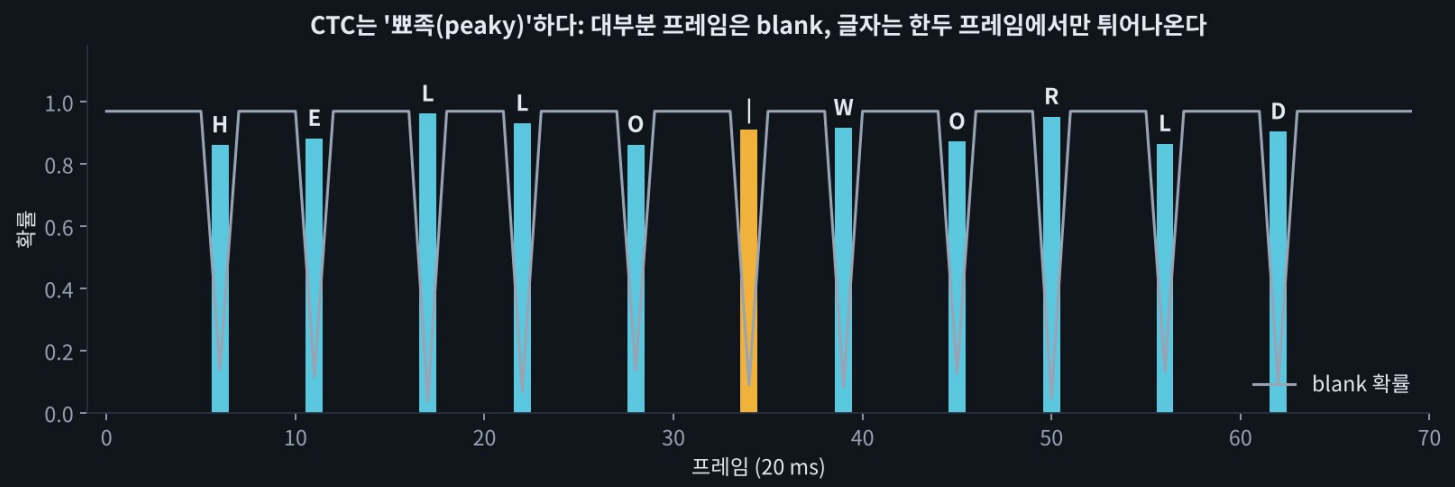
$T = \lfloor (L - 400) / 320 \rfloor + 1$ 1초 → 49 프레임

🧩 **빈칸 실습 3**

T_formula = (L - R) // ____ + 1 정답 : S_TOT

▶ 애니메이션 D6-5 Wav2Vec2 프레임 · 디코딩

프레임마다 argmax → 접기, 대부분은 blank




```
ids = logits.argmax(dim=-1)[0]
path = [id2tok[i] for i in ids]
text = "".join(
  ctc_collapse(path, "<pad>"))
  .replace("|", " ")

processor.batch_decode(ids)
# 같은 일 : 합치기 → <pad> 제거 → | → 공백
```

토큰	역할
<pad> (0 번)	CTC blank
|	띄어쓰기를 글자 하나로
A–Z, '	대문자 글자 (960h 모델)

🧩 빈칸 실습 4

ids = logits.argmax(dim=____)[0] 정답 : -1

$\pi^*_t = \text{argmax}_k\, p_t(k),\ \hat{Y} = \mathcal{B}(\pi^*)$

스파이크 프레임 × 0.02 s = 글자의 대략적인 시각

```
FRAME_SEC = S_TOT / SR          # 320 / 16000 = 0.02

for t, p in enumerate(path):
    if p != "<pad>" and (t == 0 or p != path[t-1]):
        char_times.append((p, t * FRAME_SEC))

# '|' 가 나올 때마다 단어 하나 완성
```

단어	시작 ~ 끝 (예시)
SPEECH	0.12 ~ 0.58 s
RECOGNITION	0.62 ~ 1.30 s
TURNS	1.36 ~ 1.62 s
SOUND	1.70 ~ 2.02 s

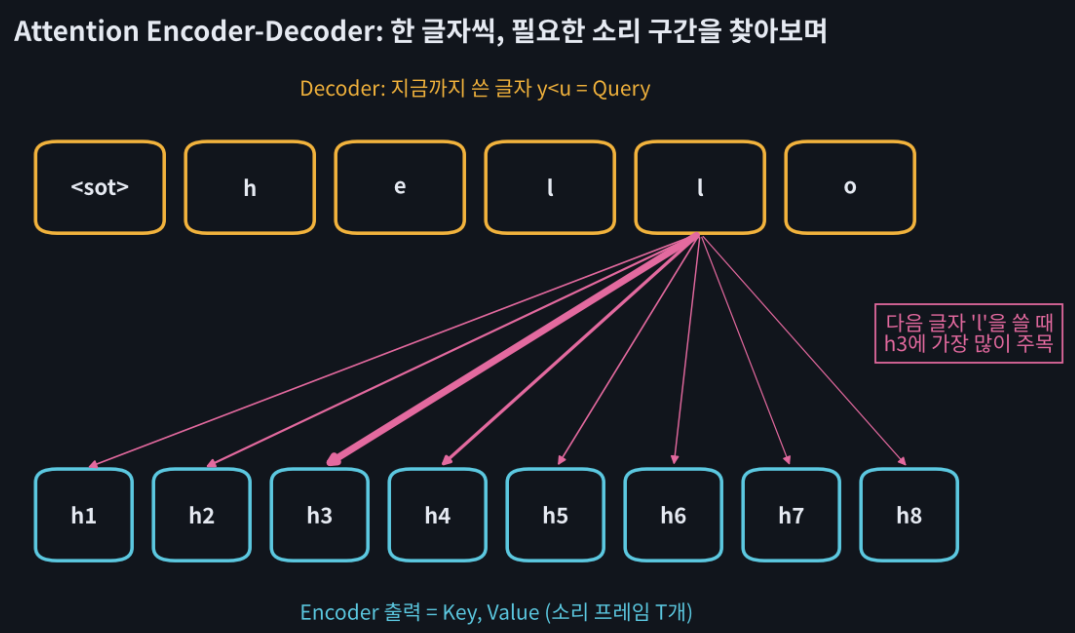
🧩 **빈칸 실습 5**

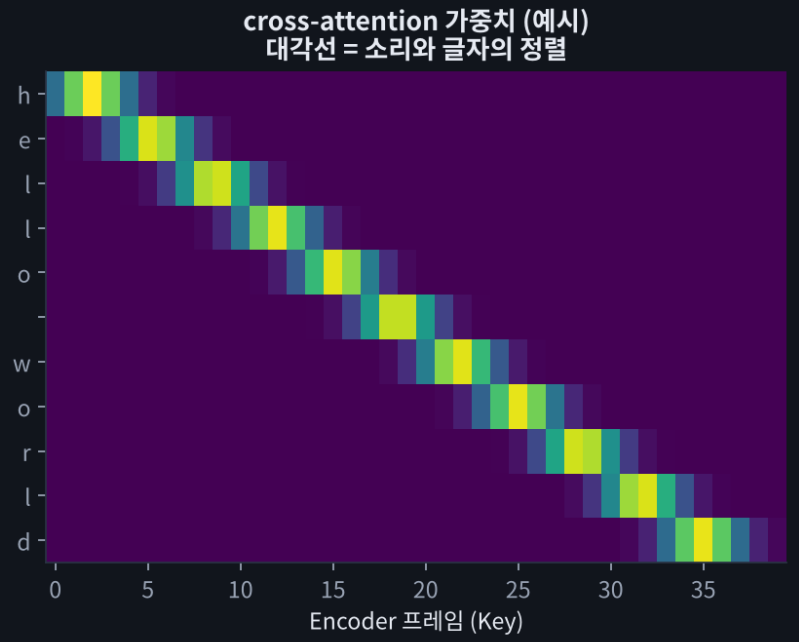
FRAME_SEC = ____ 정답 : S_TOT / SR (0.02)

→ **D9 WhisperX 단어 정렬 (forced alignment) 의 출발점**

10 ms(Log-Mel hop) 와 헷갈리지 않기 : Wav2Vec2 프레임은 20 ms

연쇄 법칙 그대로 : 앞 글자를 보며 한 토큰씩





$$P(Y \mid X) = \prod_u P(y_u \mid y_{<u}, X)$$

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d_k})\, V$$

Q = 디코더 상태 , K = V = 인코더 출력 H

▶ 애니메이션 D6-6 Cross-attention 정렬

√d_k 로 나누지 않으면 softmax 가 한 칸에 몰린다

```
def attention(Q, K, V):
    d = Q.shape[-1]
    scores = Q @ K.transpose(-2, -1) / math.sqrt(d)
    w = scores.softmax(dim=-1)     #  프레임 방향 합 = 1
    return w @ V, w

# == F.scaled_dot_product_attention(Q, K, V)
```

d	q·k 분산	√d 로 나눈 뒤	최대 가중치 (안 나눔 → 나눔)
16	16	1.0	0.61 → 0.14
64	64	1.0	0.81 → 0.14
256	256	1.0	0.91 → 0.14
1024	1024	1.0	0.95 → 0.14

🧩 **빈칸 실습 6**

scores = Q @ K.transpose(-2, -1) / ____ 정답 : math.sqrt(d)

Var(q·k) = d_k → √d_k 로 나누면 1

▶ 애니메이션 D6-6 √d 스케일 슬라이더 (아래쪽)

인코더는 한 번 , 디코더는 토큰마다

```
enc = whisper.model.encoder(feats).last_hidden_state   # (1, 1500, 384)
ids = [<|startoftranscript|>, <|en|>, <|transcribe|>, <|notimestamps|>]
for step in range(100):
    logits = whisper(encoder_outputs=enc, decoder_input_ids=ids).logits
    nxt = logits[0, -1].argmax()        #  마지막 위치 =  다음 토큰
    ids.append(nxt)
    if nxt == EOS: break

#  내 루프  == whisper.generate(feats, language="en", task="transcribe")
```

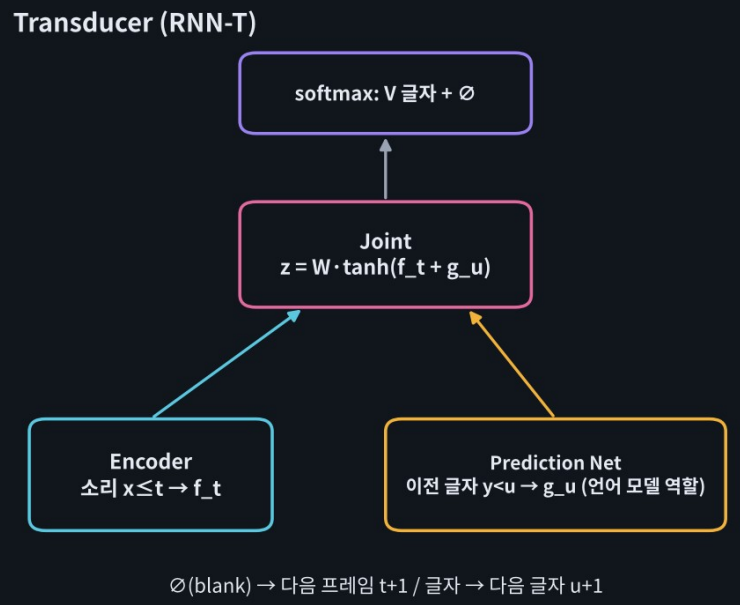
Whisper-tiny	
입력	80-mel, 30 초 패딩 (1, 80, 3000)
Encoder	Conv 2 층 → 1500 × 20 ms
Decoder	BPE 토큰 약 5 만 개
attention	eager 로 가중치 꺼내기

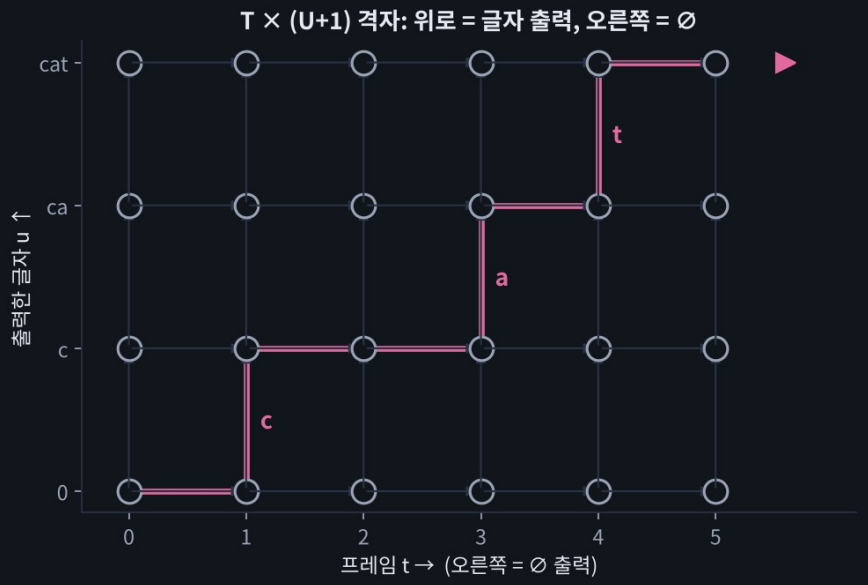
🧩 **빈칸 실습 7**

nxt_scores = logits_w[0, ____].clone() 정답 : -1

약점 : 토큰 수만큼 반복 , 틀린 토큰이 다음 입력 → D7 환각

T × (U+1) 격자 : ∅ 면 오른쪽 , 글자면 위





$$\alpha(t,u) = \alpha(t-1,u)\cdot\varnothing(t-1,u) + \alpha(t,u-1)\cdot y(t,u-1)$$

$$P(Y \mid X) = \alpha(T-1,U)\cdot\varnothing(T-1,U) \qquad \text{경로 수 } C(T+U-1,U)$$

🧩 빈칸 실습 8

logp[t, u - 1, y[____]] 정답 : u - 1

▶ 애니메이션 D6-7 Transducer 격자 걷기

도구 상자 : 빠른 CTC, 똑똑한 AED, 스트리밍 Transducer

	CTC	Attention Enc-Dec	Transducer (RNN-T)
P(Y|X)	Σ_π Π_t p_t(π_t)	Π_u P(y_u | y_<u, X)	Σ 격자 경로 Π P(· | t, u)
앞 글자 참고	안 봄 (조건부 독립)	봄	봄 (prediction net)
정렬	경로 합 · 단조	attention · 부드러움	경로 합 · 단조
출력 길이	U ≤ T	제한 없음	제한 없음
스트리밍	쉬움	어려움 (전체 입력)	쉬움 (설계 목적)
디코딩 속도	가장 빠름	느림 (토큰마다)	중간
흔한 실패	철자 · 동음이의어	반복 · 환각	학습 메모리 T×U×V
대표	Wav2Vec2, HuBERT + CTC	Whisper	Conformer-Transducer

▶ 애니메이션 D6-8 세 방식 비교 (스트리밍 타이밍)

실시간 자막 = CTC · Transducer, 최종 녹취록 = AED 도 후보

가리고 , 진짜 소리 코드를 가짜 100 개 사이에서 고르기



P(가려짐) = 1 − (1 − p)^M = 1 − 0.935^{10} ≈ 0.49

코드북 G = 2 × V = 320 → 320^2 = 102,400 가지 (Gumbel-softmax)

$L_m = -\log \exp(sim(c,q)/\kappa) / \Sigma \exp(sim(c,q')/\kappa), \quad \kappa = 0.1$

🧩 빈칸 실습 9

log_softmax(sims / kappa)[:, ____] 정답 : 0

▶ 애니메이션 D6-9 자기지도 학습 (마스킹 · InfoNCE)

k-means 가짜 라벨을 가린 자리에서 맞히기



모델	사전학습 목표	라벨	쓰임
wav2vec 2.0	가린 자리에서 진짜 양자화 코드 고르기 (대조)	없음	+ CTC 미세조정 , XLS-R(128 개 언어)
HuBERT	가린 자리의 k-means 번호 맞히기 (예측)	없음 (가짜 라벨)	+ CTC 미세조정 , 음성 토큰
Whisper	받아쓰기 자체 (AED)	자막 68 만 h (약한 지도)	바로 받아쓰기 · 번역 (D7)

L = −Σ_{t∈ 가린 자리 } log p(z_t | 가린 X) · 피치를 바꿔도 같은 번호 = " 무슨 소리 " 를 담은 좋은 특징

오늘의 원리를 열두 줄로

원리	수식 · 코드	확인
CTC 접기	$\mathcal{B}$: 반복 합치기 → blank 지우기	빈칸 1 · D6-3
CTC 확률	$P(Y\|X) = \Sigma_{\pi \in \mathcal{B}^{-1}(Y)} \Pi_t p_t(\pi_t)$	Part 2-1
경로 수	$C(T+U, 2U)$ (연속 중복 없을 때)	Part 2-2
forward α	$\alpha_t(s) = (\alpha(s) + \alpha(s-1) + \alpha(s-2)^*) \cdot p_t(l'_s)$	빈칸 2 · 수식 검증 1
Wav2Vec2 프레임	$T = \lfloor (L - 400)/320 \rfloor + 1$	빈칸 3
greedy 디코딩	argmax(dim=−1) → $\mathcal{B}$	빈칸 4
타임스탬프	$t \times 320 / 16000 = t \times 0.02$ s	빈칸 5
AED	$\Pi_u P(y_u \mid y_{<u}, X)$	Part 4-1
attention	$\mathrm{softmax}(QK^T/\sqrt{d_k})\, V$	빈칸 6 · 수식 검증 2
Transducer	$\alpha(t,u) = \alpha(t-1,u)\varnothing + \alpha(t,u-1)y$	빈칸 8 · 수식 검증 3
마스킹	$1 - (1 - p)^M \approx 0.49$	수식 검증 4
InfoNCE · HuBERT	$-\log \mathrm{softmax}(\mathrm{sim}/\kappa)[0]$ · $-\Sigma_{t \in \mathcal{M}} \log p(z_t \mid$ 가린 $X)$	빈칸 9 · Part 6-4

오늘 헷갈리기 쉬운 것

헷갈리는 점	설명
blank vs 띄어쓰기	blank(<pad>) 는 " 새 글자 없음 ", 띄어쓰기는 | 라는 진짜 글자
접기 순서	반복 합치기 먼저 , blank 지우기 나중 . 반대로 하면 hello → helo
10 ms vs 20 ms	Log-Mel hop = 10 ms (D3), Wav2Vec2 프레임 = 20 ms (보폭 320)
greedy = 최선 ?	가장 좋은 경로 ≠ 가장 좋은 글자열 . 실전 차이는 작고 , 빔 서치는 D7 · D8
F.ctc_loss 모양	log_probs 는 (T, N, C) 이고 log_softmax 값 . 모델 출력 (N, T, C) 는 transpose
attention 합 = 1	softmax 덕분 . √d 는 크기를 맞출 뿐 합과 무관
Transducer 의 T < U	가능 (한 프레임에서 글자 여러 개). CTC 는 불가능
mask_prob = 0.65?	transformers 의 mask_prob ≈ p × M. 논문 p = 0.065, M = 10 과 같은 설정
사전학습 체크포인트	wav2vec2-base(양자화기 있음) vs -960h(CTC 미세조정 , 양자화기 없음)

모양 (shape) 과 축 (dim) 을 소리 내어 읽는 습관 : (T, N, C) 인가 (N, T, C) 인가 ?

오늘 만든 것과 다음 단계

- ☐ CTC 접기 함수와 forward α 를 직접 구현해 F.ctc_loss 와 맞췄다
- ☐ Wav2Vec2 프레임 수를 공식으로 예측하고 출력 모양으로 확인했다
- ☐ greedy 디코딩과 CTC 스파이크로 단어 타임스탬프를 만들었다
- ☐ attention 과 Whisper 한 토큰씩 루프를 구현해 generate() 와 맞췄다
- ☐ Transducer α 점화식을 구현하고 세 방식을 비교했다
- ☐ InfoNCE 를 구현하고 wav2vec 2.0 · HuBERT 특징을 확인했다

다음 : Day 7 · Whisper 심층 분석

오늘 AED 의 예로 잠깐 본 Whisper 를 깊게 : 30 초 창과 Log-Mel, 모델 크기별 성능 · 속도 , 언어 감지 , 빔 서치 · temperature fallback, 그리고 한 토큰씩 생성 구조에서 생기는 환각과 대응법 .

worksheet.html	40 문항
개념 워크시트 · 노션 제출	
animation.html	9 개 탭
인터랙티브 애니메이션	
D6_ASR 원리 _ 실습 .ipynb	빈칸 9
실습 노트북	

레포 위치 04-voice-ai/day06