Physical AI 실무 · 2일차

ALL AI

2일차 · LLM과 VLM: 학습 원리부터 검증 가능한 판단까지

v1.0



경기도 성남시 분당구 판교로 289번길 20 판교테크노밸리
스타트업캠퍼스 1동 806호-807호

Copyright @ 2026 ALL.AI Inc. All rights reserved.

www.allai.co.kr

매일 재부팅 후 · 같은 환경을 다시 생성

2일차 · 실습 시작 전 | 호스트에서 실행 · 이름·경로·포트는 본인 배정값

ALL AI

- 호스트에서 본인 컨테이너 상태를 확인합니다.
- 없음: 다음 슬라이드의 런처로 재생성합니다.
- Up: Jupyter에 접속합니다.
- Exited 예외: 호스트 파일 보존 확인 → 중지된 본인 항목만 정리 → 재생성합니다.

```
docker ps -a

# Exited인 본인 항목만, 파일 보존 확인 후
# 로컬 / 원격 중 본인 이름 하나 사용
docker rm physical_ai_local
# 원격 이름: physical_ai_remote01

# 다음 슬라이드의 런처로 재생성
# 실행 중인 항목에는 rm/stop 하지 않기
```

시작 안내 · state · 01.Setup/README.md

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

로컬 사용자 · 실습 컨테이너 열기

2일차 · 실습 시작 전 | 호스트에서 실행 · 이름·경로·포트는 본인 배정값

ALL AI

- USB 카메라 연결 후 생성합니다.
- Jetson 데스크톱의 호스트 터미널에서 실행합니다.
- 접속: http://localhost:8888
- 토큰: nvidia
- 노트북 첫 준비 셀부터 다시 실행합니다.

```
cd /home/nvidia/NEPES
cd 01.Setup/02.Docker
export ROS_DOMAIN_ID=21
bash 04_run_container.sh \
  nepes-course:physical-ai-v1.0 \
  /home/nvidia/NEPES \
  local physical_ai_local 8888
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

원격 사용자 · 개인 실습 환경 열기

2일차 · 실습 시작 전 | 호스트에서 실행 · 이름·경로·포트는 본인 배정값

ALL AI

- PC에서 SSH로 Jetson에 접속한 뒤 생성 명령을 실행합니다.
- 1일차의 개인 자료 폴더를 재사용합니다.
- PC 브라우저 접속:
- http://<Jetson-IP>:8889
- 로그인 토큰: nvidia

```
ssh nvidia@<Jetson-IP>
cd /home/nvidia/NEPES_remote01
cd 01.Setup/02.Docker
export ROS_DOMAIN_ID=22
bash 04_run_container.sh \
  nepes-course:physical-ai-v1.0 \
  /home/nvidia/NEPES_remote01 \
  remote physical_ai_remote01 8889
```

시작 안내 · remote · 01.Setup/README.md

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

공용 Ollama · 로컬 담당자 한 명만 시작

2일차 · 실습 시작 전 | 호스트에서 실행 · 이름·경로·포트는 본인 배정값

ALL AI

- Jetson 호스트에서 한 번 실행합니다.
- 원격 사용자는 같은 서버를 공유합니다.
- 이미 실행 중이면 런처가 확인합니다.
- 모델 목록이 보이면 준비 완료입니다.
- 수업 모델은 다시 다운로드하지 않습니다.

```
cd /home/nvidia/NEPES
bash 01.Setup/02.Docker/\
06_run_ollama.sh /home/nvidia/NEPES

docker exec physical_ai_ollama \
  ollama list

# LLM: gemma3:1b
# VLM: gemma4:e2b-it-qat
```

시작 안내 · ollama · 01.Setup/README.md

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

2일차 · 학습하는 모델과 이미지를 읽는 모델

- 작은 숫자 모델을 직접 훈련하며 입력·정답·오차·파라미터의 관계를 이해합니다.
- 사전학습 LLM에 질문하고, 이미지 입력이 가능한 VLM으로 관찰 근거를 확인합니다.
- 마지막에는 응답을 검증 가능한 JSON으로 바꾸고 결과·시간·실패 이유를 저장합니다.
- 함께 해석하기: 작은 LSTM 훈련과 배포된 Gemma 추론은 별도 실습입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

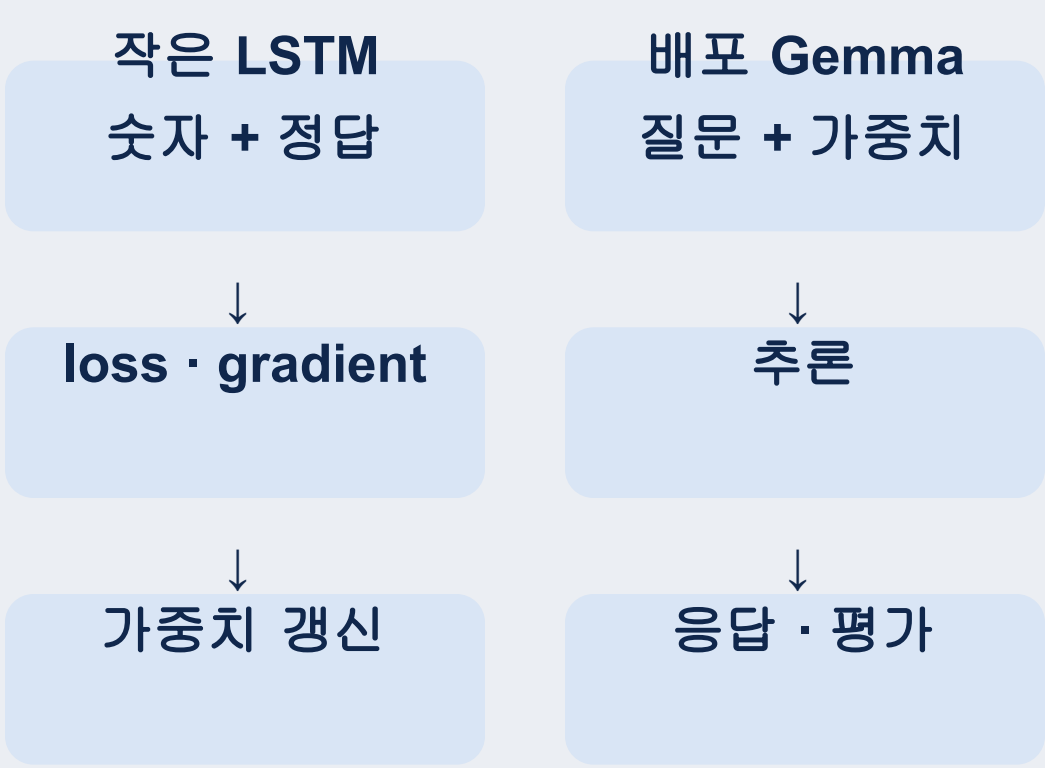
8시간의 진행 지도

- 오전 120분: 훈련 핵심 → loss 구현 → LSTM 훈련 전후 비교 → checkpoint 재로드.
- 오전 60분씩: Ollama 기본 사용과 생성 옵션 → Python 대화 이력·초기화·실패 처리.
- 오후 60분씩: VLM 입력 → 근거 중심 질문 → 최신 영상 프레임 → 구조화 결과와 평가.
- 함께 해석하기: 본수업은 00→05→06이고 구조별 01~04는 선택 자습입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

오늘의 두 모델은 서로 다른 실습입니다

- 작은 LSTM: 숫자 과제를 위해 무작위 파라미터에서 시작하고 GPU 역전파로 실제 값을 바꿉니다.
- Gemma: 미리 배포한 가중치를 Ollama 서버가 읽어 답을 생성하며 수업 중에는 값을 훈련하지 않습니다.
- 프롬프트를 바꾸거나 대화 이력을 추가하는 것은 이번 실습에서 파라미터 업데이트가 아닙니다.



본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

실습 환경을 먼저 확인합니다

ALL AI

- 개인 컨테이너의 Jupyter Terminal에서 확인 후 수업용 Python 커널로 진행합니다.
- GPU와 gemma3:1b 모델을 확인합니다. 공통 Ollama 서버를 사용합니다.
- 오류는 커널·CUDA·서버 연결로 나누어 점검합니다. 동시 요청은 순서를 조절합니다.

```
cd /workspace/04.LLM
python scripts/check_environment.py
ollama list
```

먼저 실습 | 04.LLM/00_training_core.ipynb

준비 셀·숫자 기억 과제·tensor shape 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

AI·머신러닝·딥러닝을 구분하기

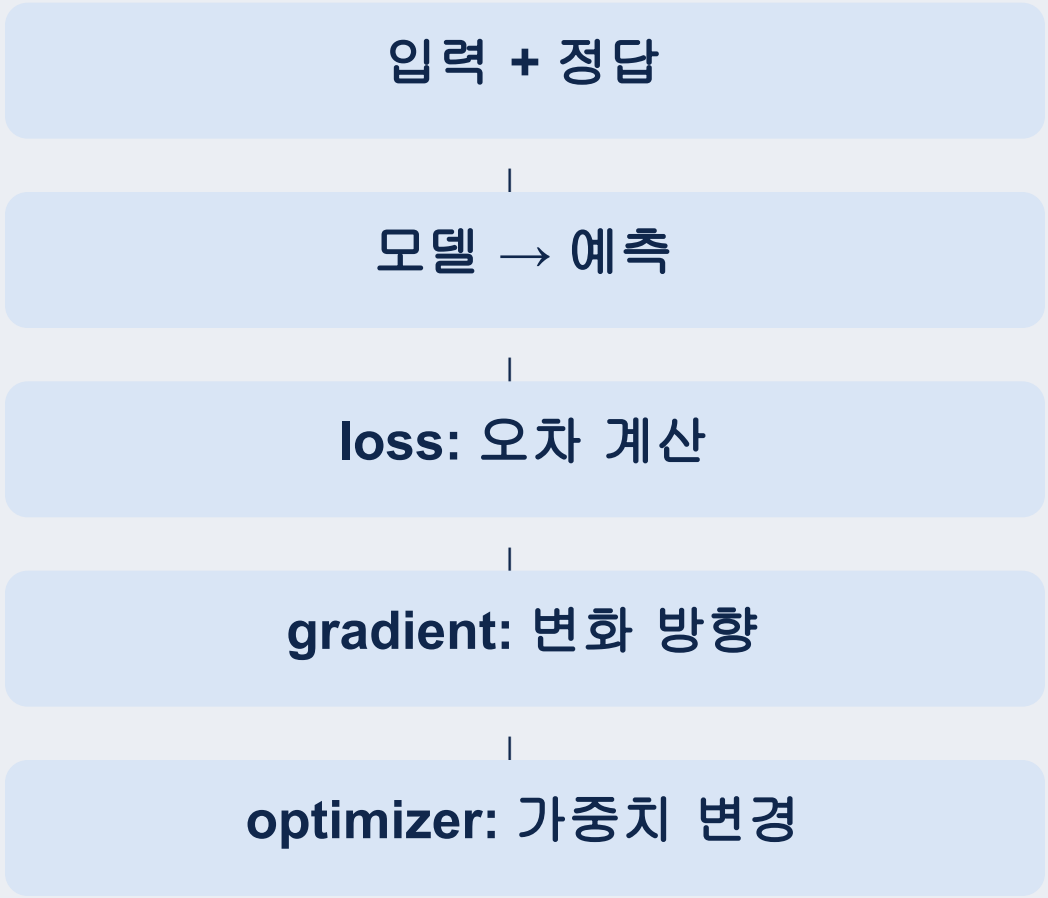
ALL AI

- AI는 지능적인 작업을 수행하는 방법을 넓게 부르는 말이며, 모든 AI가 신경망을 쓰는 것은 아닙니다.
- 머신러닝은 예제에서 예측 규칙을 찾고, 딥러닝은 여러 층의 신경망으로 그 규칙을 표현합니다.
- 언어 모델은 앞의 token을 바탕으로 다음 token을 예측하는 모델입니다. 크기만으로 업무 적합성을 알 수는 없습니다.
- 함께 해석하기: 규칙은 사람이 조건을 직접 작성하고 머신러닝은 데이터와 학습 목표로 조정한 모델을 사용합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

훈련은 어떤 값을 바꾸는가

- 입력은 모델이 보는 자료, 정답은 맞혀야 할 목표, 예측은 현재 파라미터로 계산한 결과입니다.
- 파라미터는 훈련 중 조정하는 숫자입니다. loss는 예측과 정답의 차이를 계산한 한 개의 값입니다.
- optimizer가 gradient를 이용해 파라미터를 바꾸고, 새로운 예제에서도 잘 맞는지 검증합니다.
- 함께 해석하기: 모델의 학습 가능한 가중치입니다.



본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

숫자 다섯 개로 기억 과제를 만듭니다

- 입력이 1, 2, 3, 4, 5이면 LSTM의 목표 출력은 BOS, 1, 2, 3, 4입니다.
- 현재 위치에서 한 시점 전의 입력을 출력해야 하므로 앞에서 본 정보를 기억해야 합니다.
- 이 과제는 자연어 대화가 아니라 훈련 원리를 확인하는 지연 복사 과제입니다.
- 함께 해석하기: 이번 과제의 정해진 순서를 기억하고 재현하는 능력을 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

데이터는 훈련용과 검증용으로 나눕니다

- 고정 seed로 만든 서로 다른 숫자 시퀀스 640개 중 512개는 훈련, 128개는 검증에 사용합니다.
- 훈련 데이터는 업데이트에 사용하고, 검증 데이터는 보지 못한 예제로 현재 모델을 평가합니다.
- 검증 결과를 반복해서 보고 선택했다면 최종 업무 평가는 별도의 입력과 조건으로 다시 해야 합니다.
- 함께 해석하기: 새 입력을 평가한다는 의미가 약해집니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Token은 모델이 다루는 입력 단위입니다

- token은 모델이 읽는 단위이고, vocabulary는 사용 가능한 token 목록입니다.
- 이번 숫자 과제는 token ID 3~12로 숫자 0~9를 나타내고, 1과 2를 BOS와 EOS에 사용합니다.
- 자연어의 token은 단어와 항상 같지 않습니다. 숫자 ID 자체의 크기가 뜻의 크기를 의미하지 않습니다.
- 함께 해석하기: ID는 기호를 찾는 번호입니다. 수치의 크기가 의미의 크기를 뜻하지 않습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Embedding은 token을 벡터로 바꿉니다

ALL AI

- Embedding은 각 token ID를 여러 숫자로 된 벡터에 대응시키는 학습 가능한 표입니다.
- 정수 ID는 항목을 찾는 주소이고, 찾은 벡터가 이후 신경망 계산의 입력이 됩니다.
- 처음의 벡터가 의미를 완성한 것은 아닙니다. 과제의 loss를 줄이는 과정에서 다른 파라미터와 함께 바뀝니다.



본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Tensor shape는 데이터의 배치도입니다

- tensor는 숫자를 여러 축으로 배열한 자료입니다. shape는 각 축에 몇 개가 들어 있는지 알려줍니다.
- B는 한 번에 처리하는 예제 수, T는 길이, V는 출력 후보 token 수입니다.
- logits의 [B,T,V]와 정답의 [B,T]는 같은 예제·위치를 가리켜야 합니다.
- 함께 해석하기: 각 위치의 후보 token 점수를 잃습니다. B는 예제 묶음, T는 위치, V는 후보 종류입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Logits와 확률은 다릅니다

- logits는 모델이 각 후보에 주는 정규화 전 점수입니다. 음수나 1보다 큰 값도 가능합니다.
- softmax는 후보 점수를 합이 1인 값으로 바꿉니다. 높은 점수의 후보가 더 큰 값을 받습니다.
- 이번 CrossEntropyLoss에는 raw logits를 전달합니다. 손실 함수 내부에서 필요한 변환을 처리합니다.
- 함께 해석하기: logits는 정규화 전 점수입니다.

먼저 실습 | 04.LLM/00_training_core.ipynb
loss TODO·학습자 검증 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Loss는 틀린 정도를 비교하는 기준입니다

ALL AI

- Cross entropy는 정답 후보에 충분한 점수를 주었는지 평가합니다. 정답에 낮은 확률을 주면 loss가 커집니다.
- loss는 업데이트 방향을 구하는 연속적인 값이고, 정확도는 맞힌 개수를 세는 지표입니다.
- 정확도가 같아도 확신 정도가 다르면 loss가 다를 수 있으므로 훈련 전후 두 지표를 함께 읽습니다.
- 함께 해석하기: loss는 예측 분포와 정답의 차이를 요약합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Loss 구현 확인 · 두 tensor의 위치를 맞춥니다

- 00_training_core.ipynb에서 예제 shape를 확인하고 exercises/loss.py를 파일 편집기로 수정한 내용을 확인합니다.
- [B,T,V]는 [B×T,V], 정답 [B,T]는 [B×T]로 바꾸어 같은 순서로 비교합니다.
- 파일 저장 후 check 검증 셀을 실행한 결과를 확인합니다. 완료 기준은 learner_verification=PASS입니다.
- 함께 해석하기: logits는 [6,5], target은 [6]으로 맞춥니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Loss 구현 확인 · 코드로 읽는 계약

- 이 코드는 강사가 안내하는 시점에 확인하는 참고 구현입니다. 마지막 후보 축을 보존하는 이유를 말로 설명합니다.
- reshape(-1)는 모든 정답 위치를 한 축으로 모읍니다. logits와 targets의 예제·시간 순서는 같아야 합니다.
- 숫자가 출력되는 것뿐 아니라 gradient가 모델로 전달되는지까지 검증해야 합니다.

```
from torch.nn import functional as F


def token_loss(logits, targets):
    v = logits.shape[-1]
    scores = logits.reshape(-1, v)
    gold = targets.reshape(-1)
    return F.cross_entropy(
        scores, gold
    )
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Gradient는 어느 방향으로 바꿀지 알려줍니다

- gradient는 파라미터를 조금 바꿀 때 loss가 어떻게 변하는지 나타냅니다.
- 역전파는 출력의 오차에서 시작해 계산 경로를 거슬러 각 파라미터의 gradient를 계산합니다.
- optimizer는 gradient와 학습률을 사용해 파라미터를 업데이트합니다.
  학습률이 지나치면 훈련이 불안정할 수 있습니다.
- 함께 해석하기: 현재 loss가 가중치 변화에 어떻게 반응하는지를 나타내는 값입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

한 번의 훈련 단계는 네 부분입니다

ALL AI

한 번의 훈련과 검증



평가 loss를 읽는 것과 모델 파라미터를 바꾸는 것을 구분합니다. shape와 정답 위치부터 확인하세요.

먼저 실습 | 04.LLM/00_training_core.ipynb

LSTM 훈련·checkpoint 재로드 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

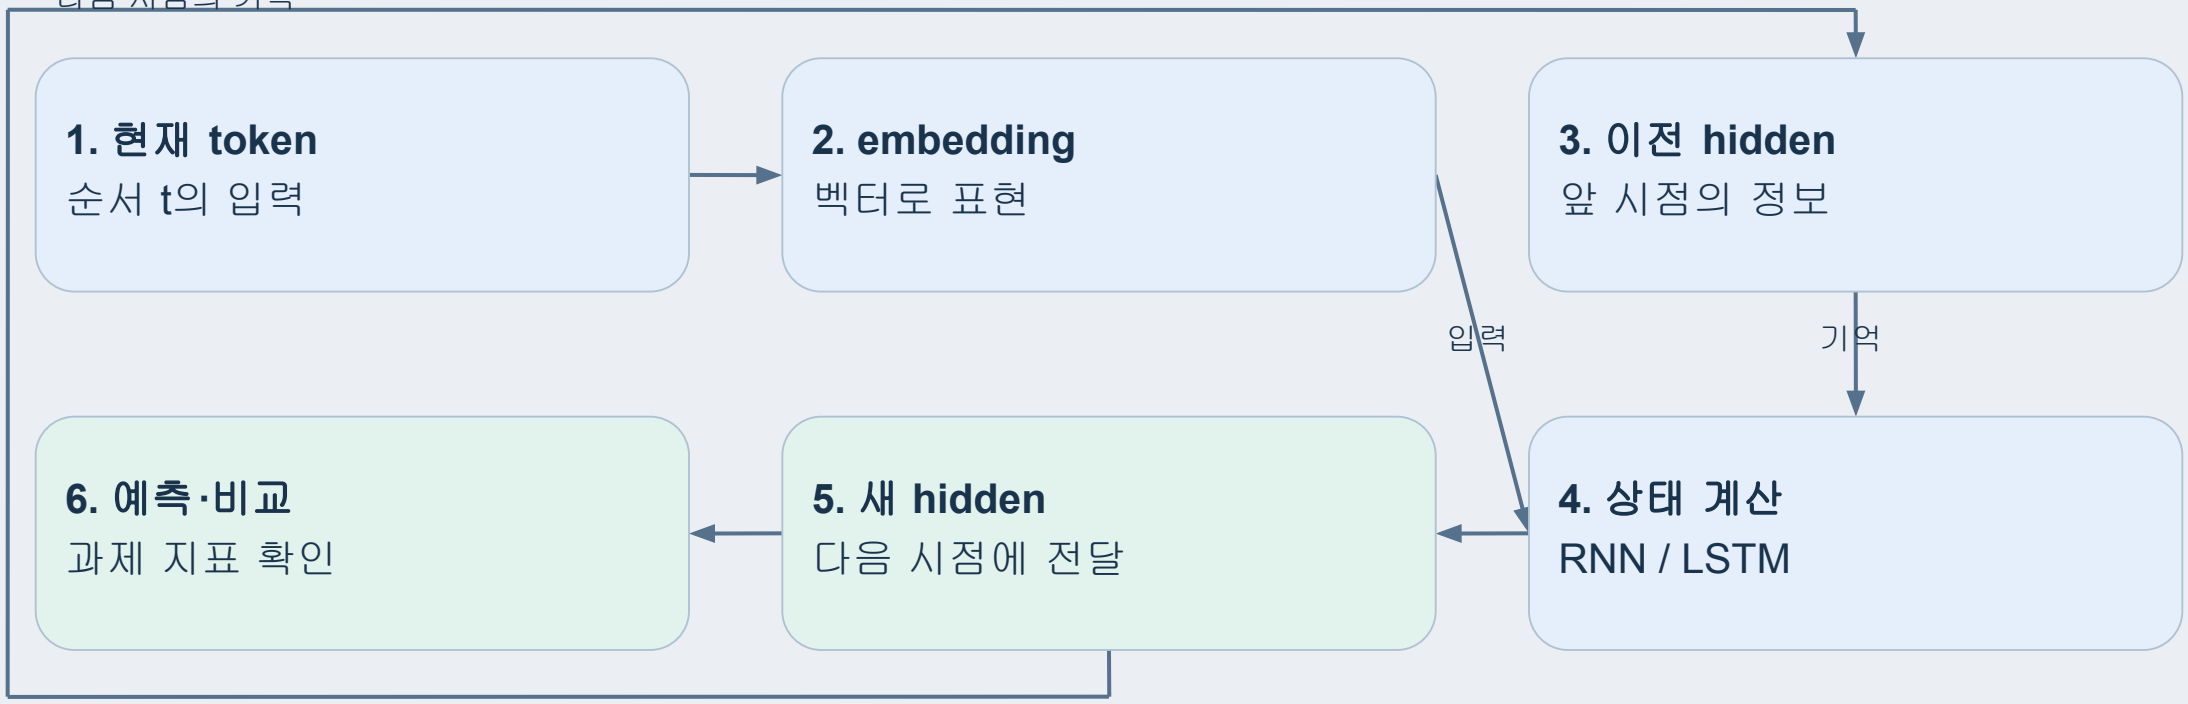
Batch·Epoch·학습률을 구분합니다

- batch는 한 업데이트에 묶는 예제이고, epoch는 훈련 데이터 전체를 한 번 사용한 횟수입니다.
- 학습률은 업데이트 크기를 조절합니다. epoch를 늘린다고 항상 검증 성능이 좋아지지는 않습니다.
- 수업은 quick 설정으로 짧게 관찰하고, 긴 반복과 구조 비교는 자습 설정으로 진행합니다.
- 함께 해석하기: batch는 한 번 처리할 예제 묶음, epoch는 데이터 전체를 돈 단위, learning rate는 갱신 크기와 관련됩니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

RNN은 앞에서 읽은 정보를 상태로 전달합니다

시점마다 기억을 전달하기



LSTM은 hidden 외에 cell state도 전달합니다. 시퀀스 진행과 optimizer 업데이트는 다른 반복입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

LSTM은 남길 기억과 지울 기억을 조절합니다

- LSTM은 cell state라는 기억 경로와 여러 gate로 정보의 유지·입력·출력을 조절합니다.
- gate는 사람이 정한 if문이 아니라 학습되는 연속 값입니다. 과제에 도움이 되는 기억 방식이 훈련됩니다.
- 이번 지연 복사는 바로 전 입력을 기억해야 하므로 LSTM의 동작을 작은 예제로 확인하기 좋습니다.
- 함께 해석하기: 기억을 남기고 지우는 구조를 제공하지만 학습 조건과 과제에 따라 결과가 달라집니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

LSTM 훈련 · 전후 지표를 남깁니다

- 00_training_core의 run_training("lstm") 셀을 실행합니다. 별도 Python 프로세스가 끝나면 GPU 자원을 반환합니다.
- 훈련 전후 검증 loss·token 정확도·시퀀스 전체 일치율과 실제 예측 예제를 비교합니다.
- 결과는 Data/outputs/04.LLM/<실행명>/, 가중치는 Data/checkpoints/users/04.LLM에 저장됩니다.
- 함께 해석하기: 훈련 전 기준과 조건이 없어 개선 정도를 설명하기 어렵습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Loss 기록을 읽는 세 가지 질문

ALL AI

- 훈련이 진행될수록 오차가 대체로 줄어드는지, 갑자기 커지는 구간이 있는지 확인합니다.
- 훈련 loss만 좋아지고 검증 결과가 나쁘다면 과적합이나 데이터 차이를 의심합니다.
- 짧은 숫자 실험에서의 개선은 해당 과제에 대한 관찰입니다. 다른 길이·사진·업무로 일반화하지 않습니다.
- 함께 해석하기: 작은 변동이 있을 수 있으므로 전체 추세와 검증 지표를 함께 봅니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Token 정확도와 전체 일치율

- token 정확도는 각 위치를 얼마나 맞혔는지 세고, 시퀀스 전체 일치율은 모든 위치를 맞힌 예제를 셉니다.
- 5개 중 4개가 맞으면 token 기준 80%지만 해당 시퀀스는 전체 일치에 실패합니다.
- 같은 지표 이름도 과제가 다르면 직접 순위를 매기기 어렵습니다. 입력·정답·평가 방식을 함께 적습니다.
- 함께 해석하기: 여러 위치 중 하나라도 틀리면 전체 일치는 실패입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Checkpoint는 훈련 결과를 다시 읽는 파일입니다

ALL AI

훈련 결과를 저장하고 다시 쓰기



현재 메모리의 모델과 저장 파일은 다릅니다. 새 프로세스 재로드까지 확인해야 재사용을 검증합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

재로드 결과 · 새 프로세스에서 확인합니다

- 00_training_core의 checkpoint 재로드 셀은 방금 만든 파일을 infer.py에 전달합니다.
- 입력 1,2,3,4,5의 기대 출력은 BOS,1,2,3,4입니다. 실제 예측과 위치별로 비교합니다.
- checkpoint가 없으면 앞 훈련 결과와 경로를 확인합니다. 본인의 exercise 가중치인지도 확인합니다.
- 함께 해석하기: 이미 메모리에 있는 모델을 사용할 수 있습니다.

먼저 읽기·확인 | 04.LLM/00_training_core.ipynb
구조 비교·질문 답안·기록 저장 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Seq2Seq는 입력을 읽고 다른 순서로 출력합니다

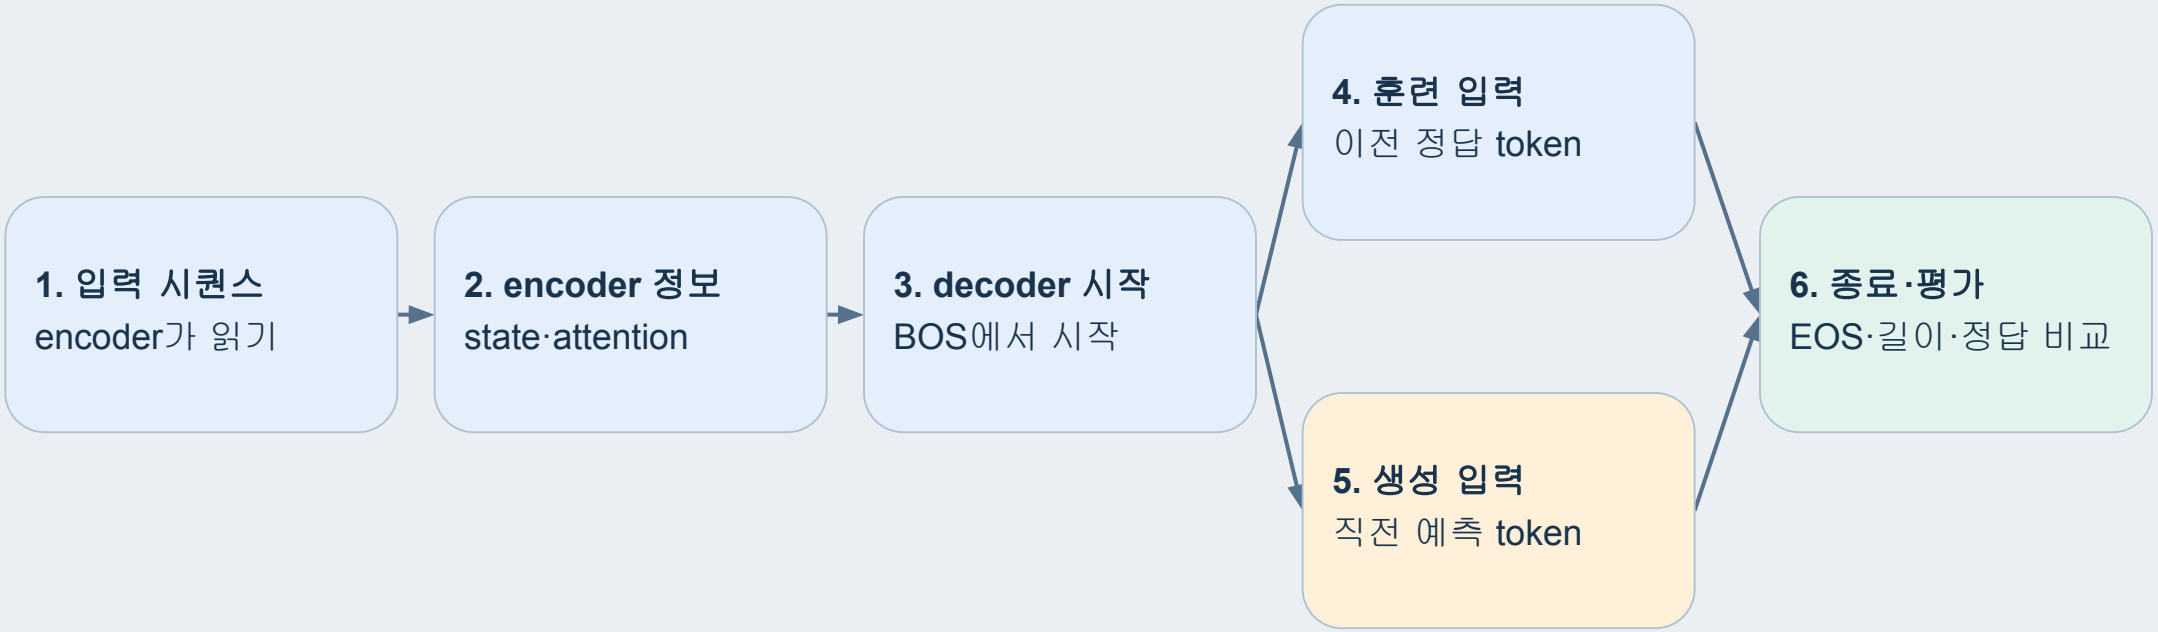
- Encoder가 입력을 읽고, decoder가 출력 token을 차례로 생성하는 구조입니다.
- 교재의 Seq2Seq 과제는 숫자 입력을 역순으로 출력하고 마지막에 EOS를 생성합니다.
- RNN/LSTM의 한 시점 지연 복사와는 과제가 다르므로 두 정확도를 단순한 모델 순위로 비교하지 않습니다.
- 함께 해석하기: 구조는 읽기와 생성을 분리하지만 이번 자습의 과제·shape 계약을 따라야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Teacher forcing과 자유 생성

결과 복습 | 2일차 · 훈련 원리 · 120분 | 2일차 · LLM / VLM

훈련과 생성의 입력이 다릅니다



4번과 5번은 서로 다른 실행 경로입니다. teacher forcing loss만으로 자유 생성 성공을 판단하지 않습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Attention은 필요한 입력 위치를 다시 참고합니다

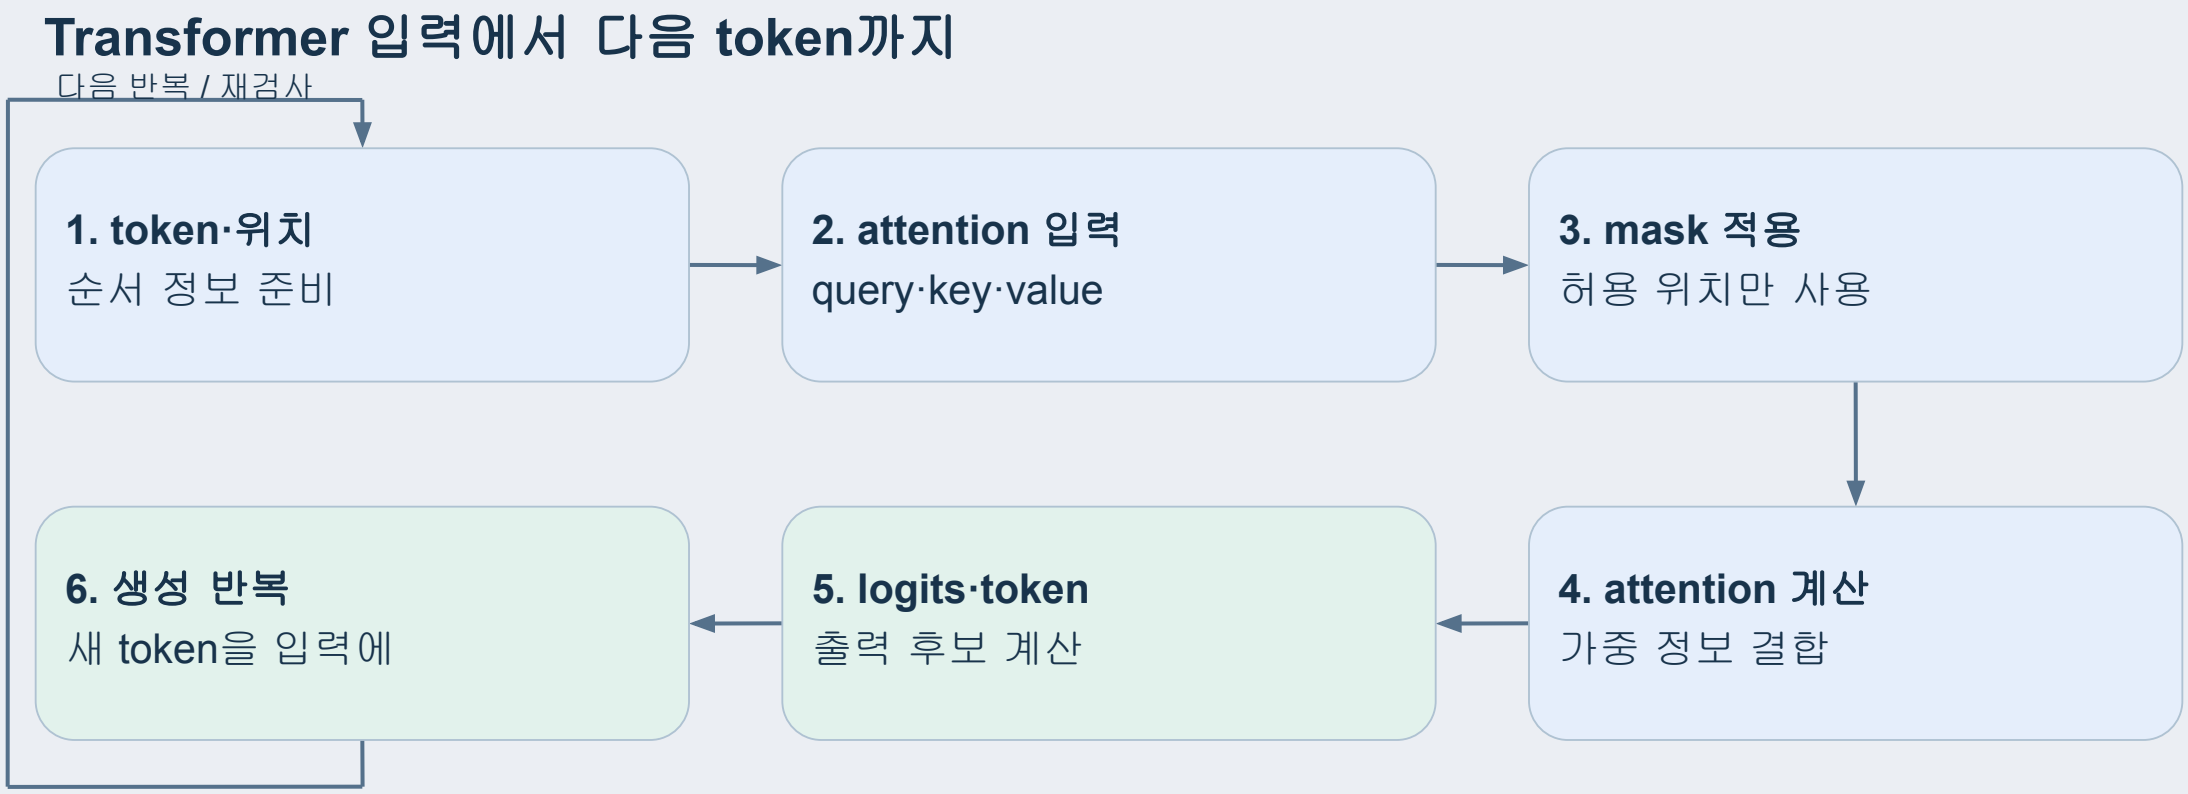
ALL AI

- 현재 출력 단계의 query와 입력 위치의 key를 비교해 어느 위치를 참고할지 가중치를 계산합니다.
- 그 가중치로 value를 섞은 context를 만들어 출력에 사용합니다. 모든 정보를 한 요약에만 담는 부담을 줄입니다.
- 교재 최소 Attention은 single-head이며 학습형 Q/K/V projection을 생략합니다. Transformer 전체 구현과 범위가 다릅니다.
- 함께 해석하기: 현재 계산에서 해당 위치를 크게 참고한 가중치입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Transformer는 attention과 위치 정보를 결합합니다

결과 복습 | 2일차 · 훈련 원리 · 120분 | 2일차 · LLM / VLM



미래 token을 가리는 위치와 다음 token을 만드는 위치를 구분합니다. mask TODO의 입출력 형상을 확인하세요.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

훈련 결과를 업무 판단으로 옮기기

- 훈련 전후 무엇이 좋아졌는지 실제 지표와 예측 예제로 설명합니다.
- 숫자 과제로 알 수 없는 사진·길이·조명·현장 조건을 명시하고 필요한 추가 데이터를 적습니다.
- 00 노트북 training_review를 작성하고 Data/outputs/course-review/04.LLM/training-review.json에 저장합니다.
- 함께 해석하기: 업무 입력·성공 기준·실패 비용과 추가 데이터가 필요합니다.

먼저 실습 | 04.LLM/05_ollama_basics.ipynb

CLI·API·options·프롬프트 비교 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Ollama는 모델을 실행하는 서버입니다

공용 모델 서버에 요청하기



클라이언트는 개인별로, 서버·모델 저장소는 공유합니다. 모델 tag와 실제 준비 상태를 먼저 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

모델 tag·digest·양자화

- tag는 실행할 모델 변형의 이름이고, digest는 실제 배포 모델을 식별하는 값입니다.
- 양자화는 가중치를 적은 비트로 표현해 저장·메모리 부담을 줄이는 방법이며 정확도·속도 영향은 별도 확인합니다.
- 교재 LLM은 사전 배포한 gemma3:1b를 사용합니다. 수강생이 pull로 다른 파일을 받지 않습니다.
- 함께 해석하기: tag와 실제 digest·실행 환경을 함께 기록해야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

CLI에서 먼저 질문합니다

- 개인 컨테이너 Terminal에서 모델 목록을 확인한 뒤 gemma3:1b를 실행합니다.
- 짧은 질문 하나로 모델 응답을 확인하고 /bye로 CLI 대화를 종료합니다.
- CLI 응답은 파일 저장 실습을 대신하지 않습니다. 이후 노트북에서 요청·응답·시간을 기록합니다.

```
ollama list
ollama run gemma3:1b
# 대화 종료: /bye
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

HTTP 요청의 구성 요소

ALL AI

- /api/chat에는 model, messages, stream과 생성 options를 보냅니다.
- messages는 role·content 목록이며 응답 본문은 message.content에 있습니다.
- stream=false는 결과를 한 번에 받습니다. API 형식과 답의 사실성은 따로 확인합니다.

```
{
  "model": "gemma3:1b",
  "messages": [{
    "role": "user",
    "content": "센서란?"
  }],
  "stream": false,
  "options": {
    "temperature": 0,
    "num_predict": 64
  }
}
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

생성 옵션은 출력 조건을 조절합니다

- temperature는 token 선택의 변동성, num_predict는 출력 token 상한, num_ctx는 문맥 길이 한도를 조절합니다.
- seed는 같은 환경의 비교 변동을 줄이고, keep_alive는 요청 뒤 모델을 메모리에 둘 시간을 제안합니다.
- seed와 keep_alive는 이전 대화를 저장하는 기능이 아닙니다. 낮은 temperature도 정확성을 보장하지 않습니다.
- Vocabulary는 token 종류 수입니다. num_ctx를 늘려도 vocabulary는 늘지 않습니다.
- 같은 token도 등장할 때마다 길이에 포함됩니다. num_predict는 생성 상한이며 더 일찍 끝날 수 있습니다.
- 함께 해석하기: token 생성 상한이며 글자·문장 수와 다릅니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Options 구현 확인 · 입력값부터 검사합니다

- 05 노트북을 열고 exercises/options.py의 build_options를 완성합니다.
- num_predict는 bool을 제외한 양의 정수여야 하며 temperature=0, num_ctx=2048을 반환합니다.
- 저장 후 check_options("exercise")가 통과해야 실제 client.chat 호출로 넘어갑니다.
- 함께 해석하기: 현재 옵션 계약이 정한 타입·범위를 지켜야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

첫 응답의 시간과 생성 속도

- wall time은 client가 요청부터 응답까지 기다린 전체 시간입니다.
- 출력 tokens/s는 생성 속도이며 모델 적재·입력 처리·대기 시간을 모두 대신하지 않습니다.
- 첫 요청에는 모델 적재 시간이 포함될 수 있습니다. cold start와 이미 적재된 요청을 구분해 기록합니다.
- 함께 해석하기: 모델 로드·대기·입출력 등이 포함될 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

프롬프트 비교 · 조건을 구체화합니다

ALL AI

- 같은 모델·옵션에서 네 질문의 응답을 비교합니다.
- 대상·상황·원하는 범위·출력 형식을 구체화합니다.
- 05 노트북의 prompt-comparison-*.json에 요청별로 저장합니다.
- 중간 실패는 같은 파일을 지정해 실패한 요청만 재시도합니다.
- 네 응답이 모두 성공한 뒤 형식과 근거를 평가합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

작업 지침에 있는 것과 없는 것

- 지침: 빨간 블록과 파란 블록을 확인하고, 가려져 구분할 수 없으면 담당자 확인을 요청합니다.
- 지침을 prompt에 넣고 “파란 블록이 가려졌다면?”과 “허용 최고 온도는?”을 질문합니다.
- 첫 질문은 지침의 근거를, 두 번째는 문서에 없다는 응답을 확인합니다. 임의 온도 숫자는 근거 없는 답입니다.
- 함께 해석하기: 수치 정답이 없습니다. 지침에 없다고 말해야 합니다.

먼저 실습 | 04.LLM/06_ollama_python.ipynb

messages·대화 이력·reset·실패 처리 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

대화 기억은 messages를 다시 보내는 일입니다

- API 요청은 보낸 messages를 문맥으로 사용합니다. 이전 요청이 자동으로 다음 요청에 포함되는 것은 아닙니다.
- 이력을 유지하려면 이전 user와 assistant 메시지를 새 질문 앞에 넣습니다.
- 서버에 모델이 적재되어 있다는 사실과 client가 대화 내용을 보존하는 것은 서로 다른 상태입니다.
- '추가 token 입력'은 vocabulary 확장이 아니라 입력 길이 증가입니다. system 지시·이전 대화·현재 질문·채팅 구분 token이 문맥을 사용합니다.
- 함께 해석하기: 이 실습의 대화 문맥은 client가 messages에 포함해 다시 보내는 정보입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

이력 없는 요청부터 비교합니다

- 06 노트북에서 설비 코드 NEPES-42를 알려준 후, 이전 messages 없이 코드를 다시 묻습니다.
- 두 번째 요청 JSON에 코드가 없다는 점을 먼저 확인하고 자연어 응답을 읽습니다.
- 우연히 맞은 문장 한 번으로 기억 기능을 입증하지 않습니다. 전송 데이터와 이력 검증을 함께 봅니다.
- 함께 해석하기: 우연한 추정이나 질문 자체의 단서일 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Messages 구현 확인 · 원본 이력을 바꾸지 않습니다

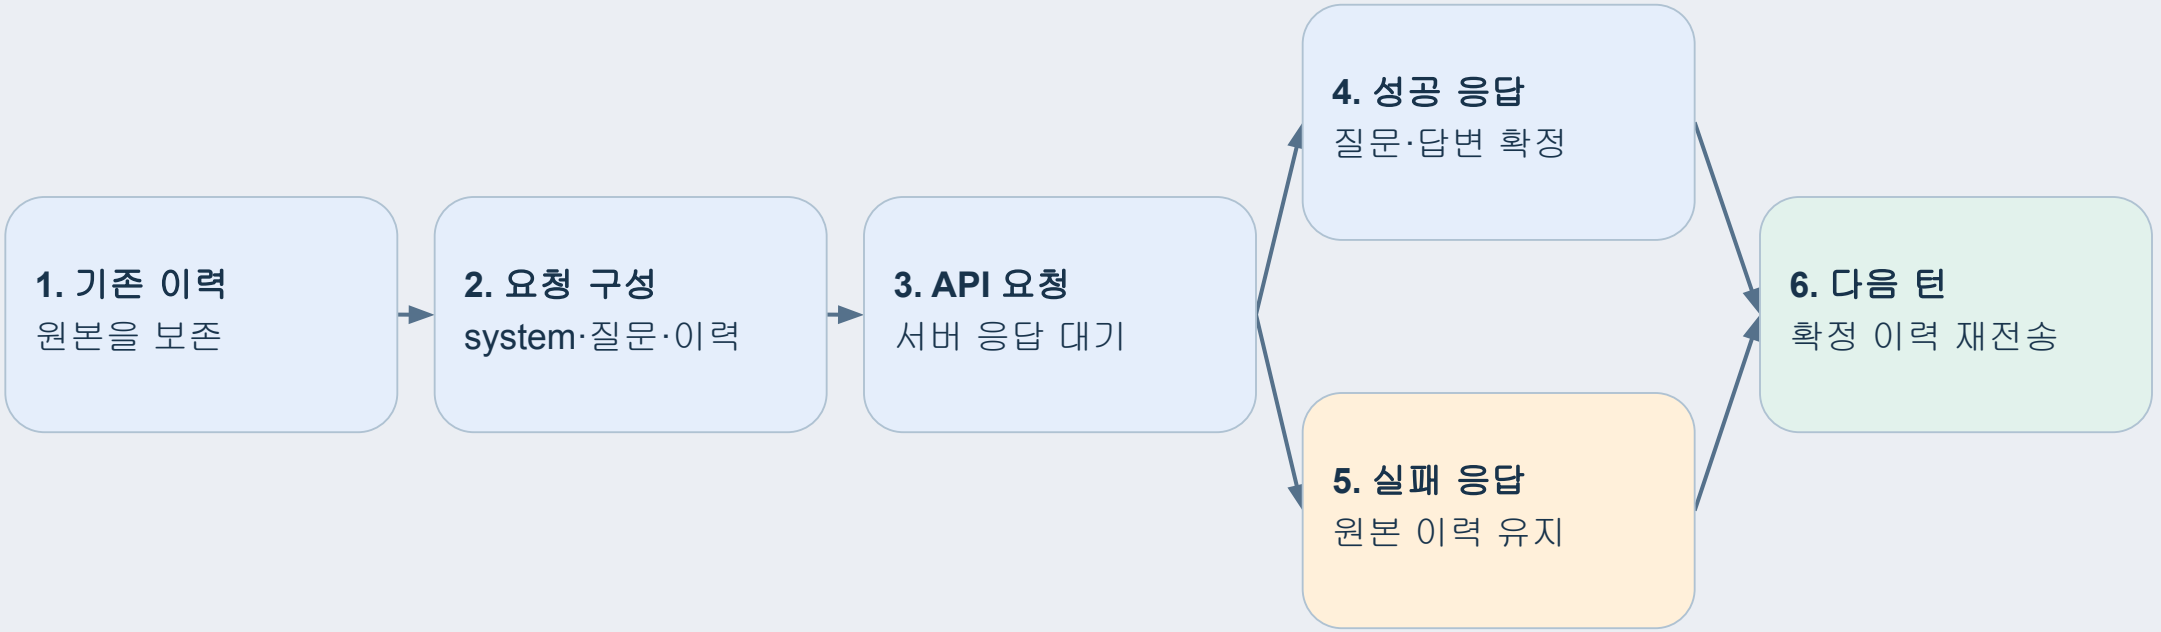
- exercises/messages.py에서 이전 목록을 복사하고 새 user 질문을 뒤에 추가합니다.
- 호출자가 가진 previous를 직접 바꾸면 실패하거나 재시도할 때 이력이 예상과 달라질 수 있습니다.
- 딕셔너리까지 복사하는 deepcopy를 사용하고 check_messages 검증으로 원본 보존을 확인합니다.
- 함께 해석하기: 원본 이력은 2로 보존하고 API에 보낼 새 목록은 3이 됩니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

성공한 대화만 이력에 확정합니다

결과 복습 | 2일차 · Python 대화 · 60분 | 2일차 · LLM / VLM

성공한 대화만 이력에 확정하기



성공과 실패는 분기입니다. 실패한 요청의 질문만 이력에 남아 다음 대화에 섞이지 않게 확인하세요.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

길이 제한과 Reset

ALL AI

- max_turns는 최근 대화 쌍 수를 제한해 메시지가 끝없이 커지는 것을 막습니다.
- 메시지 개수 제한과 token 문맥 제한은 다릅니다. 긴 문장 몇 개만으로도 문맥이 커질 수 있습니다.
- reset은 client 이력을 비웁니다. 모델 가중치를 삭제하거나 서버를 재시작하는 작업은 아닙니다.
- 예: num_ctx=2048, num_predict=256 → 입력 1,792 이내 + 생성 여유 256 token으로 계획합니다.
- 전체 입력을 보존하기 위한 예산입니다. 초과 시 잘림·문맥 이동·오류 처리는 환경에 따라 다릅니다. num_predict만 늘려도 문맥 용량은 늘지 않습니다.
- 함께 해석하기: 턴과 메시지의 단위를 코드 계약에 따라 읽어야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

대화 결과 · 비교·초기화·실패를 확인합니다

ALL AI

- 06 노트북에서 이력을 포함한 요청, Conversation(max_turns=2), reset과 오류 테스트를 실행한 결과를 확인합니다.
- 이력 관리 테스트는 가짜 응답으로 결정적으로 검사하고, 실제 Gemma 응답은 별도로 읽습니다.
- history-comparison-*.json에 이력 유무 결과를 저장하고 정상 응답·초기화·실패 시 보존을 설명합니다.
- 함께 해석하기: 이력·복사·실패 처리의 결정적 계약을 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

오전 정리 · 네 문장으로 설명하기

- 훈련은 loss의 gradient를 이용해 파라미터를 바꾸고, 추론은 주어진 가중치로 출력을 계산합니다.
- 모델 구조 이름보다 입력·정답·평가 조건을 알아야 결과를 해석할 수 있습니다.
- 대화는 messages로 문맥을 전달하며, 좋은 문장이라도 지침의 근거와 실패 처리를 확인해야 합니다.
- 함께 해석하기: 훈련과 추론, 가중치와 입력, 요청 성공과 사실성, 이력 저장과 모델 적재를 구분합니다.

먼저 실습 | 05.VLM/01_vlm_basics.ipynb

이미지 message·실제 질의·저장 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

VLM은 이미지와 질문을 함께 읽습니다

ALL AI

- LLM 실습은 text→text였고, VLM은 text+image→text로 입력이 확장됩니다.
- 이미지는 시각적 단서를, 질문은 어떤 대상과 관계를 설명할지 제공합니다.
- 출력 문장은 이미지의 사실을 보장하지 않습니다. 사람은 관찰 근거와 입력의 한계를 확인해야 합니다.
- 함께 해석하기: 현재 API는 이미지 bytes를 읽어 messages의 images에 전송해야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Vision capability를 확인합니다

결과 복습 | 2일차 · VLM 입력 · 60분 | 2일차 · LLM / VLM

- 교재 VLM 기본 모델은 gemma4:e2b-it-qat이며 gemma3:1b는 이미지 입력용으로 사용하지 않습니다.
- 모델 목록의 존재와 vision capability를 모두 확인하고 road.png·dog.jpg·ETS.mp4 입력도 검사합니다.
- 개인 컨테이너에서 검사하며 모델 다운로드는 강사의 사전 배포 절차로 완료합니다.

```
cd /workspace/05.VLM
export VLM_MODEL=gemma4:e2b-it-qat
/opt/course/bin/python \
  scripts/check_environment.py
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

이미지를 숫자 배열로 이해하기

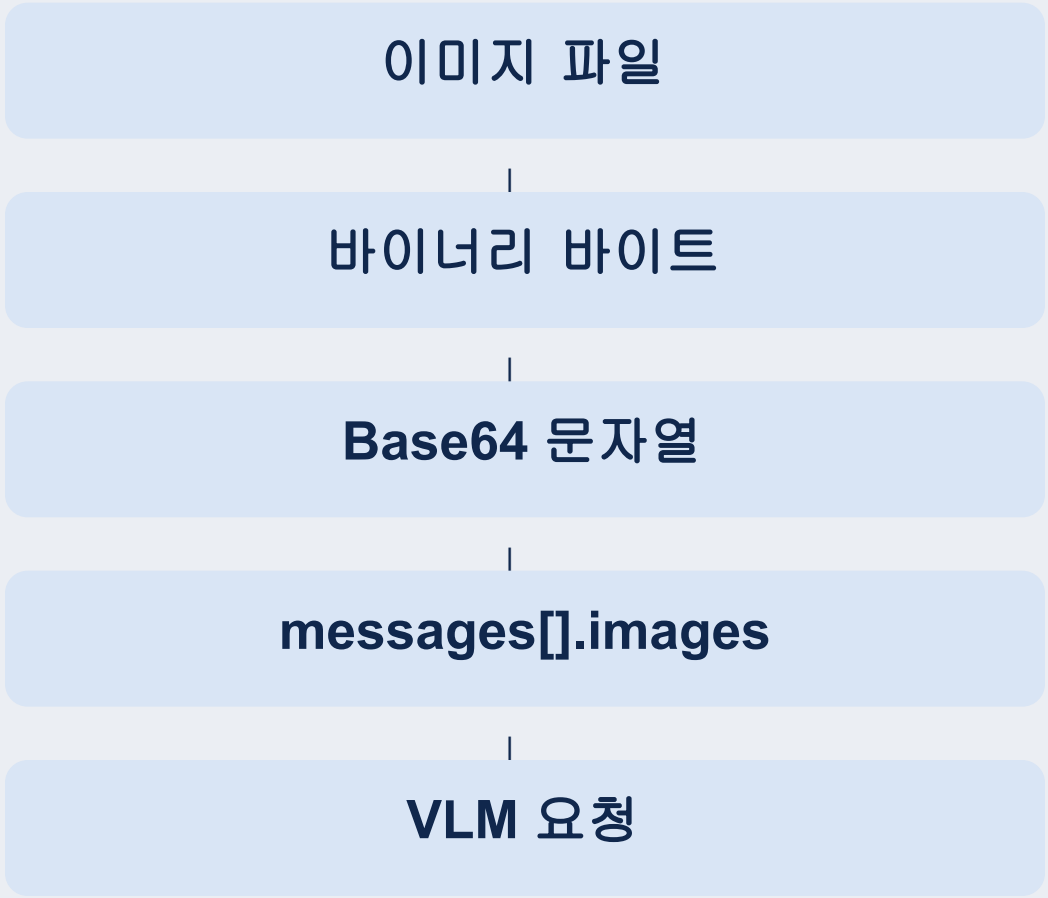
- 픽셀은 이미지의 작은 위치이며, 해상도는 가로·세로 픽셀 수입니다.
- 색상 채널은 각 픽셀의 색을 숫자로 표현합니다. 파일 바이트와 디코딩된 픽셀 배열은 표현이 다릅니다.
- 큰 이미지에는 더 많은 세부 정보가 있지만 입력 크기·전송량·처리 시간도 늘 수 있습니다.
- 함께 해석하기: shape는 높이·너비·채널 같은 배열 구조이고 파일 용량은 인코딩·압축 등에 영향을 받습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Base64는 이미지의 전송 표기입니다

결과 복습 | 2일차 · VLM 입력 · 60분 | 2일차 · LLM / VLM

- 이미지 파일의 바이너리 바이트를 JSON 안에 넣기 위해 Base64 문자열로 인코딩합니다.
- Base64는 이미지 이해·압축·암호화가 아닙니다. 보통 원본보다 약 4/3 긴 문자열이 됩니다.
- 01 노트북에서 원본 byte 수와 문자열 길이를 비교하고 전체 문자열 대신 앞부분만 확인합니다.

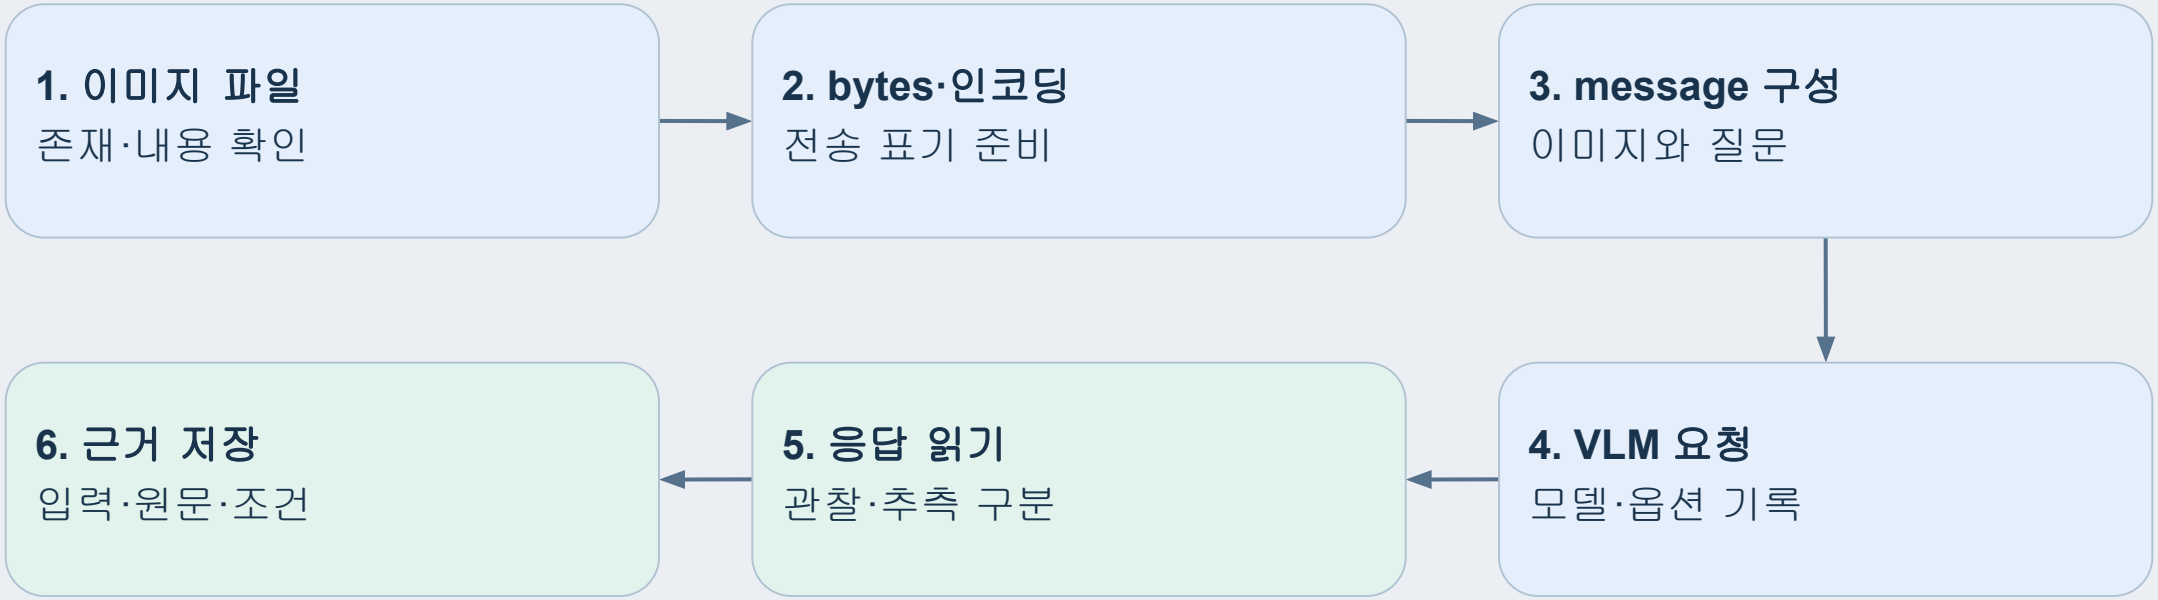


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

이미지 메시지의 구조

결과 복습 | 2일차 · VLM 입력 · 60분 | 2일차 · LLM / VLM

이미지와 질문을 한 요청으로



Base64는 전송 표기입니다. 이미지 의미를 추론하는 단계는 VLM 내부이며 응답은 원본과 대조합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Message 구현 확인 · 빈 입력을 막습니다

ALL AI

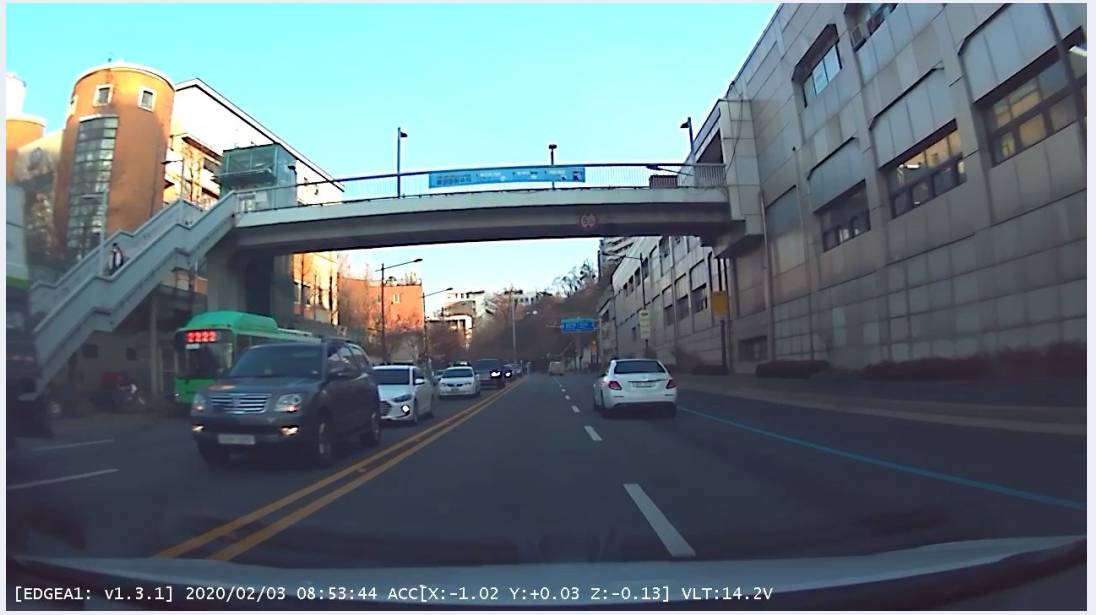
- 01 노트북과 exercises/message.py에서 build_vision_message를 완성합니다.
- prompt는 공백만 있으면 거부하고, image_base64는 비어 있지 않은 문자열인지 검사합니다.
- 저장 후 check_message("exercise")를 실행해 role·content·images 구조가 맞는지 확인합니다.
- 함께 해석하기: 현재 메시지 함수는 빈 입력을 계약에 맞게 검사합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

첫 이미지 질의 · 응답과 근거를 나란히 봅니다

결과 복습 | 2일차 · VLM 입력 · 60분 | 2일차 · LLM / VLM

- road.png를 보고 질문한 뒤 응답·시간을 확인하고 저장 셀까지 실행합니다.
- 저장 폴더: Data/outputs/05.VLM/
- 노트북: basics-<실행ID>/image-query.json
- 스크립트: query-<실행ID>/query.json
- 함께 해석하기: 원본과 답을 나란히 보고 실제 색·위치·가림을 확인합니다.



배포 실습 이미지 · road.png의 객체와 응답 대조

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

이미지 질의 결과를 파일로 남깁니다

결과 복습 | 2일차 · VLM 입력 · 60분 | 2일차 · LLM / VLM

ALL AI

- 개인 컨테이너 Terminal에서 배포 road.png에 질문하고 생성된 query JSON 경로를 확인합니다.
- JSON에는 입력 SHA-256·모델·질문·응답·벽시계 시간과 서버 시간이 연결됩니다.
- 파일 없음은 입력 경로, 쓰기 실패는 출력 폴더를 확인합니다. 결과 원문을 수정해 덮어쓰지 않습니다.

```
cd /workspace
/opt/course/bin/python \
  05.VLM/scripts/query_image.py \
  Data/images/05.VLM/road.png \
  --question "교통수단을 설명하세요."
```

먼저 실습 | 05.VLM/02_image_questions.ipynb

근거 중심 prompt·두 요청 비교 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

관찰과 추측을 분리합니다

- 관찰은 이미지의 픽셀에서 확인되는 대상·색·위치이고, 추측은 보이지 않는 목적·과거·원인을 덧붙이는 것입니다.
- 작은 글자·가림·프레임 밖 상황·정확한 거리에는 답할 근거가 부족할 수 있습니다.
- 질문에서 관찰 범위를 정하고 확실하지 않을 때 unknown을 쓰도록 요구합니다.



배포 실습 이미지 · 보이는 근거와 추측 구분

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

좋은 질문에는 세 가지가 있습니다

ALL AI

- 관찰 대상: 무엇을 확인할지 구체적으로 지정합니다. 예를 들어 동물과 연결된 물체를 찾도록 합니다.
- 출력 형식: animal, connected_object, visible_evidence처럼 비교할 항목을 정합니다.
- 불확실성 규칙: 안 보이거나 확실하지 않으면 unknown을 쓰고 보이는 근거만 사용하도록 합니다.
- 함께 해석하기: 대상과 관찰 범위, 요구 출력, 불확실 처리 기준을 명확히 하여 비교 가능한 응답을 얻습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Prompt 구현 확인 · 필드 계약을 만듭니다

ALL AI

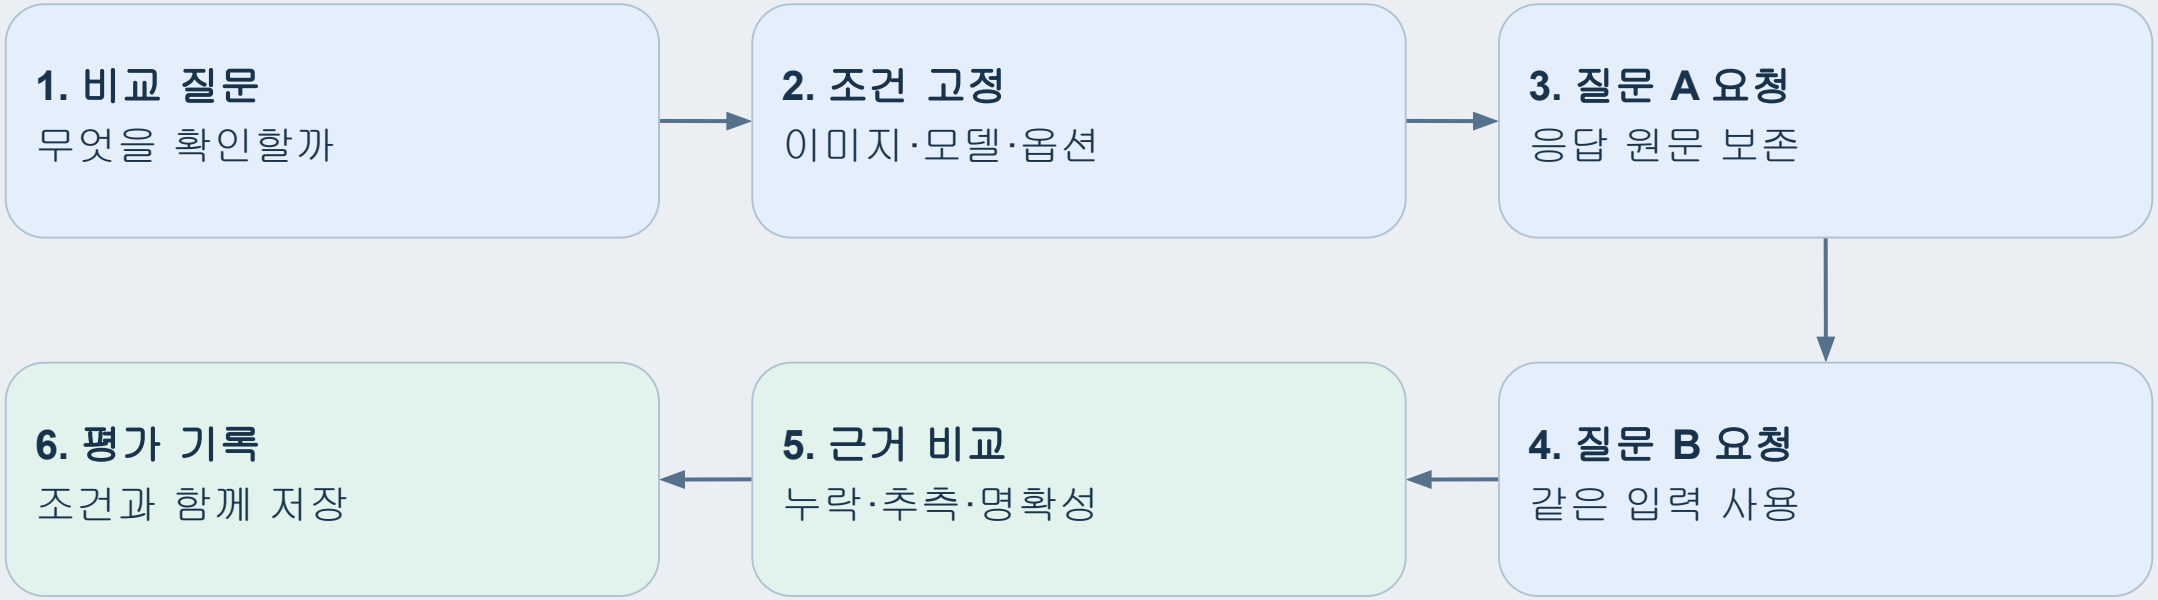
- exercises/prompts.py에서 질문·근거 제한·unknown 규칙·필드 순서를 포함한 문자열을 만듭니다.
- required_fields는 중복 없는 비어 있지 않은 문자열의 list 또는 tuple이어야 합니다.
- 02 노트북 check_prompts 검증을 통과한 뒤 만들어진 prompt를 출력해 사람이 먼저 읽습니다.
- 함께 해석하기: 뒤의 평가·검증 코드가 기대하는 계약과 달라집니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

같은 이미지에 두 질문을 비교합니다

ALL AI

같은 이미지에 다른 질문 비교



질문을 바꿀 때 이미지와 모델까지 함께 바꾸면 차이의 원인을 구분하기 어렵습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Confidence는 보정된 정확도 확률이 아닙니다

- VLM이 문장이나 JSON으로 만든 confidence는 자기 보고 값입니다.
- 0.9라는 숫자가 같은 조건 100번 중 90번 맞는다는 뜻이라고 가정할 수 없습니다.
- 실제 기대 label과 비교해 의미 정확성을 평가하고, confidence가 높아도 근거가 없으면 확인 대상으로 둡니다.
- 함께 해석하기: 모델의 자기 보고 점수를 보정된 정확도 확률로 해석하지 않습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

재현할 수 있게 입력과 조건을 남깁니다

- 입력 해시는 같은 파일을 사용했는지 확인하는 식별자이며 이미지 의미가 같다는 증명은 아닙니다.
- 모델 tag·digest·질문·옵션·원문·시간을 함께 남겨야 차이의 원인을 추적할 수 있습니다.
- 같은 사진의 밝기 변형이나 인접 frame은 독립된 장면으로 과대 계산하지 않고 같은 원본 그룹에 묶습니다.
- 함께 해석하기: 입력 파일·모델 tag/digest·옵션·실행 환경·시각을 비교합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

작업대 사례는 실제 측정 범위를 구분합니다

ALL AI

- 작업대 사진이 준비됐다면 지침과 함께 두 블록의 존재·가림을 사람이 먼저 확인합니다.
- 사진이 없다면 road/dog의 명시된 과제로 평가 방법을 연습하고 작업대 성능은 미측정으로 남깁니다.
- 실제 제조 규격·결함 검사를 구현한 것처럼 이름을 바꾸지 않고 어떤 입력에서 무엇을 확인했는지 적습니다.
- 함께 해석하기: 참고값과 현재 실측을 구분합니다.

먼저 실습 | 05.VLM/03_camera_description.ipynb

간격·최신 프레임·공동 USB 실습 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

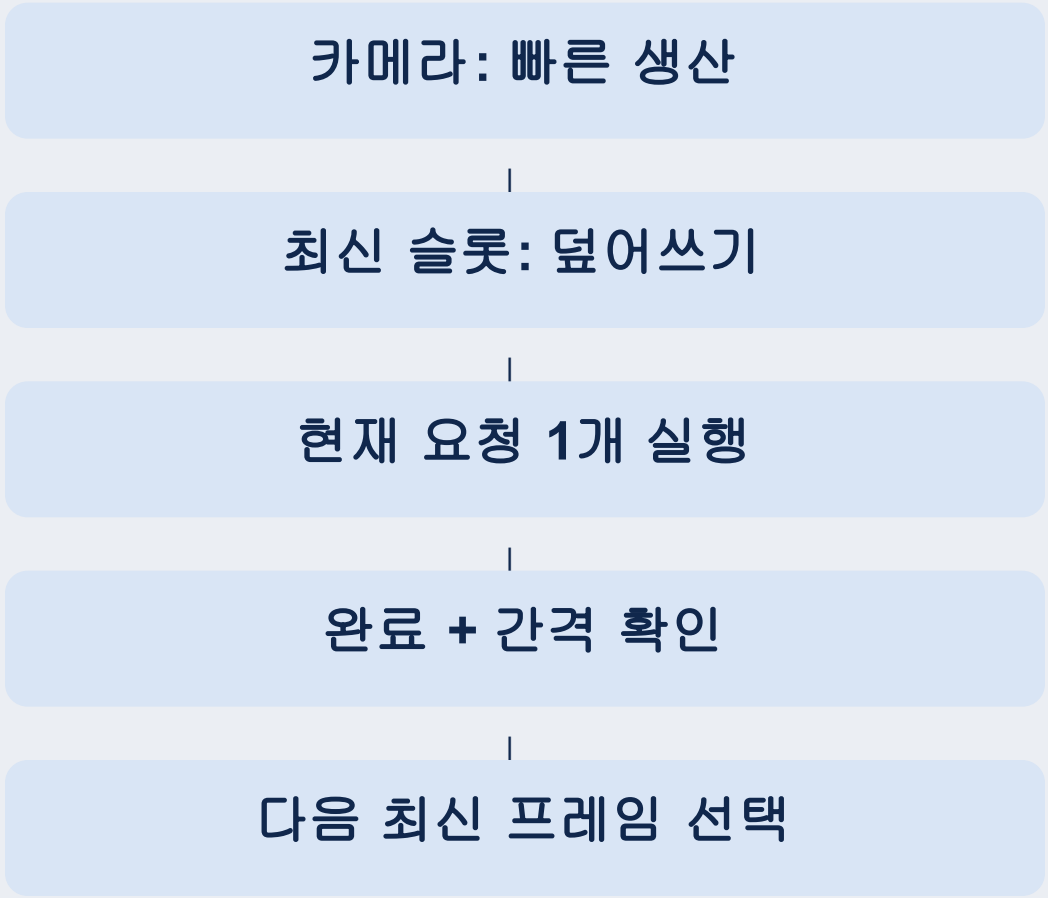
영상은 시간 순서가 있는 프레임입니다

- FPS는 1초에 입력되는 프레임 수입니다. 30 FPS이면 10초 동안 300장이 생깁니다.
- VLM 요청 하나가 오래 걸리면 카메라 입력 속도와 추론 처리 속도가 크게 다릅니다.
- 연속 입력에서는 답이 맞는지뿐 아니라 언제 촬영한 장면의 답인지 확인해야 합니다.
- 함께 해석하기: 그 프레임이 촬영된 순간의 입력에 대한 응답입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

모든 프레임을 큐에 넣으면 오래된 답이 옵니다

- 생산 속도가 소비 속도보다 빠르면 대기열이 늘고 메모리와 지연이 함께 커집니다.
- 수초 전 장면을 순서대로 모두 처리하면 현재 화면과 판단이 어긋날 수 있습니다.
- 이번 실습은 요청을 한 번에 하나만 실행하고, 다음 요청에는 최신 입력을 선택해 적체를 제한합니다.

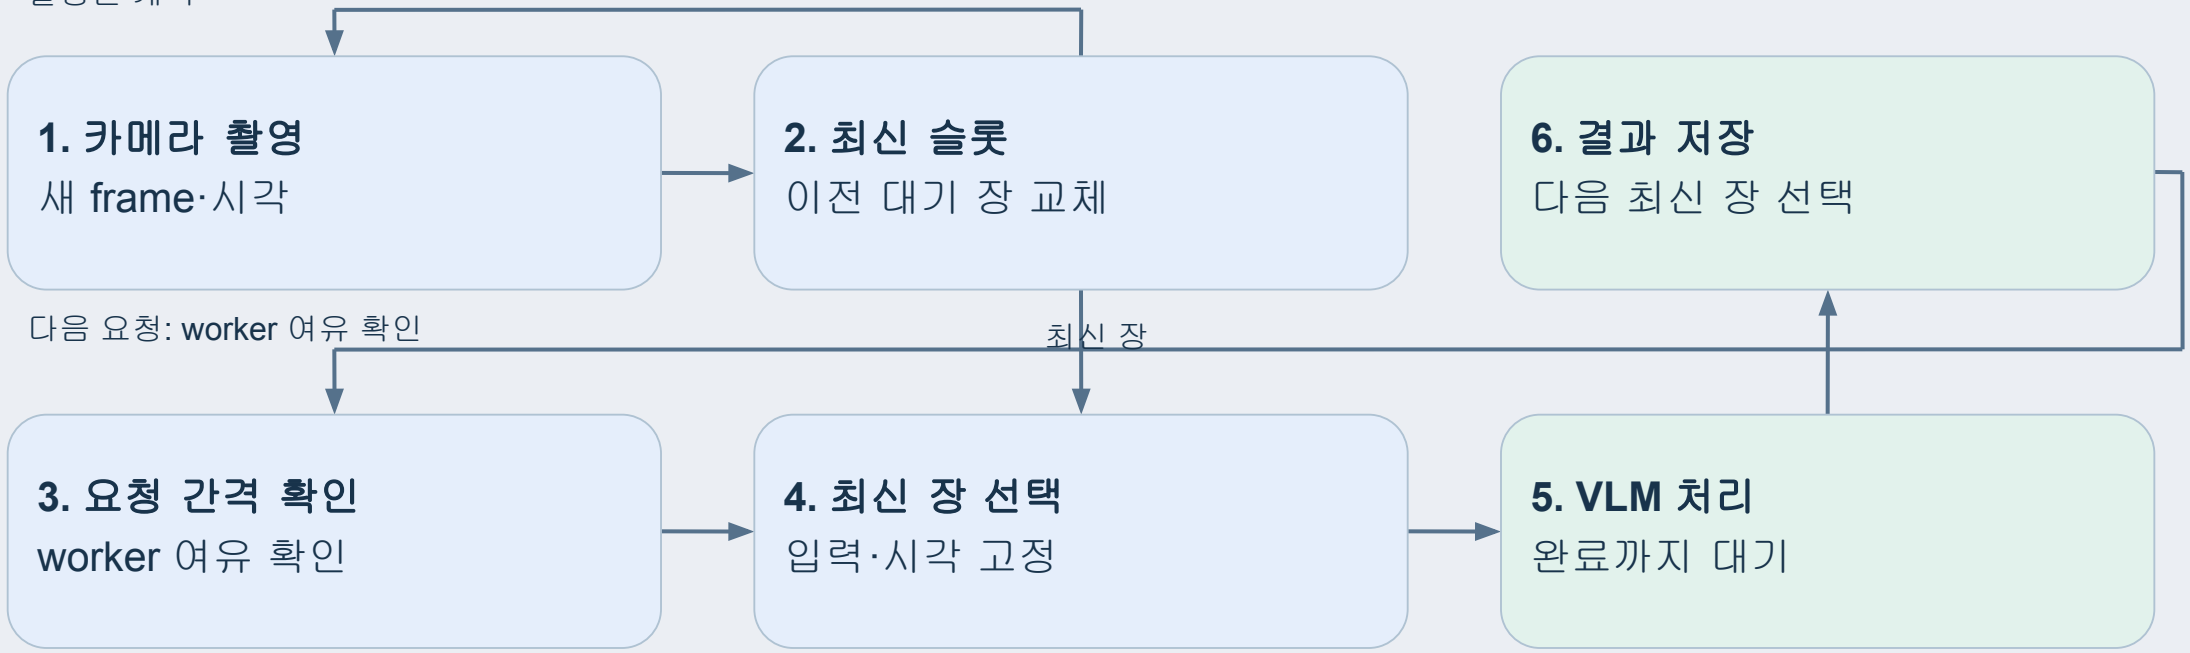


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

처리 간격과 최신 슬롯은 다른 역할입니다

결과 복습 | 2일차 · 영상·최신 프레임 · 60분 | 2일차 · LLM / VLM

촬영은 계속하고 요청은 최신 한 장



촬영(1–2)과 요청(3–6)은 동시에 진행합니다. 추론을 기다리는 동안에도 최신 슬롯은 새 프레임으로 교체됩니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Sampling 구현 확인 · 시간 경계를 확인합니다

- exercises/sampling.py에서 처음 값은 선택하고 마지막 선택 시각과의 차이가 간격 이상이면 선택합니다.
- 간격은 유한한 양수, timestamp는 감소하지 않는 유한한 숫자여야 하며 bool은 거부합니다.
- [0,2,9.999,10,10.1,19.999,20]에서 간격 10의 선택 index는 [0,3,6]입니다.
- 함께 해석하기: 교재의 포함·제외 계약을 코드로 확인해야 합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

LatestFrame 실험 · 오래된 프레임을 버립니다

- 03 노트북에서 frame-1, frame-2, frame-3을 차례로 넣은 뒤 최신 값을 가져옵니다.
- sequence 0 이후의 최신 값은 frame-3이고, sequence 3 이후 새 값이 없으면 None입니다.
- 이 방식은 모든 프레임을 빠짐없이 처리하는 것이 아니라 새 상태를 제한된 공간에 보관합니다.
- 함께 해석하기: 최신 한 장 계약에서는 B를 얻습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

먼저 Dry-run으로 저장 경로를 확인합니다

- 03 노트북의 --source images --dry-run은 배포 이미지를 고르고 기록하며 실제 VLM 요청을 생략합니다.
- saved 경로와 JSONL 기록을 확인해 입력 경로·파일 쓰기·프로그램 종료를 점검합니다.
- dry_run 결과는 모델 성능 평가가 아닙니다. 실제 질의 결과와 구분해 보존합니다.
- 함께 해석하기: 그 경로는 모델 요청을 생략할 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

선택 재생 · 녹화 영상으로 다시 확인

결과 복습 | 2일차 · 영상·최신 프레임 · 60분 | 2일차 · LLM / VLM

- USB 실습은 두 수강생이 로컬 화면을 함께 봅니다.
- 재생·복습·카메라 장애 때 ETS.mp4 경로를 선택합니다.
- 실행별 stream 폴더의 입력 이미지와 JSONL을 대조합니다.
- 함께 해석하기: 같은 입력을 재생해 처리 경로를 확인할 수 있지만 장치 연결·실제 촬영 조건은 다릅니다.

```
cd /workspace
/opt/course/bin/python \
  05.VLM/scripts/camera_vlm.py \
  --source video \
  --video Data/videos/05.VLM/ETS.mp4 \
  --interval 10 --max-requests 3
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

로컬 사용자 · USB 카메라로 실행합니다

- Jetson에 직접 연결한 USB 카메라를 사용하며 GUI preview는 Jetson 모니터에서 확인합니다.
- 카메라 index는 장치에 따라 달라질 수 있고 같은 카메라를 여러 프로그램이 동시에 열지 않습니다.
- Ctrl+C 또는 preview의 Esc로 종료한 뒤 카메라·창 해제를 확인하고 저장된 기록을 읽습니다.

```
cd /workspace
/opt/course/bin/python \
  05.VLM/scripts/camera_vlm.py \
  --source camera --camera-index 0 \
  --interval 10 --max-requests 3 \
  --preview
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

연속 입력 기록에서 확인할 것

ALL AI

- sequence와 촬영 시각을 보고 같은 입력을 반복 처리했는지, 건너뛴 프레임이 있는지 확인합니다.
- 요청 시간과 응답 내용을 함께 읽고, 입력 종료·시간 초과·모델 오류를 구분합니다.
- 오래된 결과를 현재 장면의 명령으로 바로 연결하지 않습니다. 4일차에는 freshness와 TTL을 추가합니다.
- 함께 해석하기: 프레임 번호·촬영 age·요청 간격·처리 지연·오류·버린 프레임을 연결합니다.

먼저 실습 | 05.VLM/04_structured_results.ipynb

구조 검증·실제 요청·형식/의미 평가 확인 후 다음 슬라이드로 진행합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

자연어를 코드가 읽으려면 계약이 필요합니다

- “조심하면 될 것 같아요” 같은 문장은 의미가 모호하고 후속 코드가 일관되게 읽기 어렵습니다.
- label·confidence·evidence라는 정해진 key와 자료형을 사용하면 검사할 수 있습니다.
- 모델에 schema를 요청해도 결과를 코드로 다시 검증해야 합니다. 형식이 맞는 것과 내용이 맞는 것도 다릅니다.
- 함께 해석하기: 부정문이나 설명 속 단어를 잘못 읽을 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

SceneAssessment의 세 필드

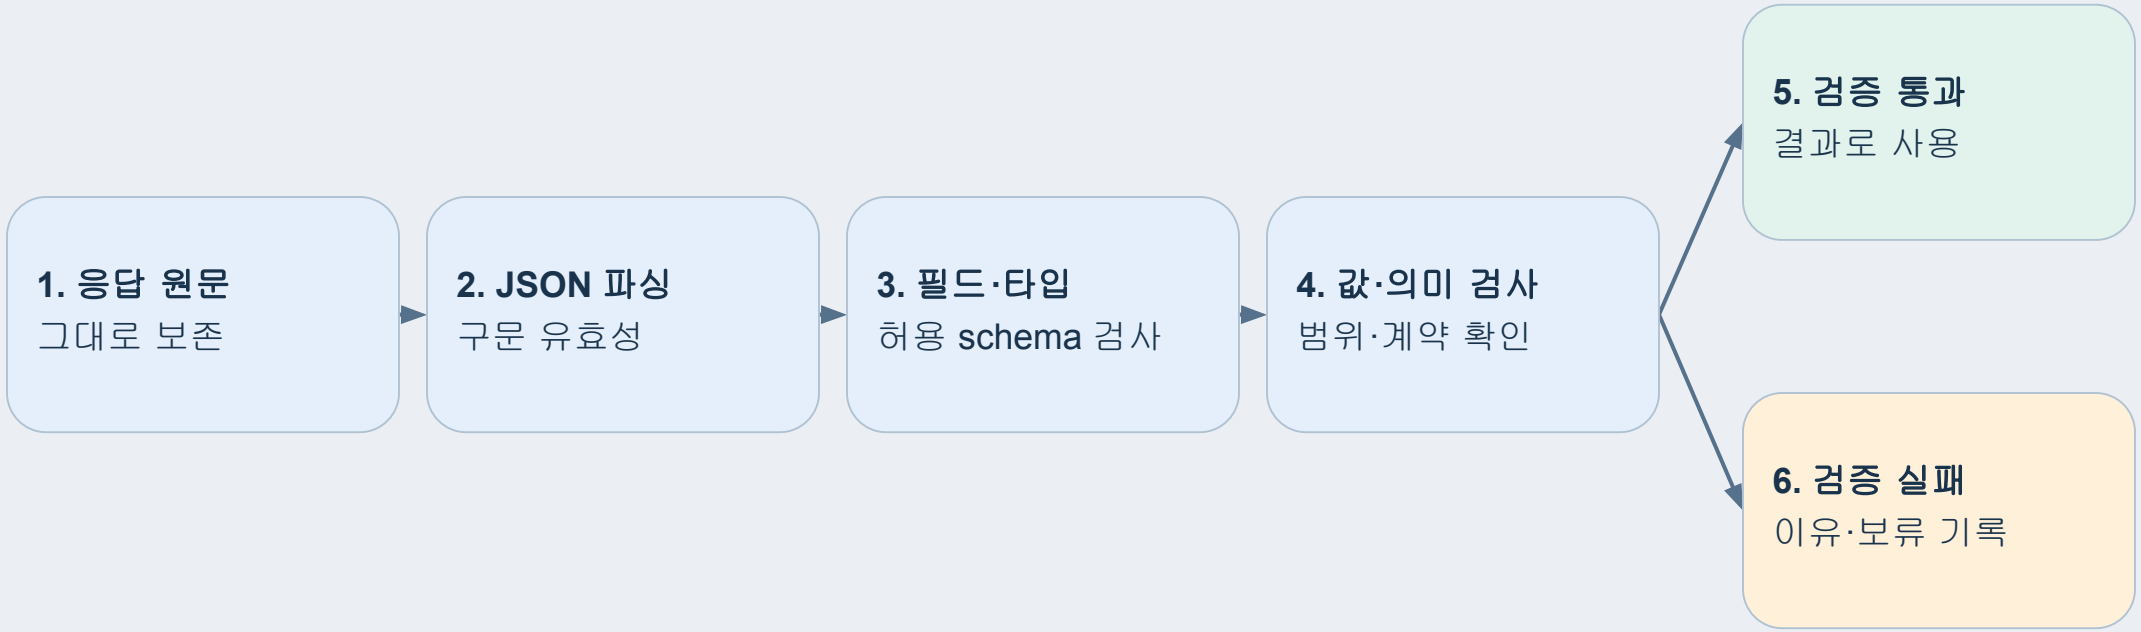
결과 복습 | 2일차 · 구조화·평가 · 60분 | 2일차 · LLM / VLM

- label은 clear·caution·unknown 중 하나입니다. 이 노트북의 도로 과제는 차량·사람이 있으면 caution입니다.
- confidence는 bool이 아닌 0~1 범위의 유한한 숫자여야 합니다.
- evidence는 비어 있지 않은 짧은 문자열 1~3개이며 각 항목은 120자 이내여야 합니다.
- 함께 해석하기: 필드 이름뿐 아니라 타입·허용값·값의 관계를 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

검증은 바깥 구조부터 안쪽 값으로

형식과 의미를 차례로 검사하기



5번과 6번은 통과/실패 분기입니다. JSON으로 읽혔다는 사실만으로 장면 판단이 맞는 것은 아닙니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Results 구현 확인 · 잘못된 출력도 검사합니다

- exercises/results.py의 parse_scene_result를 작성하고 04 노트북 check_results를 실행한 결과를 확인합니다.
- 정상 caution뿐 아니라 go label·bool confidence·JSON 아닌 문장 등의 실패 사례를 확인합니다.
- 완료 기준은 structured result TODO PASS이며 반환 값의 to_dict 결과를 직접 읽습니다.
- 함께 해석하기: 현재 노트북이 허용한 전체 표현만 처리합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

실패 시 Unknown으로 보류합니다

- status=ok의 unknown은 모델이 판단을 보류한 결과입니다.
- request_error는 요청 실패, format_error는 응답 계약 위반입니다.
- 두 오류도 unknown fallback과 오류 이유를 기록합니다.
- 형식 통과와 업무 판단 정답은 별도로 평가합니다.

```
{"label":"caution",
 "confidence":0.8,
 "evidence":["차량"]}

{"label":"go",
 "confidence":0.8,
 "evidence":["차량"]}

{"label":"clear",
 "confidence":true,
 "evidence":["도로"]}
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

실제 구조화 질의 · 원문까지 저장합니다

ALL AI

- 04 노트북: road.png 요청의 원문·판정·지연을 저장한 결과를 확인합니다.
- 실측: status=ok, clear, confidence=0.95인데 근거에는 차량을 언급했습니다.
- 차량·사람이 있으면 caution이라는 규칙과 모순이므로 의미 오답입니다.
- status=ok는 형식 검사 통과이며 confidence는 정답 확률이 아닙니다.
- 기대 label·원문·근거를 대조해 형식과 의미를 따로 기록합니다.
- 함께 해석하기: 실패 원인과 모델의 실제 출력을 확인하기 어려워집니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

평가 전에 사람이 기대값을 정합니다

- 응답을 보기 전에 입력과 규칙을 읽고 expected_label과 이유를 적습니다.
- 형식 성공·사람이 읽은 의미·보류·지연·실패 원인을 따로 기록합니다.
- 같은 입력을 보며 prompt를 고친 연습 결과와 마지막 확인 결과는 구분하고 미측정 조건은 비워 둡니다.
- 함께 해석하기: 응답에 맞춰 평가 기준이 바뀔 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

평가표 · 한 건을 끝까지 연결합니다

- 개인 컨테이너 Terminal에서 평가 템플릿을 복사하고 Jupyter 파일 편집기로 엽니다.
- 실제 결과 한 건의 입력 ID·기대값·원문 경로·형식·의미·지연·실패 원인을 채웁니다.
- 형식 오류는 model_label을 비우고 원문 해석을 별도 기록합니다. 빈 템플릿 행은 측정 건수가 아닙니다.

```
cd /workspace
mkdir -p Data/outputs/course-review
cp -n templates/evaluation.csv \
  Data/outputs/course-review/
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

형식 성공·의미 정확성·보류를 따로 봅니다

- 형식 성공률은 전체 요청 중 schema를 만족한 비율이며, 형식 실패를 분모에서 빼지 않습니다.
- false_allow는 caution/unknown 기대에 clear, false_reject는 clear 기대에 caution을 출력한 경우입니다.
- unknown 출력은 abstain으로 구분합니다. 높은 보류율만으로 작업을 잘 수행했다고 판단하지 않습니다.
- 함께 해석하기: 허용 가능한 장면까지 보류하여 작업을 수행하지 못할 수 있습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

2일차 완료 확인과 다음 연결

- LLM: loss·options·messages 검증, LSTM 전후 결과·checkpoint 재로드·대화 비교 기록을 확인합니다.
- VLM: 네 TODO 검증, 실제 이미지 질의·입력 해시·지연·구조화 결과와 실패 보류 기록을 확인합니다.
- 3일차에는 픽셀 처리와 ROS 전달을 배우고, 4일차에는 검증한 판단을 제한된 행동 승인 구조로 연결합니다.
- 함께 해석하기: 배열과 메시지의 입력 계약, 시간·최신성, 원문·결과 저장, 불확실 처리입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

부록 · 구조별 자습 경로

- 01_training_basics는 tensor·gradient·loss를, 02_rnn_lstm은 두 기억 구조를 자세히 실험합니다.
- 03_seq2seq_attention은 shift·attention, 04_transformer는 causal mask와 다섯 모델 비교를 다룹니다.
- 자습에서도 TODO 검증을 먼저 하고 자기 코드는 exercise로 실행합니다. solution 결과가 본인 검증을 대신하지 않습니다.
- 함께 해석하기: 과제·데이터·출력 길이·평가 방식이 같아야 의미 있는 비교입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

부록 · Attention의 최소 계산

- query와 key의 내적을 sqrt(d_k)로 나누고 softmax로 참고 가중치를 만듭니다.
- 가중치로 value를 가중 합해 context를 만들고, 교재는 query와 concat한 뒤 출력 Linear에 전달합니다.
- 03 교재는 d_k=H인 single-head 최소 구현입니다. 학습형 projection·multi-head 전체를 구현한 것으로 설명하지 않습니다.
- 함께 해석하기: 어느 입력 위치에 대한 가중치인지 알아야 context 계산이 맞습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

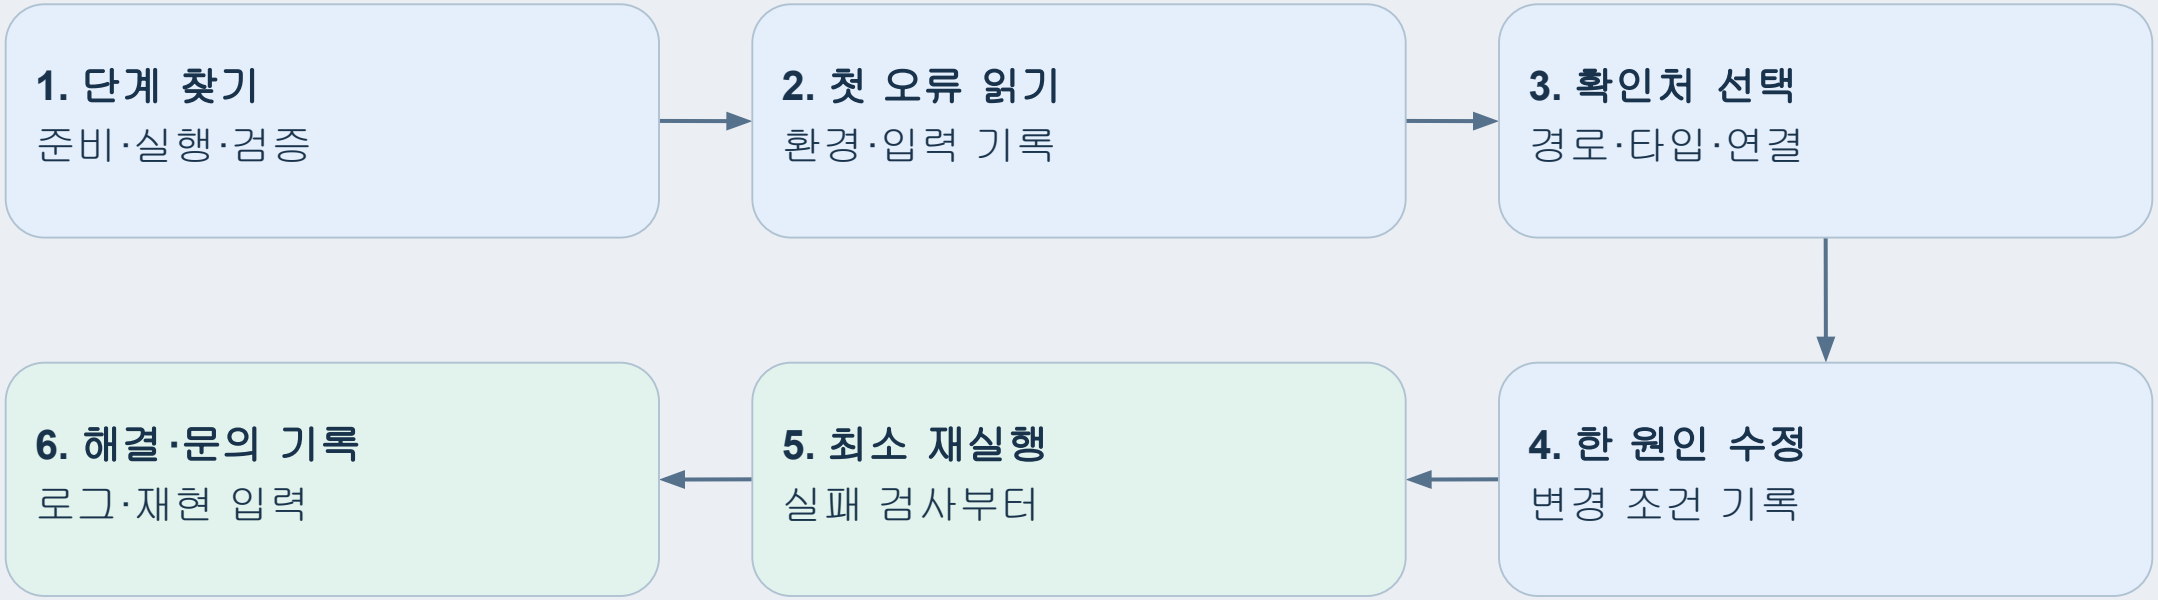
부록 · 훈련 오류를 좁히는 순서

- Shape: 후보 V축과 정답 위치 수가 맞는지 확인합니다. Dtype: 정답 token ID는 정수여야 합니다.
- Device: 모델·입력·정답이 같은 장치에 있는지 확인합니다. Gradient: loss가 계산 그래프에 연결되어야 합니다.
- File·resource: checkpoint 경로·실행명 중복·GPU 메모리·동시 프로세스를 확인합니다.
- 함께 해석하기: 입력 shape·target dtype·device·loss의 유한성·gradient·optimizer 순서로 작은 입력에서 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

부록 · API·영상 오류 복구표

실패한 단계부터 다시 확인



마지막 요약 오류만 보지 않습니다. 실패 단계·명령·첫 오류·이미 시도한 조치를 함께 남깁니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

부록 · 저장 파일 찾아보기

- LLM 훈련: Data/outputs/04.LLM/<실행명>/metrics.json·loss.csv.
- VLM 질의: query-<실행ID>/query.json. 구조화: structured-<실행ID>/structured-road.json.
- 영상: stream-<실행ID>/stream.jsonl과 입력 프레임.
- 개인 판단: Data/outputs/course-review/.
- 함께 해석하기: 현재 VLM 비교는 comparison-실행ID 폴더의 manifest.json과 prompt-comparison.jsonl입니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

부록 · 오늘의 실행과 결과 확인

- 제공 환경에서 GPU·API·vision 검사를 확인합니다.
- 훈련·추론은 보드별 순서를 정해 실행합니다.
- USB 실습은 로컬 화면을 함께 보고 각자 기록합니다.
- 예시 숫자와 자신의 실제 측정값을 구분합니다.
- 함께 해석하기: 핵심 TODO·검증·실제 요청·저장·의미 평가를 해당 범위대로 확인합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

감사합니다



경기도 성남시 분당구 판교로 289번길 20 판교테크노밸리
스타트업캠퍼스 1동 806호-807호

Copyright @ 2026 ALL.AI Inc. All rights reserved.

www.allai.co.kr