Physical AI 실무 · 2일차

ALL AI

LLM 5시간 · Tool·RAG·배심원 / VLM 3시간 · 이미지·관찰·요약

v1.03



경기도 성남시 분당구 판교로 289번길 20 판교테크노밸리
스타트업캠퍼스 1동 806호-807호

Copyright @ 2026 ALL.AI Inc. All rights reserved.

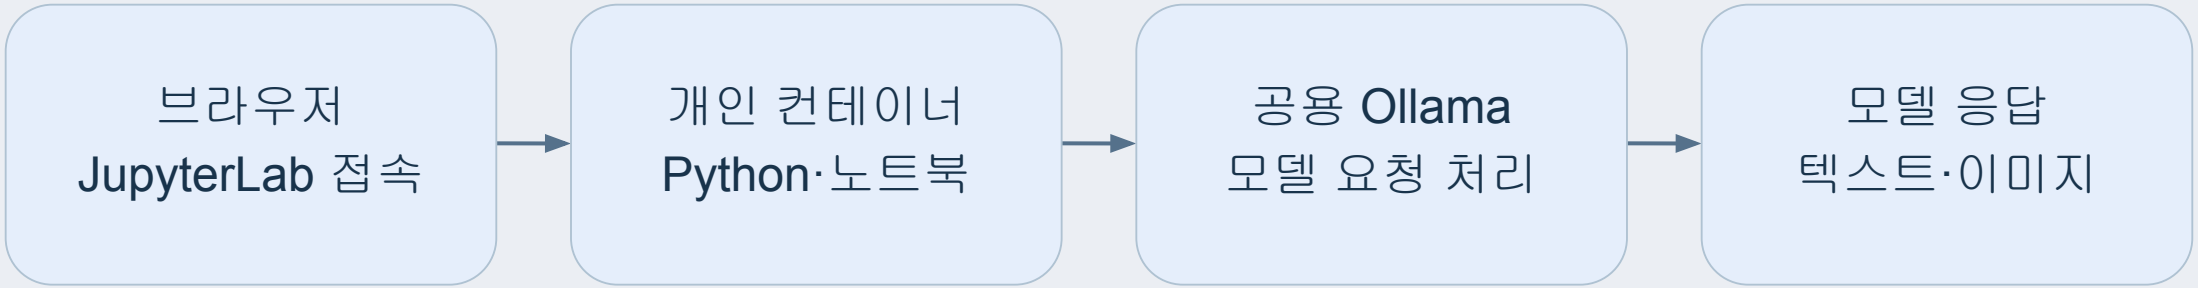
www.allai.co.kr

실습 환경 · 두 컨테이너의 역할

수업 전 준비 | 명령을 입력할 위치부터 구분합니다

ALL AI

같은 Jetson의 host-network 환경: Ollama API는 127.0.0.1:11434



Docker 실행은 Jetson 호스트에서 합니다.
패키지는 개인 Jupyter Terminal에 설치합니다.
모델은 공용 Ollama에 준비합니다.

준비 → Ollama 채팅 → 모델 다운로드 → Python 패키지 → 커널 확인

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

매일 재부팅 후 · 같은 환경을 다시 생성

수업 전 준비 | **Jetson** 호스트 터미널 · 이름·경로·포트는 본인 배정값

- 호스트에서 본인 컨테이너 상태를 확인합니다.
- 없음: 다음 슬라이드의 런처로 재생성합니다.
- Up: Jupyter에 접속합니다.
- Exited 예외: 호스트 파일 보존 확인 → 중지된 본인 항목만 정리 → 재생성합니다.

```
docker ps -a

# Exited인 본인 항목만, 파일 보존 확인 후
# 로컬 / 원격 중 본인 이름 하나 사용
docker rm physical_ai_local
# 원격 이름: physical_ai_remote01

# 다음 슬라이드의 런처로 재생성
# 실행 중인 항목에는 rm/stop 하지 않기
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

로컬 사용자 · 실습 컨테이너 열기

수업 전 준비 | **Jetson** 호스트 터미널 · 이름·경로·포트는 본인 배정값

USB 카메라를 연결한 뒤 생성합니다.

Jetson 데스크톱 터미널에서 실행합니다.

접속: http://localhost:8888

토큰: nvidia

접속 후 뒤의 패키지 설치 단계로 이동합니다.

```
cd /home/nvidia/NEPES
cd 01.Setup/02.Docker
export ROS_DOMAIN_ID=21
bash 04_run_container.sh \
  nepes-course:physical-ai-v1.0 \
  /home/nvidia/NEPES \
  local physical_ai_local 8888
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

원격 사용자 · 개인 실습 환경 열기

수업 전 준비 | Jetson 호스트 터미널 · 이름·경로·포트는 본인 배정값

PC에서 SSH로 Jetson에 접속합니다.

본인 자료 폴더·이름·포트를 사용합니다.

접속: http://<Jetson-IP>:8889

토큰: nvidia

USB 카메라는 로컬 담당자가 실행합니다.

```
ssh nvidia@<Jetson-IP>
cd /home/nvidia/NEPES_remote01
cd 01.Setup/02.Docker
export ROS_DOMAIN_ID=22
bash 04_run_container.sh \
  nepes-course:physical-ai-v1.0 \
  /home/nvidia/NEPES_remote01 \
  remote physical_ai_remote01 8889
```

시작 안내 · remote · 01.Setup/README.md

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

공용 Ollama 컨테이너 시작

수업 전 준비 | Jetson 호스트 터미널 · 이름·경로·포트는 본인 배정값

로컬 담당자 한 명이 시작합니다.

개인 Python 컨테이너와 별개입니다.

실행 중이면 같은 서버를
재사용합니다.

다음 단계에서 셸에 들어가
채팅합니다.

```
cd /home/nvidia/NEPES
cd 01.Setup/02.Docker
bash 06_run_ollama.sh \
  /home/nvidia/NEPES

docker ps
# physical_ai_ollama가 Up인지 확인
```

시작 안내 · ollama · 01.Setup/README.md

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Ollama 셸에 접속해 기본 채팅하기

수업 전 준비 | 호스트 → Ollama 컨테이너 → 채팅

호스트에서 docker exec로 들어갑니다.

Gemma 3에 짧은 질문을 보냅니다.

/bye는 채팅 종료입니다.

exit는 컨테이너 셸 종료입니다.

```
docker exec -it \
  physical_ai_ollama /bin/sh
ollama list
ollama run gemma3:1b

# 채팅 화면에서 입력
LLM을 한 문장으로 설명해줘.
/bye
# 다음 다운로드 단계까지 셸 유지
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

임베딩 모델과 Moondream 다운로드

수업 전 준비 | Ollama 컨테이너 셸에서 실행

embeddinggemma: 문서 검색용 벡터

moondream:1.8b: 8교시 이미지 설명

완료 후 ollama list로 확인합니다.

다운로드는 공용 담당자가 한 번 수행합니다.

```
ollama pull embeddinggemma
ollama pull moondream:1.8b
ollama list

# 함께 확인할 수업 모델
# gemma3:1b
# gemma4:e2b-it-qat

exit
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

JupyterLab에서 추가 Python 패키지 설치

수업 전 준비 | 개인 JupyterLab → Launcher → Terminal

각자 개인 실습 환경에 설치합니다.

LangChain·Ollama 연동·PDF 패키지를 준비합니다.

설치 스크립트가 전용 커널을 등록합니다.

설치가 끝날 때까지 기다립니다.

```
cd /workspace
scripts=04.LLM_v2/scripts
bash "$scripts/install_langchain.sh"

PY=Data/venvs/day2-langchain/bin/python
"$PY" -m pip show \
  langchain langchain-ollama pypdf
"$PY" -m pip check
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

커널 선택과 실제 서버 연결 확인

수업 전 준비 | **JupyterLab Terminal → 노트북**

Python (Day2 LangChain)을 선택합니다.

서버 확인 명령은 실제 요청을 보냅니다.

노트북의 sys.executable을 확인합니다.

설치 성공과 모델 응답을 따로 확인합니다.

```
cd /workspace
PY=Data/venvs/day2-langchain/bin/python
scripts=04.LLM_v2/scripts
"$PY" "$scripts/check_langchain.py" \
  --server

# 노트북 첫 코드 셀에서 확인
import sys
print(sys.executable)
```


본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

오늘의 흐름 · LLM 5시간 + VLM 3시간

2일차 v1.03 · 슬라이드 설명 → ipynb 실습 → 결과 확인

1~2교시 모델 비교 · 프롬프트 · 대화 기억

3~5교시 Tool · RAG · 배심원과 판사

6~8교시 이미지 스크립트 · 카메라 · 관찰 요약

각 교시 50분 수업 + 10분 휴식/전환 · 점심 별도

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

오늘의 진행 · 이론을 듣고 노트북을 실행합니다

매 교시 | 강사 설명 → 수강생 실습 시작 → 완료 확인

강사: 그림·핵심 API·입력과 출력 설명

수강생: 「수강생 실습 시작」에서 ipynb 실행

TODO 작성 → 아래 참고 정답과 비교 → 재실행

결과·오류·근거 확인 후 다음 교시로 이동

8교시 공통 진행 · 수업 50분 + 휴식·전환 10분

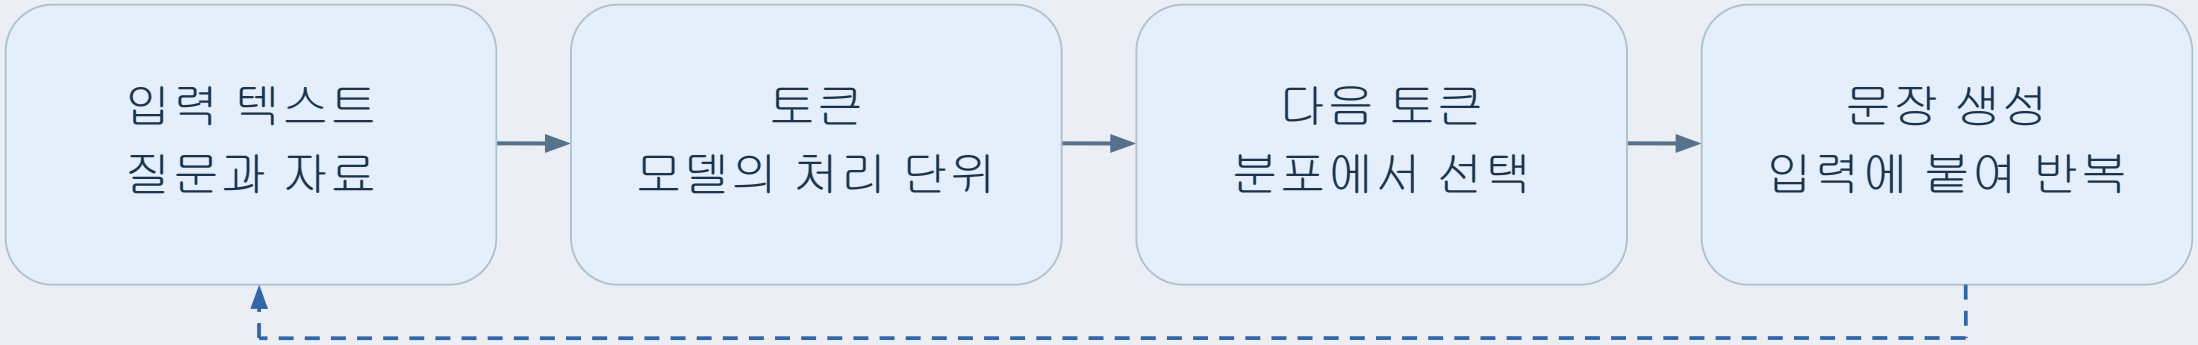
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

LLM은 다음 토큰을 반복해서 생성합니다

강사 설명 | 1교시 · LLM | 이론 후 ipynb 실습

ALL AI

생성한 토큰도 다음 계산의 문맥에 포함됩니다. 자연스러움과 사실성은 별개입니다.



지금까지의 입력으로 다음 토큰을 선택합니다.
생성한 토큰을 붙여 이 과정을 반복합니다.
자연스러운 문장이 사실을 보장하지는 않습니다.

04.LLM_v2/01_ollama_basics.ipynb

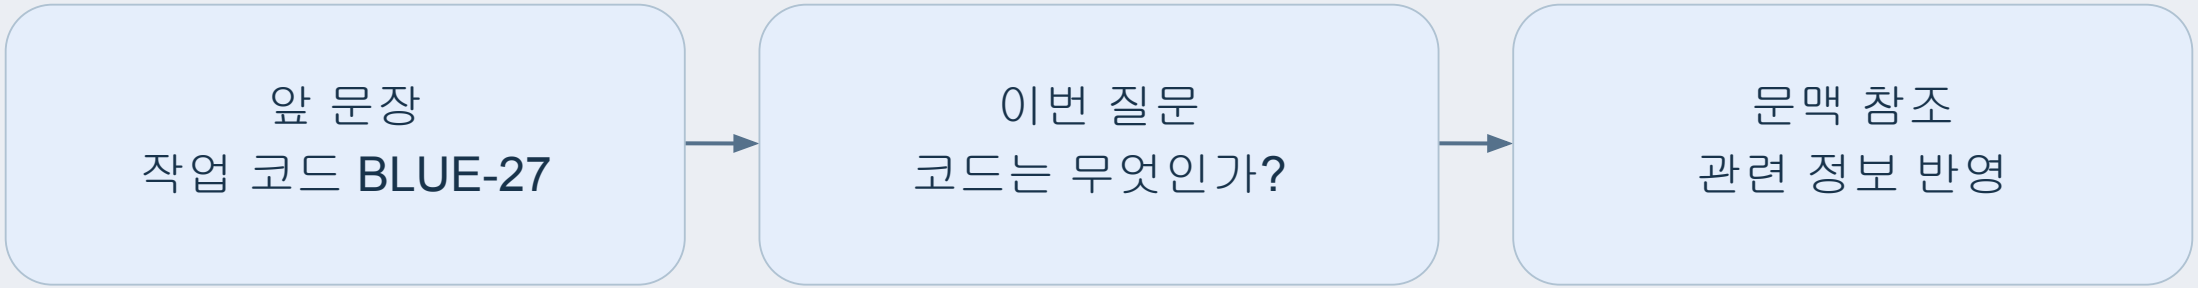
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Attention과 문맥의 역할

강사 설명 | 1교시 · LLM | 이론 후 ipynb 실습

ALL AI

이번 요청에 과거 메시지를 넣지 않으면 그 내용이 자동 전달되지 않습니다.



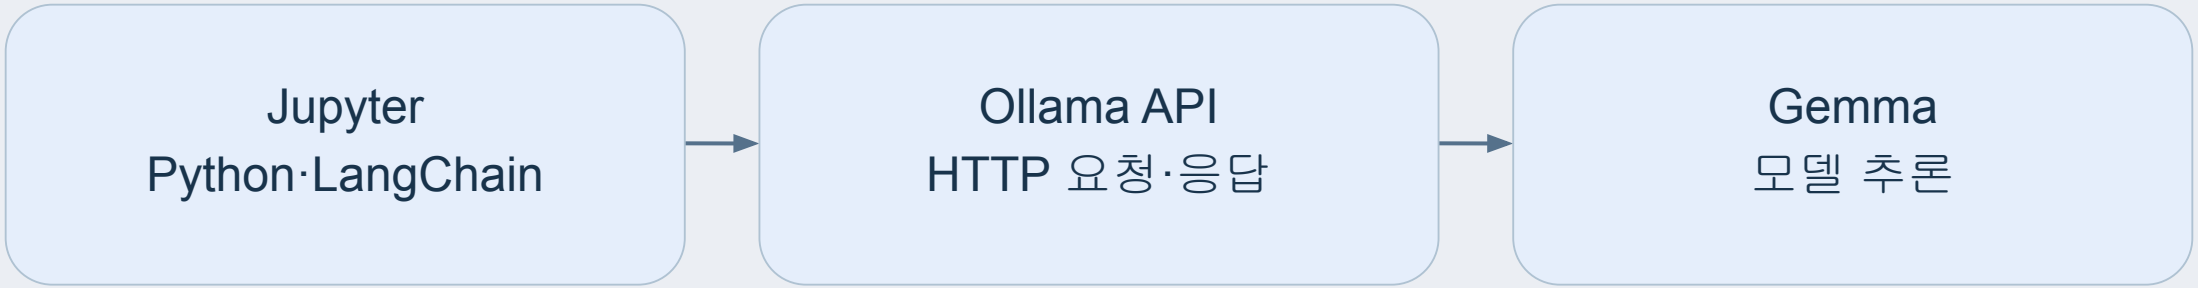
Attention은 문맥 안의 관련 정보를 반영합니다.
이번 요청에 들어간 내용이 답변의 바탕입니다.
받지 않은 센서 값은 알 수 없습니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

세 구성요소의 실행 위치

강사 설명 | 1교시 · LLM | 이론 후 ipynb 실습

Python 컨테이너와 모델 서버는 다릅니다. Tool도 Python 쪽에서 실행합니다.



LangChain은 Python의 입력과 처리를 연결합니다.
Ollama는 모델 요청을 받는 서버입니다.
Gemma는 실제 답변을 생성합니다.

04.LLM_v2/01_ollama_basics.ipynb

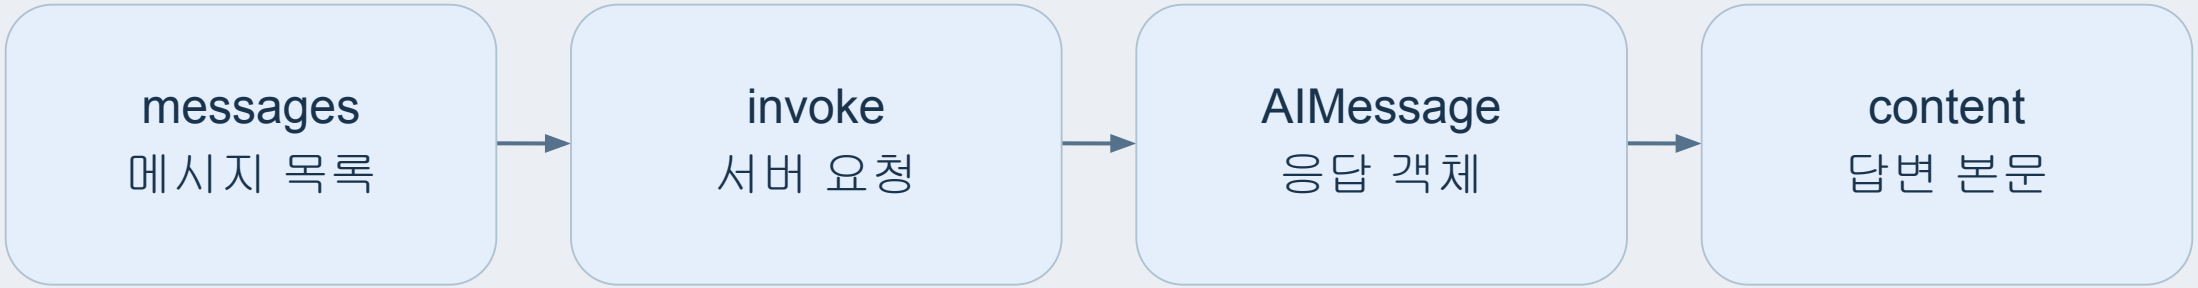
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

메시지 목록을 보내고 반환값을 읽습니다

강사 설명 | 1교시 · LLM | 이론 후 ipynb 실습

ALL AI

아래 코드는 실제 모델 요청 1회입니다.



메시지는 역할과 내용을 묶은 객체입니다.
invoke가 요청하고 AIMessage가 돌아옵니다.
답변 본문은 reply.content로 읽습니다.

04.LLM_v2/01_ollama_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

같은 질문에 자료를 추가합니다

강사 설명 | 1교시 · LLM | 이론 후 ipynb 실습

ALL AI

질문과 모델을 같게 두고 자료만 바꿉니다.

답변의 근거가 입력에 있는지 확인합니다.

자료에 없는 값도 질문해봅니다.

```
question = "무엇을 기록하나요?"
# 자료를 바꾸고 같은 질문으로 비교
reply = model.invoke(messages)
print(reply.content)
```

04.LLM_v2/01_ollama_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 1교시

설명 20분 → 실습 25분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 04.LLM_v2/01_ollama_basics.ipynb

진행: Gemma 3 호출 → Gemma 4 모델 변경 TODO

완료: 같은 질문의 두 응답과 모델 이름 확인

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

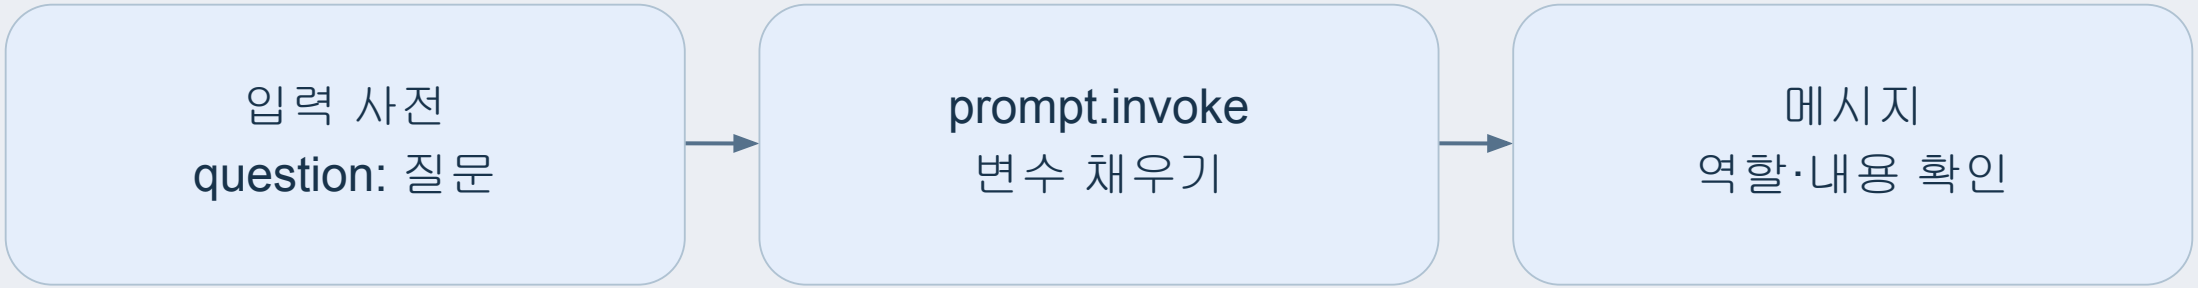
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Python 사전으로 프롬프트 변수를 채웁니다

강사 설명 | 2교시 · LLM | 이론 후 ipynb 실습

ALL AI

프롬프트 생성과 모델 실행을 따로 확인한 뒤 연결합니다.



사전의 키가 템플릿 변수명과 일치해야 합니다.
prompt.invoke는 메시지를 만듭니다.
아직 모델을 호출하지 않습니다.

04.LLM_v2/02_prompt_chat.ipynb

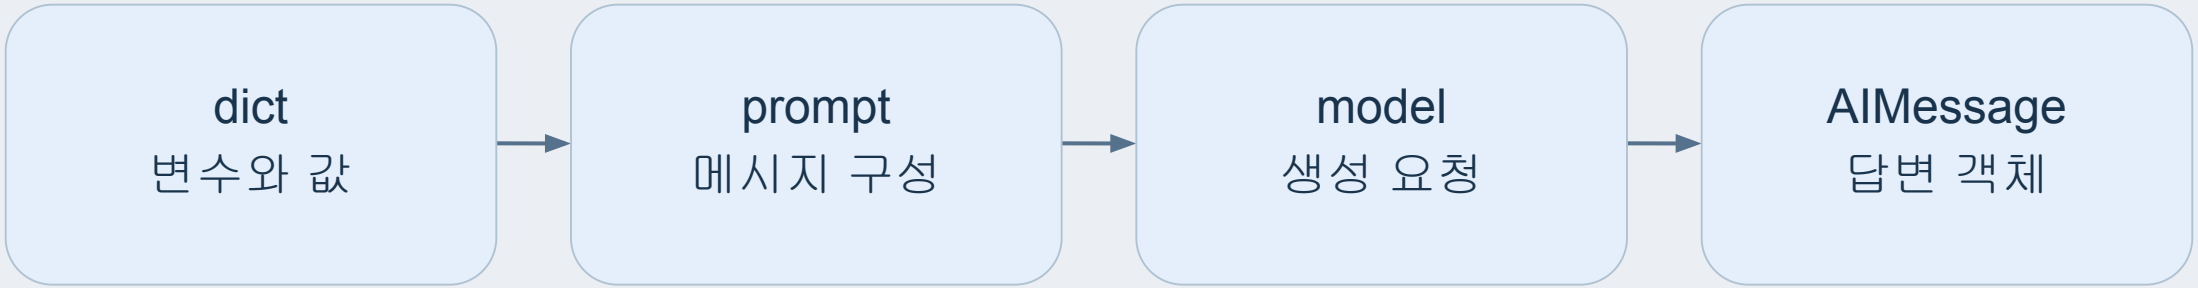
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

파이프 연산자로 처리 순서를 연결합니다

강사 설명 | 2교시 · LLM | 이론 후 ipynb 실습

ALL AI

chain.invoke에는 프롬프트가 요구하는 사전을 넣습니다.



|는 왼쪽 결과를 오른쪽 입력에 연결합니다.
chain.invoke에서 전체 흐름을 실행합니다.
중간값을 먼저 확인하고 연결합니다.

04.LLM_v2/02_prompt_chat.ipynb

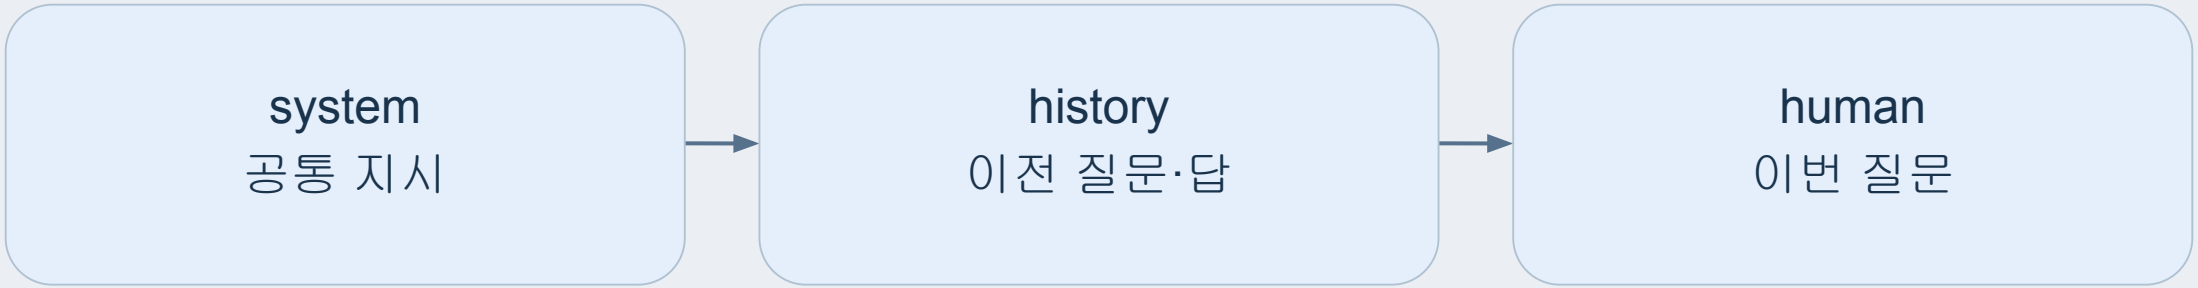
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

기억은 이전 메시지를 다시 보내는 것입니다

강사 설명 | 2교시 · LLM | 이론 후 ipynb 실습

ALL AI

순서: system → 이전 human/ai 쌍 → 이번 human. 이번 질문을 history에 미리 넣지 않습니다.



MessagesPlaceholder는 이력이 들어갈 자리입니다.
Python이 이전 질문과 답을 다시 전달합니다.
이번 질문을 이력에 중복해서 넣지 않습니다.

04.LLM_v2/02_prompt_chat.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

TODO · 최근 대화만 선택합니다

강사 설명 | 2교시 · LLM | 이론 후 ipynb 실습

최근 대화 쌍을 선택합니다.

TODO 아래 참고 정답과 비교합니다.

학생 함수를 고쳐 챗봇에 적용합니다.

```
def select_recent(history, max_pairs=2):
    # TODO: 최근 대화 쌍 선택
    return []

recent = select_recent(history)
```

04.LLM_v2/02_prompt_chat.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

기억·지시·모델을 구분해 평가합니다

강사 설명 | 2교시 · LLM | 이론 후 ipynb 실습

기억은 이전 입력, 단계별 지시는 출력 요구입니다.

조건을 한 가지씩 바꾸어 비교합니다.

입력과 응답을 함께 기록하고 비교합니다.

```
history.clear()
# Python 대화 목록만 초기화

# 모델 비교 전체 실행: 선택 복습
```

04.LLM_v2/02_prompt_chat.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 2교시

설명 15분 → 실습 30분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 04.LLM_v2/02_prompt_chat.ipynb

진행: 최근 대화 선택 TODO → 챗봇에 적용

완료: 이력 유무에 따른 입력·응답 비교

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

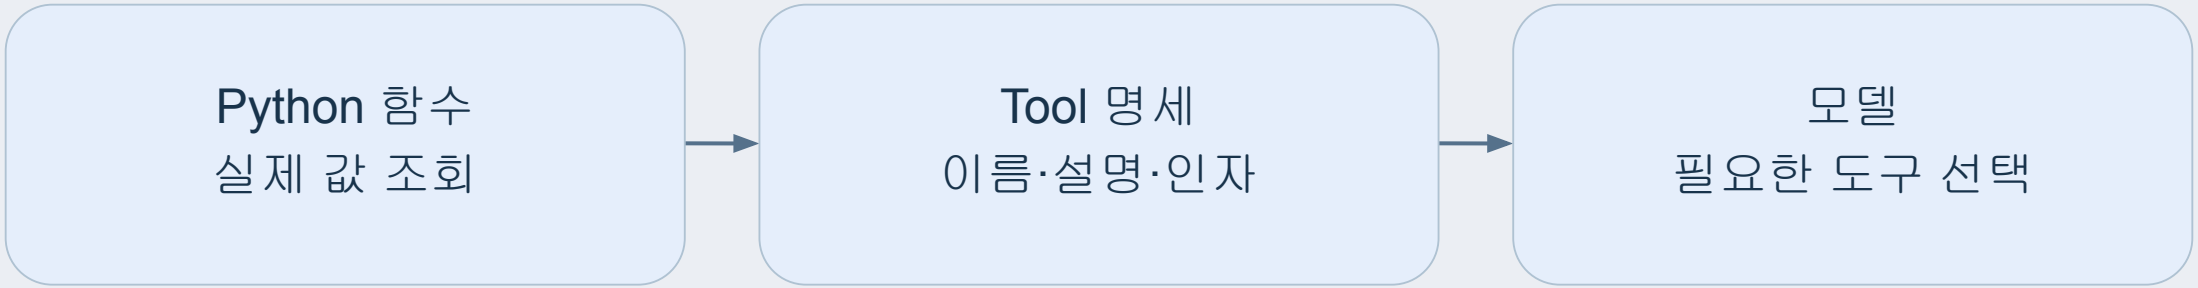
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

함수와 Tool의 관계

강사 설명 | 3교시 · LLM | 이론 후 ipynb 실습

ALL AI

Tool을 제공하는 것과 실행하는 것은 서로 다른 단계입니다.



함수는 실제 코드를 실행합니다.
Tool은 이름·설명·입력 형식을 제공합니다.
모델이 선택하고 Python이 실행합니다.

04.LLM_v2/03_tool_calling.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

@tool로 도구의 이름과 설명을 제공합니다

강사 설명 | 3교시 · LLM | 이론 후 ipynb 실습

조회 함수의 전체 코드를 먼저 읽습니다.

일반 함수 실행 후 @tool로 감쌉니다.

docstring과 입력 규격을 확인합니다.

```
@tool
def get_jetson_status() -> str:
    """현재 온도와 메모리를 조회합니다."""
    result = read_system_status()
    return json.dumps(result)
```

04.LLM_v2/03_tool_calling.ipynb

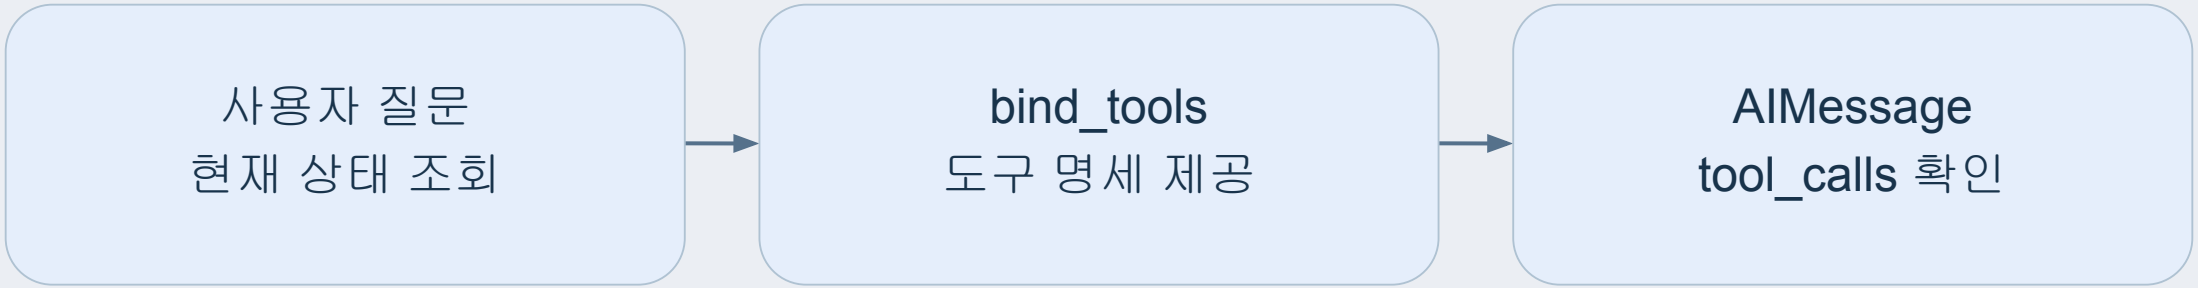
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

bind_tools는 도구 정보를 모델에 전달합니다

강사 설명 | 3교시 · LLM | 이론 후 ipynb 실습

ALL AI

도구 사용을 지원하는 배포 Gemma 4 모델을 사용합니다.



bind_tools는 사용할 도구의 명세를 제공합니다.
응답의 tool_calls에서 이름·인자·id를 읽습니다.
이 시점에는 실제 센서를 읽지 않았습니다.

04.LLM_v2/03_tool_calling.ipynb

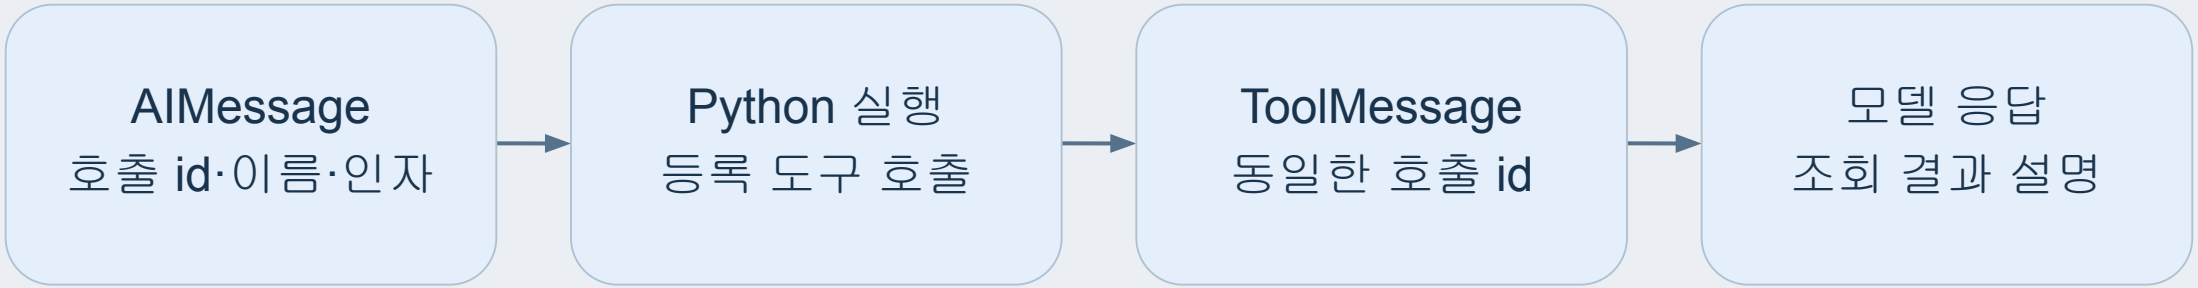
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Python 실행 결과를 ToolMessage로 돌려줍니다

강사 설명 | 3교시 · LLM | 이론 후 ipynb 실습

ALL AI

모델 요청과 Python 실행을 구분하고, 같은 요청 ID로 결과를 연결합니다.



요청 메시지를 남기고 Python 도구를 실행합니다.
같은 호출 id로 ToolMessage를 연결합니다.
모델은 실행 결과를 받아 설명합니다.

04.LLM_v2/03_tool_calling.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 3교시

설명 20분 → 실습 25분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 04.LLM_v2/03_tool_calling.ipynb

진행: 파일 읽기·split Tool TODO → invoke

완료: 예상 단어 목록과 경로 오류 확인

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

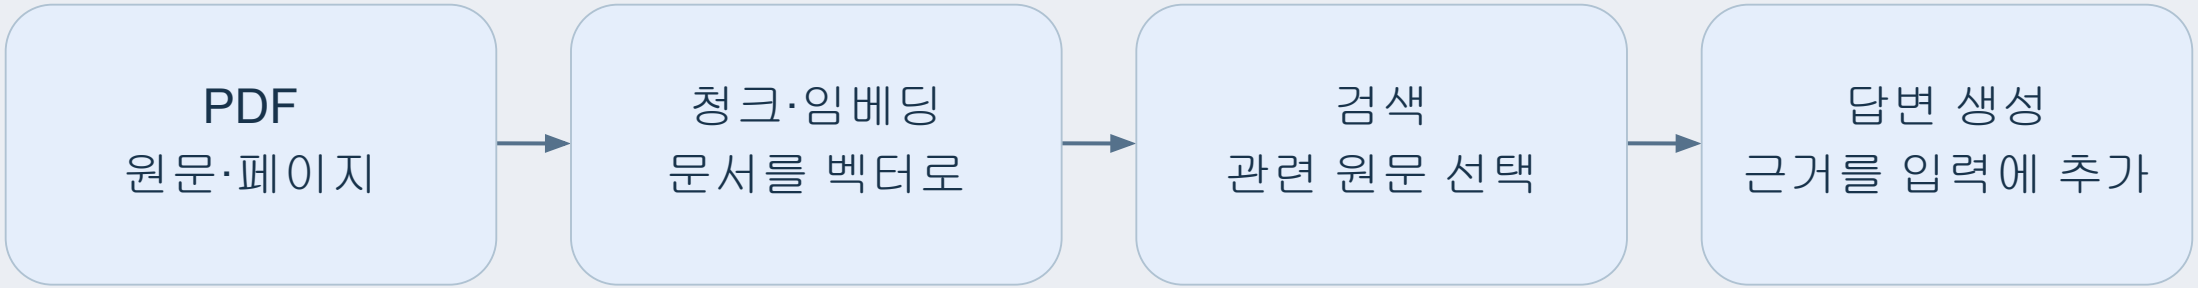
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

RAG는 검색 자료를 입력에 추가합니다

강사 설명 | 4교시 · LLM | 이론 후 ipynb 실습

ALL AI

검색 모델 embeddinggemma와 답변 모델 Gemma 4의 역할은 다릅니다.



문서 준비와 질문 처리를 분리합니다.
검색한 원문을 이번 프롬프트에 넣습니다.
모델을 다시 학습시키는 과정은 아닙니다.

04.LLM_v2/04_rag_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

PDF를 페이지별 Document로 만듭니다

강사 설명 | 4교시 · LLM | 이론 후 ipynb 실습

ALL AI

page_content는 본문, metadata는 출처입니다.

페이지 번호는 1부터 붙입니다.

metadata를 나중에 프롬프트에 직접 넣습니다.

```
pages.append(Document(
    page_content=text,
    metadata={
        "source": pdf_path.name,
        "page": number,
    },
))
```

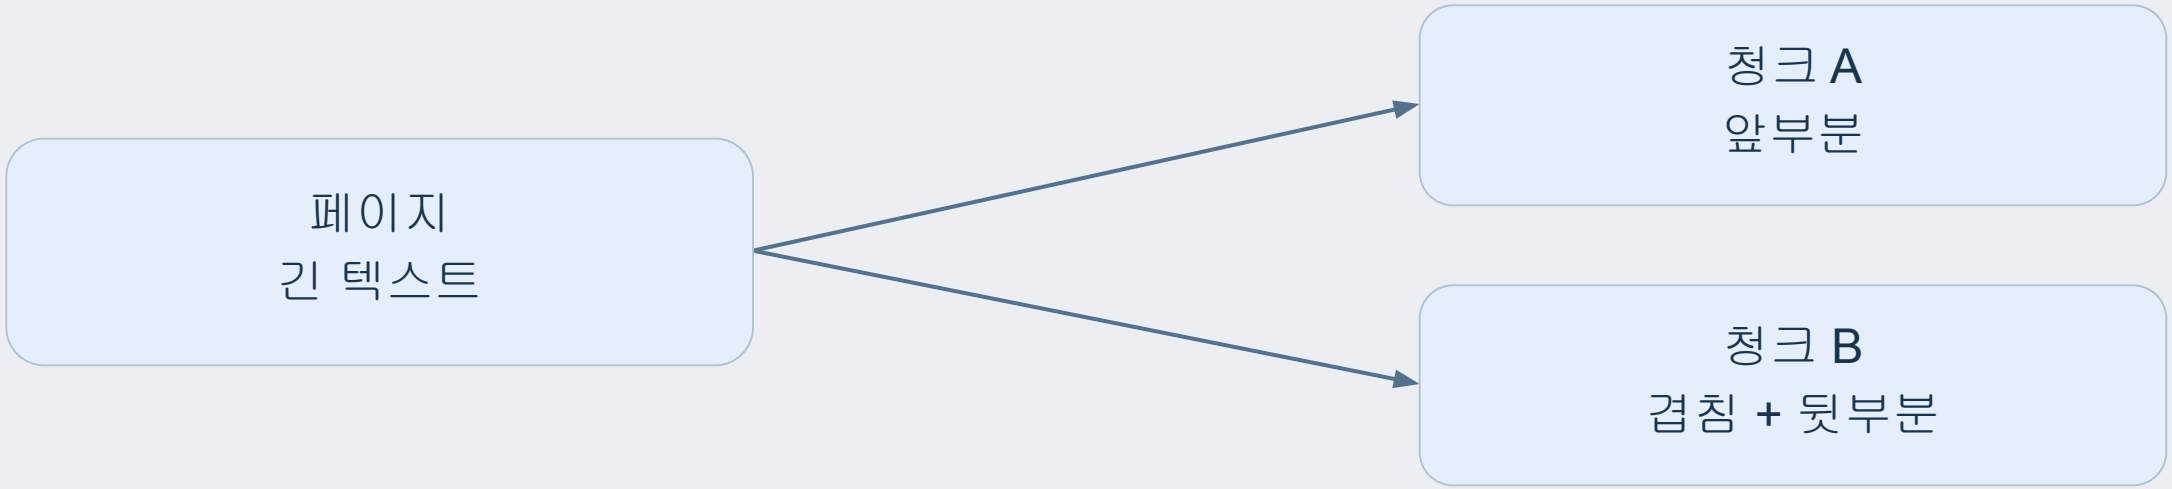
04.LLM_v2/04_rag_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

청크를 만들고 출처를 유지합니다

강사 설명 | 4교시 · LLM | 이론 후 ipynb 실습

출처와 페이지 번호가 각 청크에 남아 있어야 원문을 찾을 수 있습니다.



청크는 검색에 사용할 작은 텍스트 조각입니다.
겹침으로 경계의 문맥을 일부 유지합니다.
출처와 페이지를 보존합니다.

04.LLM_v2/04_rag_basics.ipynb

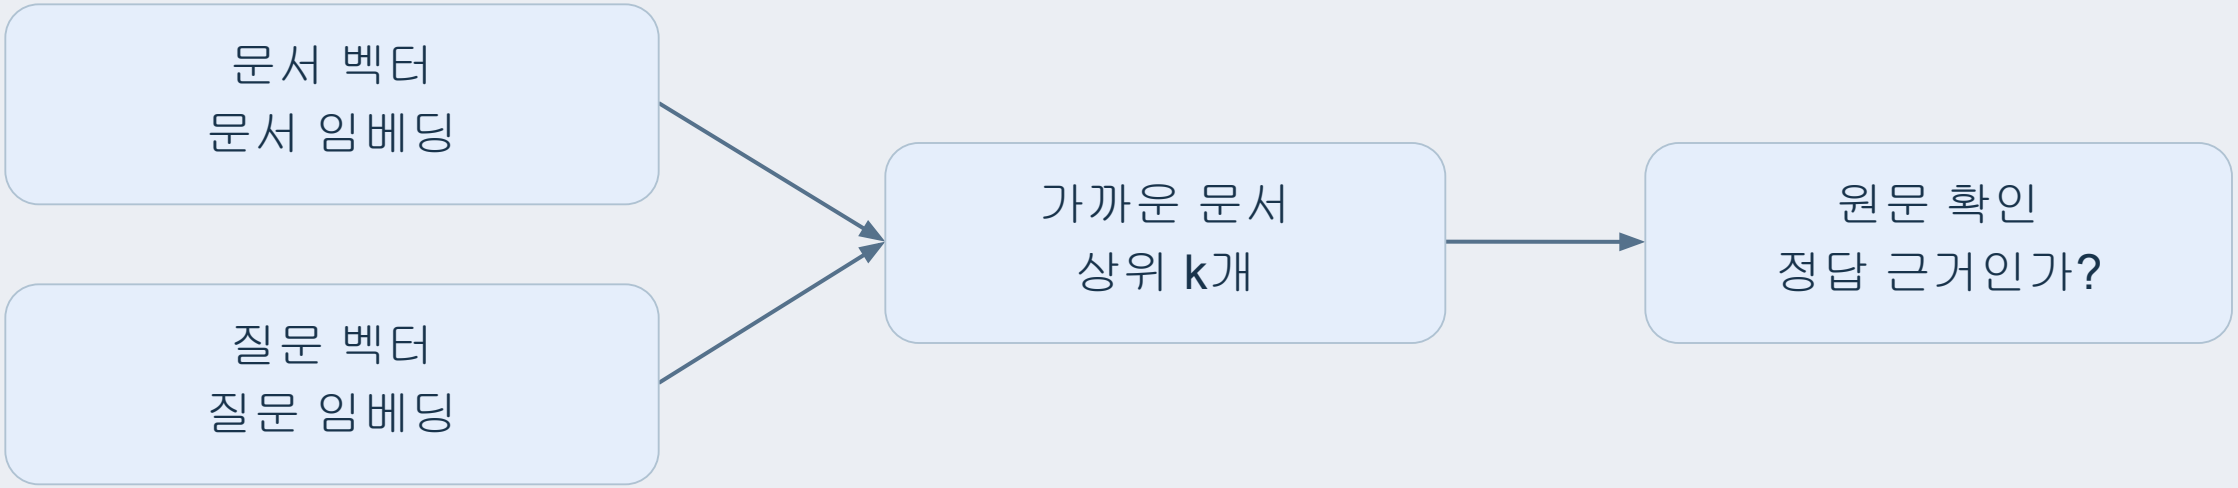
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

임베딩으로 의미가 가까운 문서를 검색합니다

강사 설명 | 4교시 · LLM | 이론 후 ipynb 실습

ALL AI

아래 저장 셀은 실제 임베딩 요청입니다. 답변 생성은 아직 하지 않습니다.



문서와 질문을 숫자 벡터로 표현합니다.
가까운 문서를 찾고 원문으로 확인합니다.
검색 점수는 정답 확률이 아닙니다.

04.LLM_v2/04_rag_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

TODO · 출처를 포함한 문맥 만들기

강사 설명 | 4교시 · LLM | 이론 후 ipynb 실습

ALL AI

파일명·페이지를 본문 앞에 붙입니다.

TODO 아래 참고 정답과 비교합니다.

출처와 원문을 실제 답변과 대조합니다.

```
for doc in documents:
    # TODO: 출처 + 본문
    text = doc.page_content
    parts.append(text)
context = "\n\n".join(parts)
```

04.LLM_v2/04_rag_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 4교시

설명 20분 → 실습 25분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 04.LLM_v2/04_rag_basics.ipynb

진행: 출처 문맥 TODO → 실제 RAG 답변

완료: 원문·파일명·페이지와 답변 대조

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

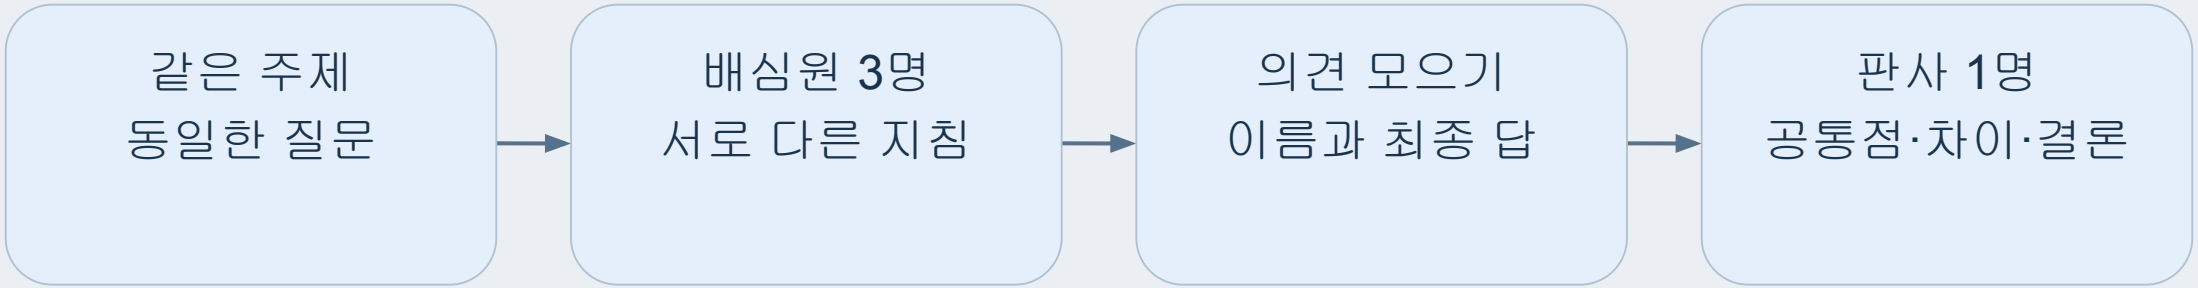
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

배심원 3명과 판사 1명

강사 설명 | 5교시 · LLM | 이론 후 ipynb 실습

ALL AI

같은 모델, 서로 다른 system_prompt. 실행 순서는 Python이 정합니다.



같은 주제를 세 관점에서 검토합니다.
Python이 의견을 모아 판사에게 전달합니다.
이번 Agent는 도구를 사용하지 않습니다.

04.LLM_v2/05_agent.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

서로 다른 관점을 지침에 담습니다

강사 설명 | 5교시 · LLM | 이론 후 ipynb 실습

효율 중심의 낙관적인 배심원

위험을 찾는 신중한 배심원

사용자 부담을 보는 실무형 배심원

```
juror = create_agent(
    model=model,
    tools=[],
    system_prompt=persona,
)
```

04.LLM_v2/05_agent.ipynb

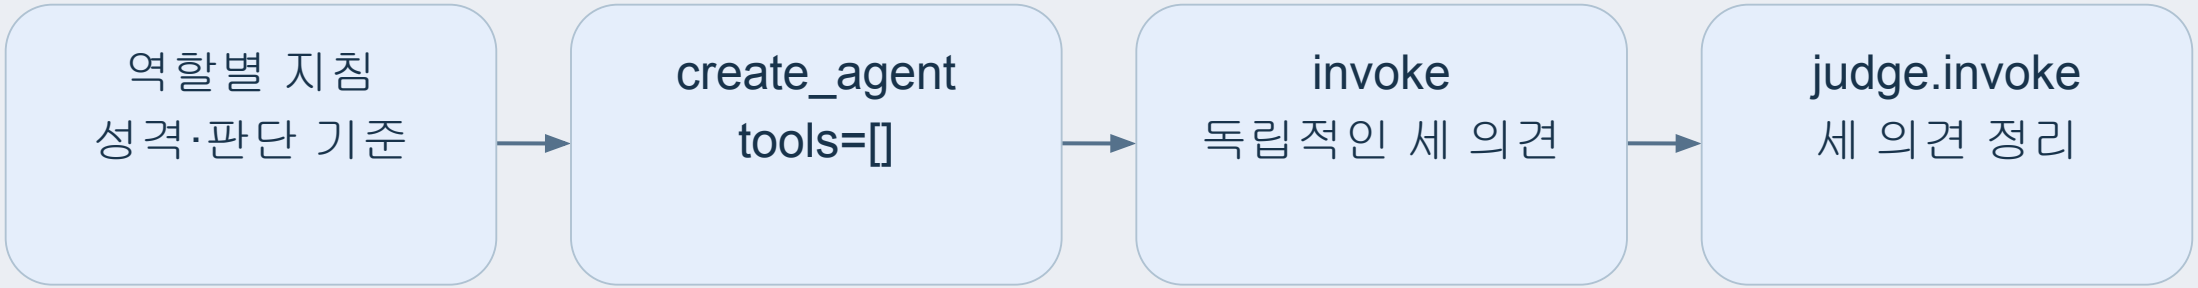
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

도구 없는 네 Agent를 순서대로 실행합니다

강사 설명 | 5교시 · LLM | 이론 후 ipynb 실습

ALL AI

모델 요청 총 4회입니다. 순차 실행이므로 응답을 기다리세요.



배심원마다 독립적인 입력을 전달합니다.
다른 배심원의 답은 공유하지 않습니다.
세 의견이 준비되면 판사를 실행합니다.

04.LLM_v2/05_agent.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

판사에게 의견을 명시적으로 전달합니다

강사 설명 | 5교시 · LLM | 이론 후 ipynb 실습

역할 이름과 의견을 함께 묶습니다.

판사는 전달받은 자료로 정리합니다.

소수 의견과 조건이 남았는지 확인합니다.

```
parts = []
for row in opinions:
    parts.append(row["name"] + "\n"
                 + row["opinion"])
# 주제 + 세 의견 → 판사 입력
```

04.LLM_v2/05_agent.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 5교시

설명 15분 → 실습 30분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 04.LLM_v2/05_agent.ipynb

진행: 배심원 3명 → 판사 1명 순차 실행

완료: 세 의견과 판사 정리의 일치 확인

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

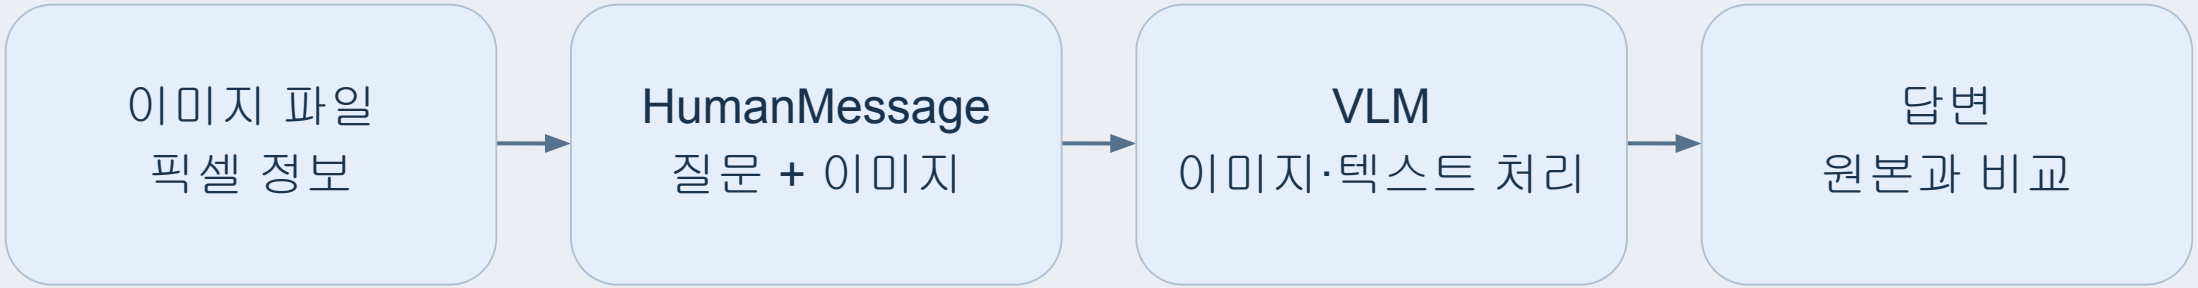
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

LLM 메시지에 이미지 입력을 추가합니다

강사 설명 | 6교시 · VLM | 이론 후 ipynb 실습

ALL AI

이미지 입력만으로 모든 프레임이나 사진 밖의 장면을 알 수는 없습니다.



질문과 이미지가 같은 메시지에 들어갑니다.
모델은 전달받은 이미지로 답합니다.
사진 밖의 장면이나 시간을 추측하지 않습니다.

05.VLM_v2/01_vlm_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

JPEG 압축과 Base64는 다릅니다

강사 설명 | 6교시 · VLM | 이론 후 ipynb 실습

긴 변 768 이하, JPEG 품질 80으로 저장합니다.

압축은 크기와 세부 정보를 바꿉니다.

Base64는 전송용 문자열 표현입니다.

```
image.thumbnail((768, 768))
buffer = BytesIO()
image.save(buffer, format="JPEG",
           quality=80, optimize=True)
encoded = base64.b64encode(
    buffer.getvalue()).decode("ascii")
```

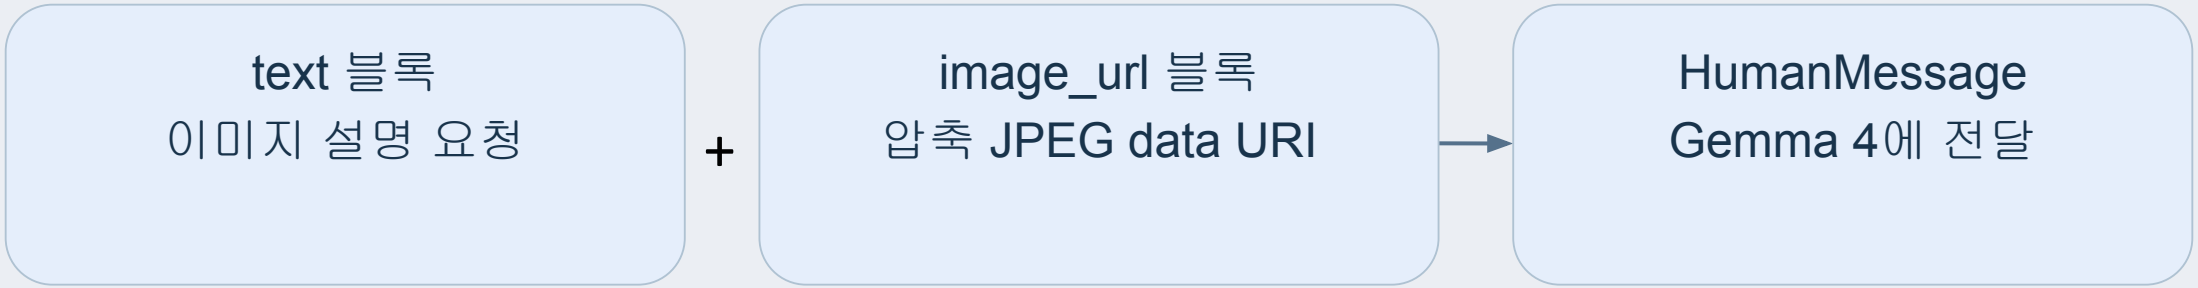
05.VLM_v2/01_vlm_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

TODO · main(image_path) 완성하기

강사 설명 | 6교시 · VLM | 이론 후 ipynb 실습

describe_image.py에 저장합니다. 전체 참고 정답은 **TODO** 바로 아래에 있습니다.



main 안에서 이미지 파일을 엽니다.
JPEG 압축 뒤 질문과 이미지를 보냅니다.
응답 본문을 터미널에 출력합니다.

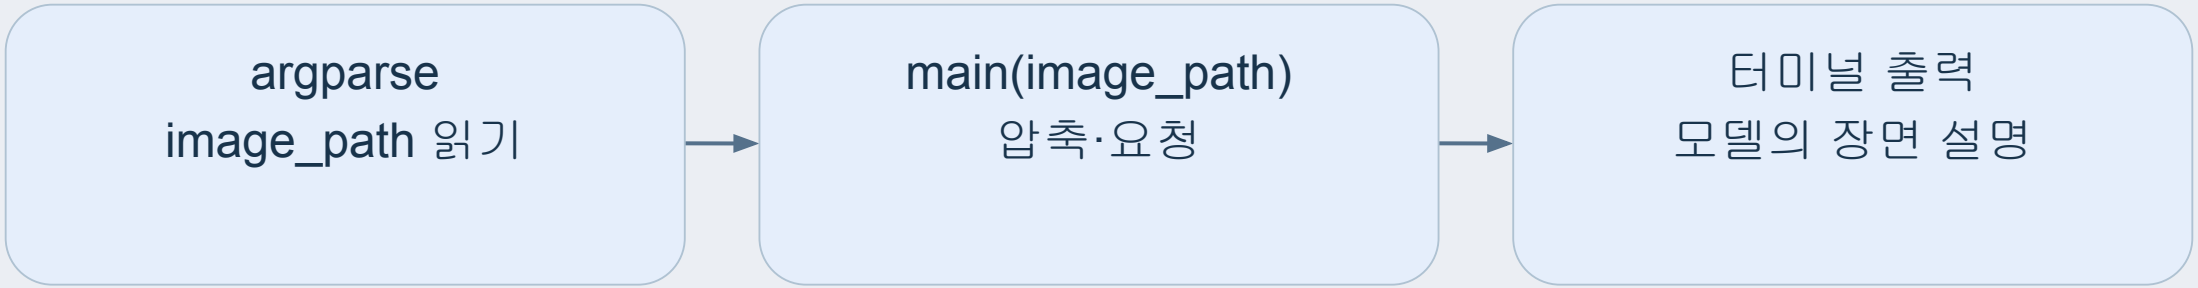
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

터미널에서 스크립트를 실행합니다

강사 설명 | 6교시 · VLM | 이론 후 ipynb 실습

ALL AI

노트북 함수 수정과 외부 .py 파일 저장을 구분하세요.



위치 인자로 이미지 경로를 받습니다.
main이 이미지 처리와 모델 요청을 합니다.
reply.content를 print로 출력합니다.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

압축 전 원본과 설명을 비교합니다

강사 설명 | 6교시 · VLM | 이론 후 ipynb 실습

원본 파일은 덮어쓰지 않습니다.

작은 물체나 글자가 누락되는지 봅니다.

파일 크기와 화질은 직접 확인합니다.

```
print(original_size, resized_size)
print(len(compressed), "bytes")
reply = model.invoke([message])
print(reply.content)
```

05.VLM_v2/01_vlm_basics.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 6교시

설명 15분 → 실습 30분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 05.VLM_v2/01_vlm_basics.ipynb

진행: describe_image.py의 main TODO → 터미널 실행

완료: JPEG 축소·Gemma 4 설명·원본 비교

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

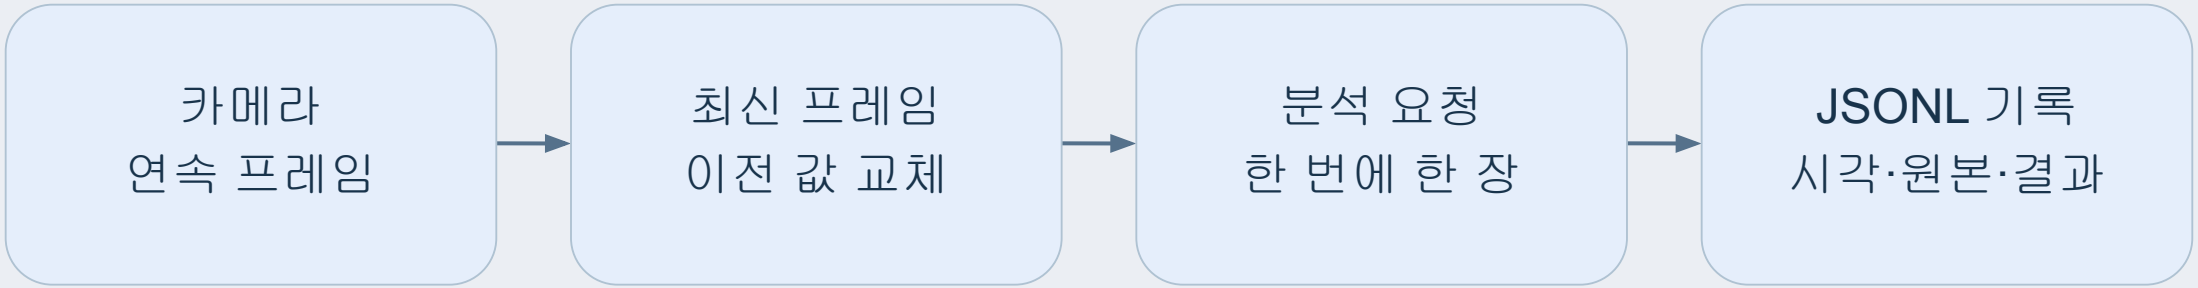
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

카메라 촬영과 모델 분석의 속도는 다릅니다

강사 설명 | 7교시 · VLM | 이론 후 ipynb 실습

ALL AI

분석하지 않은 시간 구간에 무슨 일이 있었는지는 알 수 없습니다.



촬영은 계속되고 모델 요청에는 시간이 듭니다.
최신 프레임 한 장을 선택합니다.
관찰하지 않은 구간의 사건은 알 수 없습니다.

05.VLM_v2/02_camera_records.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

실행 위치와 공동 실습 역할

강사 설명 | 7교시 · VLM | 이론 후 ipynb 실습

로컬 담당자 한 명이 카메라를 엽니다.

장면 변경과 관찰 기록 역할을 교대합니다.

카메라 장애가 길어지면 녹화 입력으로 전환합니다.

```
--source camera
--interval 10
--max-requests 3
--preview

# 전체 명령은 노트북에서 확인
```

05.VLM_v2/02_camera_records.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

자신의 로그 파일을 명시적으로 선택합니다

강사 설명 | 7교시 · VLM | 이론 후 ipynb 실습

터미널에 출력된 자기 로그 경로를 넣습니다.

ID·시각·원본 경로·raw·status를 읽습니다.

dry-run은 실제 VLM 관찰이 아닙니다.

```
OBSERVATION_LOG = "실제 로그 경로"
records = load_observations(
    Path(OBSERVATION_LOG)
)
print(records[0]["captured_at_utc"])
```

05.VLM_v2/02_camera_records.ipynb

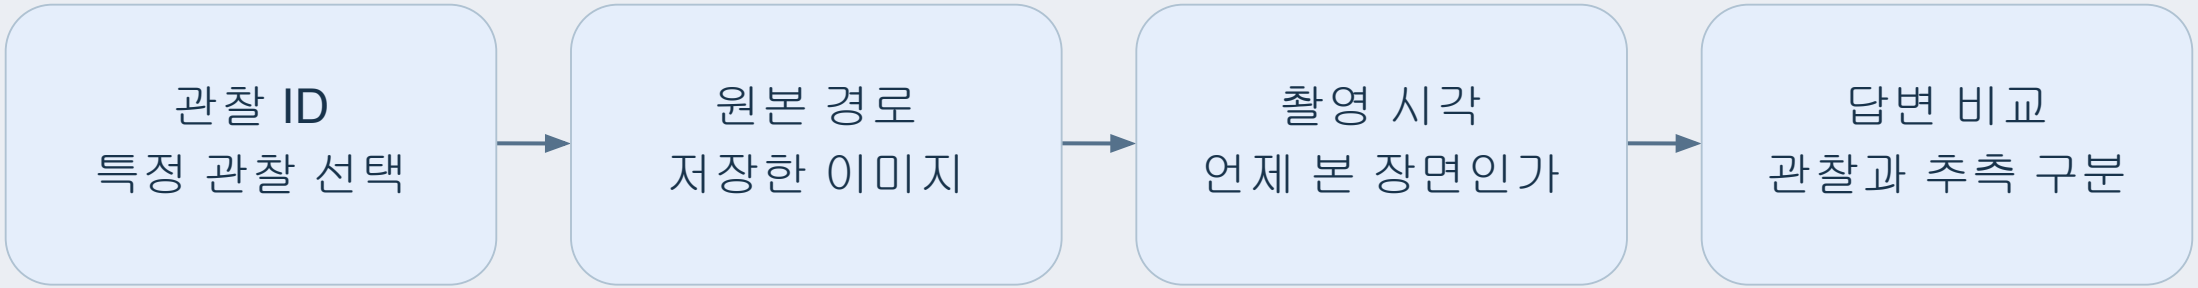
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

답변에서 원본 프레임으로 돌아갑니다

강사 설명 | 7교시 · VLM | 이론 후 ipynb 실습

ALL AI

모델 지연 동안 장면이 바뀌었을 수 있습니다.



관찰 ID로 저장한 원본 프레임을 찾습니다.
촬영 시각과 모델 응답 시각을 구분합니다.
문장이 실제 이미지에 근거하는지 확인합니다.

05.VLM_v2/02_camera_records.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

10초 간격과 실제 관찰 간격을 구분합니다

강사 설명 | 7교시 · VLM | 이론 후 ipynb 실습

10초는 요청 시작 사이의 최소 간격입니다.

모델이 느리면 실제 관찰 간격은 늘어납니다.

모든 프레임을 분석하는 설정은 아닙니다.

```
--interval 10
# 요청 간 최소 간격

--max-requests 3
# EOF / 중단 시 더 적을 수 있음
```

05.VLM_v2/02_camera_records.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이 무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 7교시

설명 15분 → 실습 30분 → 완료 확인 5분 | 이후 휴식·전환 10분

열기: 05.VLM_v2/02_camera_records.ipynb

진행: 전체 카메라 코드 읽기 → Gemma 4 관찰

완료: 자기 로그의 ID·시각·원본·raw 확인

결과·오류를 확인한 뒤 다음 설명으로 이동합니다.

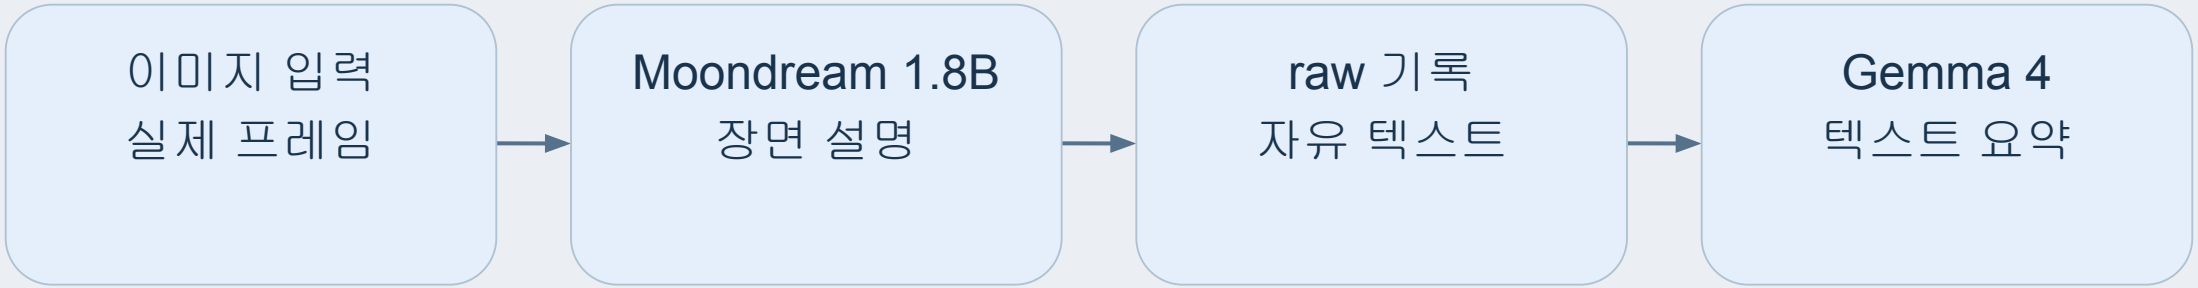
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

Moondream 1.8B를 소개합니다

강사 설명 | 8교시 · VLM | 이론 후 ipynb 실습

ALL AI

Ollama moondream:1.8b · 문맥 2K · 모델 다운로드는 수업 전에 완료



짧은 영어 질문으로 장면을 설명합니다.
같은 camera_vlm.py를 재사용합니다.
관찰 텍스트를 다음 LLM 입력으로 씁니다.

05.VLM_v2/03_observation_summary.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

관찰 기록을 읽고 사용할 범위를 정합니다

강사 설명 | 8교시 · VLM | 이론 후 ipynb 실습

id·촬영 시각·status·raw를 확인합니다.

최근 N개 행을 먼저 선택합니다.

N개 기록은 N초와 다릅니다.

```
records = load_observations(log_path)
window = records[-max_records:]

# ok + 비어 있지 않은 문자열
# ID · 시각 · 원문을 문맥으로 연결
```

05.VLM_v2/03_observation_summary.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

TODO · 최근 관찰을 문맥으로 만듭니다

강사 설명 | 8교시 · VLM | 이론 후 ipynb 실습

함수의 입력은 기록 리스트와 N입니다.

출력은 ID·시각이 붙은 문자열입니다.

빈 결과는 빈 문자열을 반환합니다.

```
def filter_observation_window(
    records, max_records=3
):
    # 최근 N개 → 정상 raw 선택
    # ID·시각·원문 → 줄바꿈 연결
    ...
```

05.VLM_v2/03_observation_summary.ipynb

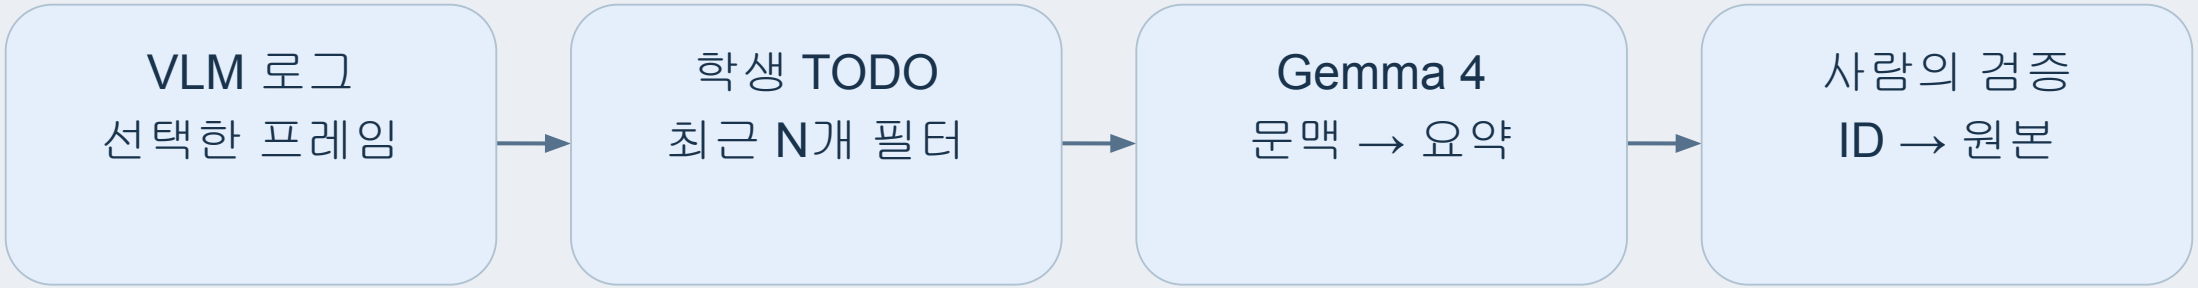
본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

관찰 텍스트를 Gemma 4가 요약합니다

강사 설명 | 8교시 · VLM | 이론 후 ipynb 실습

ALL AI

prompt | model · 이미지가 아닌 관찰 텍스트를 전달합니다.



프롬프트와 모델을 Chain으로 연결합니다.
문맥이 비었으면 호출하지 않습니다.
요약에 관찰 ID를 붙이도록 요청합니다.

05.VLM_v2/03_observation_summary.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

요약 → 관찰 ID → 원본으로 검증합니다

강사 설명 | 8교시 · VLM | 이론 후 ipynb 실습

각 문장의 ID가 선택한 기록에 있는가?

원문과 이미지가 그 설명을 뒷받침하는가?

보지 못한 구간을 추측하지 않았는가?

선택·제외 ID와 결과를 summary.json에 저장합니다.

05.VLM_v2/03_observation_summary.ipynb

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

수강생 실습 시작 · 8교시

관찰·설명 15분 → TODO 15분 → 요약 10분 → 검증 10분

열기: 05.VLM_v2/03_observation_summary.ipynb

진행: Moondream 관찰 → 필터 TODO → Gemma 4 요약

완료: 계약 검사 통과 · ID/원본 검증 · 보고서 저장

TODO 바로 아래 참고 정답과 비교하세요.

본 자료의 저작권은 (주)올에이아이에 있으며, 사전 승인 없이
무단 전재, 복사, 배포, 수정을 엄격히 금합니다.

감사합니다



경기도 성남시 분당구 판교로 289번길 20 판교테크노밸리
스타트업캠퍼스 1동 806호-807호

Copyright @ 2026 ALL.AI Inc. All rights reserved.

www.allai.co.kr